



INSTITUTO POLITÉCNICO NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO
ESCOM



Trabajo terminal

**Prototipo de sistema logístico terrestre con base en predicciones
meteorológicas**

2025-B143

Presentan:

Alberto Flores Lara

Ethel Padilla Rodríguez

Sergio Alberto Franco Calderas

Directores:

Dr. Daniel Molina Pérez

Mtro. Marco Antonio Ortiz Castillo

Fecha de presentación: 18 de diciembre de 2025



INSTITUTO POLITÉCNICO NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO
SUBDIRECCIÓN ACADÉMICA



NO de TT: **2025-B143**

Fecha de presentación: 18 de diciembre de 2025

Documento técnico

**Prototipo de sistema logístico terrestre con base en predicciones
meteorológicas**

Presentan:

Alberto Flores Lara

Ethel Padilla Rodríguez

Sergio Alberto Franco Calderas

Directores:

Dr. Daniel Molina Pérez

Mtro. Marco Antonio Ortiz Castillo

Resumen

El presente trabajo terminal tiene como objetivo desarrollar un prototipo de sistema logístico que optimice las rutas de transporte terrestre mediante el uso de predicciones meteorológicas basadas en modelos de Machine Learning. Estos modelos analizarán datos climáticos históricos con la finalidad de contribuir a evitar contratiempos ocasionados por lluvias, protegiendo tanto los tiempos de traslado como la integridad de los productos transportados. Para lograrlo, se implementarán algoritmos bioinspirados como podrían ser los genéticos y los de enjambre de partículas, tomando como restricciones las condiciones meteorológicas que se presenten en la ruta, de esta manera el sistema contribuirá a mejorar la seguridad y optimizar tiempos en el sector logístico del país.

Palabras clave - Algoritmos de optimización, Heurística, Condiciones climáticas, Machine Learning.

Índice general

RESUMEN.....	I
1. INTRODUCCIÓN	1
1.1. OBJETIVOS	2
1.1.1. <i>Objetivo general</i>	2
1.1.2. <i>Objetivos específicos</i>	2
1.2. JUSTIFICACIÓN	3
2. MARCO REFERENCIAL	4
2.1. INTELIGENCIA ARTIFICIAL.....	4
2.1.1. <i>Algoritmos bioinspirados</i>	4
2.1.1.1. El Problema del Vendedor Viajero (TSP)	4
2.1.1.2. Métodos metaheurísticos para abordar el TSP	5
2.1.1.3. Modelado de la Función Objetivo en Optimización	7
2.1.1.4. Integración de restricciones en la función objetivo.....	8
2.1.1.5. Técnicas para manejo de restricciones.....	9
2.1.2. <i>Machine Learning</i>	9
2.1.2.1. Tipos de algoritmos de Machine Learning.....	10
2.1.2.2. Aplicaciones del Machine Learning	10
2.1.2.3. Modelos utilizados en predicción meteorológica.....	10
2.1.2.4. Métricas de evaluación de modelos de Machine Learning	13
2.1.2.5. Características y fuentes de datos en predicción meteorológica	15
2.2. METEOROLOGÍA	15
2.2.1. <i>El agua en la atmósfera</i>	16
2.2.1.1. Tipos de precipitación.....	16
2.2.1.2. Medida de la precipitación.....	16
2.2.2. <i>Accidentes viales y precipitaciones</i>	17
2.3. ESTADO DEL ARTE	17
2.3.1. <i>Modelos de logística</i>	17
2.3.2. <i>Predicción del clima con machine learning</i>	18
3. PROPUESTA A DESARROLLAR	20
4. ANÁLISIS DE DISEÑO	22
4.1. REQUERIMIENTOS.....	22
4.1.1. <i>Requerimientos funcionales</i>	22
4.1.2. <i>Requerimientos no funcionales</i>	23
4.2. CASOS DE USO	23
4.2.1. <i>Casos de uso del algoritmo bioinspirado</i>	24
4.2.2. <i>Casos de uso del algoritmo de machine learning</i>	27
4.2.3. <i>Casos de uso de la interfaz web</i>	29
4.3. MODELO RELACIONAL DE LA BASE DE DATOS.....	36
4.4. DIAGRAMA DE CLASES	37
4.5. DIAGRAMA DE OBJETOS.....	39
4.6. DIAGRAMAS DE FLUJO	41
4.6.1. <i>Preprocesamiento de datos</i>	41
4.6.2. <i>Entrenamiento de los modelos</i>	46
4.7. ÍNDICE DE PENALIZACIÓN Y ENCUESTA	47
4.8. DIAGRAMAS DE SECUENCIA.....	49
4.9. MOCKUPS	53

5.	SELECCIÓN DE MODELOS	57
5.1.	SELECCIÓN DE LENGUAJES DE PROGRAMACIÓN	57
5.2.	EVALUACIÓN DE MODELOS DE MACHINE LEARNING	59
5.2.1.	<i>Pseudocódigos de modelos de Machine Learning</i>	<i>61</i>
5.2.2.	<i>Resultados del entrenamiento de los modelos.....</i>	<i>63</i>
5.3.	EVALUACIÓN DE ALGORITMOS BIOINSPIRADOS	66
5.3.1.	<i>Pseudocódigos de algoritmos bioinspirados.....</i>	<i>67</i>
5.3.2.	<i>Resultados obtenidos y análisis</i>	<i>73</i>
5.3.2.1.	Tiempos de Ejecución.....	73
5.3.2.2.	Calidad de las Soluciones	77
5.3.2.3.	Estabilidad de soluciones.....	81
5.4.	SELECCIÓN DE TECNOLOGÍAS	83
5.4.1.	<i>Selección del algoritmo bioinspirado</i>	<i>83</i>
5.4.2.	<i>Selección del modelo de Machine Learning</i>	<i>84</i>
5.4.3.	<i>Selección de la API meteorológica</i>	<i>84</i>
6.	ALCANCE DEL SISTEMA	86
7.	ESTUDIO DE FACTIBILIDAD	87
7.1.	RECURSOS HUMANOS.....	87
7.2.	RECURSOS DE HARDWARE.....	87
7.3.	INFRAESTRUCTURA.....	88
8.	IMPLEMENTACIÓN DE LA HERRAMIENTA LOGISTICLIMA	89
8.1.	DESARROLLO DEL BACKEND DEL SISTEMA	89
8.1.1.	<i>Preparación de los datos de las Naves Industriales</i>	<i>89</i>
8.1.2.	<i>Implementación del algoritmo de optimización de rutas</i>	<i>91</i>
8.1.3.	<i>Desarrollo de la base de datos.....</i>	<i>93</i>
8.2.	DESARROLLO DEL FRONTEND DEL SISTEMA	93
8.3.	INTEGRACIÓN DEL BACKEND Y EL FRONTEND	99
8.4.	DESPLIEGUE DEL SISTEMA	101
8.4.1.	<i>Empaquetado con Docker</i>	<i>101</i>
8.4.2.	<i>Gestión de datos sensibles y Configuración Segura</i>	<i>102</i>
8.4.3.	<i>Despliegue de la Infraestructura en Google Cloud Platform (GCP)</i>	<i>102</i>
8.4.3.1.	Alojamiento de la Aplicación (Cloud Run).....	102
8.4.3.2.	Base de Datos Administrada (Cloud SQL para MySQL).....	103
8.4.4.	<i>Resultado del Despliegue</i>	<i>104</i>
9.	PRUEBAS	105
9.1.	PRUEBAS DE INTEGRACIÓN	105
9.1.1.	<i>Integración Backend (Python) – Algoritmo del núcleo (C)</i>	<i>105</i>
9.1.2.	<i>Integración Backend – Base de datos</i>	<i>108</i>
9.1.3.	<i>Integración Frontend – Backend</i>	<i>112</i>
9.2.	PRUEBAS DEL ALGORITMO DE RECOCIDO SIMULADO.....	114
9.3.	PRUEBAS DEL MODELO DE PREDICCIÓN METEOROLÓGICA	115
9.4.	PRUEBAS DE ESTRÉS EN EL SERVIDOR.....	120
9.4.1.	<i>Escenario A: “Cálculo Concurrente pocos datos”</i>	<i>121</i>
9.4.2.	<i>Escenario B: “Cálculo Masivo Concurrente”</i>	<i>121</i>
9.4.3.	<i>Escenario C: “Cálculo Masivo Concurrente con Correcciones”</i>	<i>121</i>
9.4.4.	<i>Paralelización de predicción de la condición meteorológica.....</i>	<i>121</i>
9.5.	PRUEBAS DE ACEPTACIÓN	122

10.	BALANCE DE COSTOS FINAL	125
11.	CONCLUSIONES	127
	REFERENCIAS	130

Índice de tablas

Tabla 1:	Algoritmos que abordan el problema del TSP	7
Tabla 2:	Técnicas de penalización.....	9
Tabla 3:	Métricas de evaluación en Machine Learning.....	13
Tabla 4:	Modelos de logística existentes.....	18
Tabla 5:	Tabla descriptiva de actores	23
Tabla 6:	Caso de uso configurar parámetros del algoritmo bioinspirado.....	24
Tabla 7:	Caso de uso ejecutar optimización de ruta con restricciones meteorológicas.....	25
Tabla 8:	Caso de uso visualizar iteraciones de la optimización	26
Tabla 9:	Caso de uso realizar predicciones meteorológicas con modelo de machine learning	27
Tabla 10:	Caso de uso obtener los datos para realizar las predicciones meteorológicas.....	28
Tabla 11:	Caso de uso seleccionar puntos de interés.....	29
Tabla 12:	Caso de uso generar ruta optimizada.....	30
Tabla 13:	Caso de uso visualizar ruta.....	31
Tabla 14:	Caso de uso guardar ruta	32
Tabla 15:	Caso de uso consultar rutas guardadas.....	33
Tabla 16:	Caso de uso crear cuenta de usuario.....	34
Tabla 17:	Caso de uso iniciar sesión en el sistema.....	35
Tabla 18:	Datos originales de Weather Underground.....	43
Tabla 19:	Nuevas clases con datos agrupados.....	44
Tabla 20:	Resumen del desempeño los modelos.....	65
Tabla 21:	Rendimiento en tiempo de ejecución (2 000 000 evaluaciones).....	76
Tabla 22:	Rendimiento en distancia y estabilidad (2 000 000 evaluaciones).....	82
Tabla 23:	Recursos humanos.....	87
Tabla 24:	Recursos de hardware	88
Tabla 25:	Infraestructura	88
Tabla 26:	Costo total estimado del proyecto	88
Tabla 27:	Comparación de la disminución de riesgo	115
Tabla 28:	Comparación de los tiempos de ejecución	115
Tabla 29:	Resultados de la comparativa del modelo de predicción meteorológica en México.....	118
Tabla 30:	Resultados de la comparativa del modelo de predicción meteorológica fuera de México	120
Tabla 31:	Condiciones actuales del sistema	120
Tabla 32:	Tiempos totales de la optimización	122
Tabla 33:	Pruebas de aceptación a un planificador logístico	123
Tabla 34:	Pruebas de aceptación a un operador de tráiler	124
Tabla 35:	Recursos humanos costo final.....	125
Tabla 36:	Recursos de Hardware y Software final.....	125
Tabla 37:	Recursos de infraestructura final.....	126
Tabla 38:	Costo total final del proyecto	126

Índice de figuras

Figura 1: Ejemplo de red neuronal recurrente. Elaboración propia.	10
Figura 2: Ejemplo de red LSTM. Elaboración propia.....	11
Figura 3: Ejemplo de máquina de soporte vectorial. Elaboración propia.	11
Figura 4: Ejemplo de Árbol de Decisión. Elaboración propia.	12
Figura 5: Ejemplo de random forest. Elaboración propia.	12
Figura 6: Ejemplo de matriz de confusión. Elaboración propia.....	14
Figura 7: Distribución de valores en una matriz de confusión 4x4. Elaboración propia	14
Figura 8: Ejemplo de matriz de confusión 4x4. Elaboración propia.....	14
Figura 9: Arquitectura del sistema. Elaboración propia.....	20
Figura 10: Diagrama de casos de uso para Usuario	35
Figura 11: Diagrama de casos de uso para Administrador.....	36
Figura 12: Modelo relacional base de datos.....	36
Figura 13: Diagrama de clases del sistema	38
Figura 14: Diagrama de objetos del sistema	40
Figura 15: Ejemplo de datos en Weather Underground	41
Figura 16: Diagrama de flujo del preprocesamiento de los datos	41
Figura 17: Clases sin balancear.....	45
Figura 18: Clases después de balancear.....	45
Figura 19: Diagrama de flujo entrenamiento de los modelos	46
Figura 20: Entrevista realizada a conductores. Elaboración propia	47
Figura 21: Concentrado de datos encuesta. Elaboración propia	48
Figura 22: Diagrama de secuencia iniciar sesión.....	49
Figura 23: Diagrama de secuencia crear nueva cuenta	49
Figura 24: Diagrama de secuencia consultar rutas guardadas.....	50
Figura 25: Diagrama de secuencia guardar ruta.....	50
Figura 26: Diagrama de secuencia visualizar ruta	51
Figura 27: Diagrama de secuencia seleccionar puntos de interés	51
Figura 28: Diagrama de secuencia generación de ruta.....	52
Figura 29: Mockup pantalla principal.....	53
Figura 30: Mockup ruta generada	54
Figura 31: Mockup Nueva Cuenta	55
Figura 32: Mockup Iniciar Sesión.....	55
Figura 33: Mockup página usuario	56
Figura 34: Parámetros del entrenamiento de los modelos de Machine Learning	60
Figura 35: Pseudocódigo del modelo RNN	61
Figura 36: Pseudocódigo del modelo LSTM	61
Figura 37: Pseudocódigo del modelo SVM	62
Figura 38: Pseudocódigo del modelo Árboles de decisión	62
Figura 39: Pseudocódigo del modelo Random Forest	63
Figura 40: Matriz de confusión y métricas del modelo RNN	63
Figura 41: Matriz de confusión y métricas del modelo LSTM.....	64
Figura 42: Matriz de confusión y métricas del modelo SVM.....	64
Figura 43: Matriz de confusión y métricas del modelo Árboles de decisión.....	65
Figura 44: Matriz de confusión y métricas del modelo Random Forest	65
Figura 45: Pseudocódigo algoritmo genético.....	67
Figura 46: Pseudocódigo PSO	68
Figura 47: Pseudocódigo Recocido Simulado	69

Figura 48: Pseudocódigo Búsqueda Tabú	70
Figura 49: Parámetros de algoritmos bioinspirados	72
Figura 50: Comparación de los tiempos de ejecución de los algoritmos con 100,000 evaluaciones.	73
Figura 51: Comparación de los tiempos de ejecución de los algoritmos con 500,000 evaluaciones.	74
Figura 52: Comparación de los tiempos de ejecución de los algoritmos con 2,000,000 de evaluaciones.	75
Figura 53: Comparación de la calidad de la solución de los algoritmos con 100,000 evaluaciones.	77
Figura 54: Comparación de la calidad de la solución de los algoritmos con 500,000 evaluaciones.	78
Figura 55: Comparación de la calidad de la solución de los algoritmos con 2,000,000 de evaluaciones.	79
Figura 56: Estabilidad de los algoritmos durante el total de evaluaciones	81
Figura 57: Datos obtenidos de la API de Weather Underground	84
Figura 58: Datos obtenidos de Weather API	85
Figura 59: CSV original con los datos de las naves industriales.	90
Figura 60: CSV después del preprocesamiento.	90
Figura 61: Primeros registros del CSV utilizando la matriz de distancias por formula de Haversine	91
Figura 62: Primeros datos del CSV utilizando la matriz de distancias por carreteras	91
Figura 63: Pruebas de estrés realizadas con todas las naves industriales.....	92
Figura 64: Evolución del fitness del algoritmo bioinspirado en las pruebas de estrés.....	92
Figura 65: Descripción de la tabla Usuario.....	93
Figura 66: Descripción de la tabla Ruta.....	93
Figura 67: Vista de la ventana para seleccionar las naves industriales	94
Figura 68: Animación Lottie durante la espera de la optimización.....	94
Figura 69: Vista de la ventana para iniciar sesión en el sistema	95
Figura 70: Vista de la ventana para crear una cuenta en el sistema	96
Figura 71: Vista del mapa con el trazado de la ruta penalizada	97
Figura 72: Vista del mapa con el trazado de la ruta sin penalizar	97
Figura 73: Vista principal del administrador.	98
Figura 74: Usuarios registrados en la base de datos.	99
Figura 75: Vista de la ventana de rutas guardadas para el usuario con cuenta en el sistema	100
Figura 76: Detalles completos de la ruta del usuario.	100
Figura 77: Borrar ruta del usuario de la base de datos.	101
Figura 78: Configuración de variables de entorno en GCP para la inyección segura de credenciales.	102
Figura 79: Panel de administración en GCP mostrando el servicio de aplicaciones activo.	103
Figura 80: Panel de administración en GCP mostrando la instancia de base de datos.	103
Figura 81: Interfaz de usuario de LogistiClima desplegada en producción.	104
Figura 82: Interfaz de ruta de LogistiClima desplegada en producción.	104
Figura 83: Resultado de la solicitud de rutas con postman	106
Figura 84: Resultado en el servidor de la solicitud enviada.....	106
Figura 85: Resultado de la prueba de entrada no válida	107
Figura 86: Resultado de la prueba al mandar una entrada vacía.....	107
Figura 87: Resultado en el servidor del error de la entrada no válida.....	107
Figura 88: Resultado de crear un usuario nuevo.....	108
Figura 89: Resultado de registrar al usuario en la base de datos.....	108
Figura 90: Resultado de intentar crear otra cuenta con un correo ya registrado	109
Figura 91: Guardar la ruta después de generar el resultado	110
Figura 92: Resultado de guardar la ruta del usuario en la base de datos.....	110
Figura 93: Resultado de ver rutas guardadas para el usuario	111
Figura 94: Detalles completos de la ruta guardada para el usuario.....	111
Figura 95: Verificación de la petición a seleccionar-naves.....	112
Figura 96: JSON obtenido de la petición a seleccionar-naves	112

Figura 97: Resultado prueba de envío de cálculo de ruta y visualización de ruta	113
Figura 98: Resultado de la prueba de manejo de error.....	113
Figura 99: Mejores combinaciones de Hiperparámetros para el algoritmo de optimización.....	114
Figura 100: Clima obtenido por Google en Toluca de Lerdo, Edomex	116
Figura 101: Clima predicho por el modelo de Random Forest en Toluca de Lerdo, Edomex	116
Figura 102: Clima obtenido por Google en Tlanepantla, Edomex.....	116
Figura 103: Clima predicho por el modelo de Random Forest en Tlanepantla, Edomex	116
Figura 104: Clima obtenido por Google en Chalco, Edomex.....	117
Figura 105: Clima predicho por el modelo de Random Forest en Chalco, Edomex.....	117
Figura 106: Clima obtenido por Google en Ecatepec de Morelos, Edomex	117
Figura 107: Clima predicho por el modelo de Random Forest en Ecatepec de Morelos, Edomex.....	117
Figura 108: Clima obtenido por Google en Lindavista Norte, CDMX.....	117
Figura 109: Clima predicho por el modelo de Random Forest en Lindavista Norte, CDMX	118
Figura 110: Clima obtenido por Google en Vichadero, Uruguay	119
Figura 111: Clima predicho por el modelo de Random Forest en Vichadero, Uruguay	119
Figura 112: Clima obtenido por Google en Librazhd, Albania.....	119
Figura 113: Clima predicho por el modelo de Random Forest en Librazhd, Albania.....	119
Figura 114: Clima obtenido por Google en University Place, EE.UU.....	120
Figura 115: Clima predicho por el modelo de Random Forest en University Place, EE.UU.	120

1. Introducción

En la actualidad, la optimización de rutas de transporte es un factor clave para el éxito en la distribución eficiente de productos, especialmente en un país con una vasta red de carreteras como México. La logística cumple un rol fundamental en el desarrollo del país y en el acceso a nuevas inversiones en infraestructura [1]. Sin embargo, la actual transformación digital plantea un desafío para este sector, ya que obliga al mercado a mejorar su visibilidad, eficiencia y precisión, además de optimizar y agilizar los procesos manuales [2].

Durante la temporada de lluvias intensas, la infraestructura de carreteras y vías de comunicación en el Estado de México se ve afectada severamente, lo que obliga a grandes empresas que almacenan y distribuyen sus productos en la entidad a adaptar sus estrategias logísticas. Cabe destacar que el Estado de México es una de las entidades más industrializadas del país, ya que aporta 16.2 % de la industrialización nacional y concentra el 12.1 % del personal ocupado a nivel nacional, lo que lo convierte en el estado con mayor contribución en este sector [3]. Estas características económicas y laborales hacen más clara la necesidad de adaptar las operaciones ante situaciones climáticas adversas.

La temporada de lluvias suele ser la más complicada para el sector productivo, en particular en el año 2024 se ha tenido mayor afectación por las lluvias intensas que se han registrado [4]. Con las inundaciones y caídas de árboles a causa de las lluvias, los accidentes se incrementan en un 8% en comparación al resto del año, ocasionando que los automovilistas tengan contratiempos durante el recorrido de sus trayectorias debido a las inundaciones [5].

En el campo de la meteorología predictiva, se han desarrollado diversas herramientas basadas en modelos de Inteligencia Artificial, como técnicas de Machine Learning y redes neuronales. Estas herramientas aprovechan una cantidad significativa de observaciones atmosféricas y terrestres para generar interpretaciones automáticas, no solo en predicciones meteorológicas y de calidad del aire, sino también en proyecciones climáticas basadas en modelos numéricos. Sin embargo, muchos de estos desarrollos están en manos de entidades privadas, a pesar de utilizar fuentes de datos financiadas con fondos públicos. Esta situación ha generado preocupación entre las agencias nacionales e internacionales encargadas de proporcionar información ambiental y emitir alertas a la sociedad [6].

Adicionalmente, se han desarrollado diversos softwares dedicados a la optimización de rutas en la logística, utilizados por empresas para mejorar la eficiencia en la distribución de mercancías. No obstante, estas soluciones tecnológicas presentan limitaciones cuando tratan de adaptarse a las particularidades de la red de carreteras de la República Mexicana y a la consideración de las condiciones climáticas, lo que subraya la necesidad de integrar predicciones precisas del clima en la planificación logística para una mayor efectividad.

En este contexto, los algoritmos bioinspirados se han considerado como una alternativa en la optimización de rutas. Estos algoritmos, inspirados en los procesos adaptativos de la naturaleza, imitan mecanismos de

evolución y adaptación para explorar de forma global el espacio de soluciones. Al trabajar con poblaciones de soluciones son capaces de evitar quedarse atrapados en óptimos locales. Esta capacidad de equilibrar la exploración y la explotación resulta especialmente destacable para abordar problemas complejos de optimización en logística y transporte.

1.1. Objetivos

1.1.1. Objetivo general

Diseñar y desarrollar un prototipo de sistema que optimice las rutas de transporte de carga terrestre en el Estado de México, minimizando la distancia total recorrida. Este sistema utilizará la red de carreteras como base e integrará predicciones meteorológicas sobre precipitaciones pluviales, integrando modelos de Machine Learning que se encargarán de hacer las predicciones meteorológicas y algoritmos bioinspirados para realizar la optimización de las rutas. Los resultados serán desplegados a través de una interfaz web.

1.1.2. Objetivos específicos

1. Análisis y delimitación de las problemáticas asociadas a las condiciones climatológicas para las empresas de logística.
2. Análisis del estado del arte para algoritmos bioinspirados y algoritmos de machine learning.
3. Seleccionar e implementar algoritmos bioinspirados para la optimización de rutas restringido a predicciones meteorológicas pluviales y las distancias asociadas al recorrido.
4. Seleccionar e implementar un modelo de Machine Learning predictivo que analice los datos meteorológicos históricos.
5. Integrar el modelo de Machine Learning y algoritmos bioinspirados en una interfaz web que despliegue los resultados del sistema a los usuarios finales.
6. Generar documentación técnica que evidencie el funcionamiento alcanzado a partir de la implementación y validación del sistema.

1.2. Justificación

El aumento de las temperaturas, el deshielo de los glaciares y la subida del nivel del mar provocan daños en las infraestructuras y retrasos operativos. La diversificación de los modos y rutas de transporte, junto con el análisis predictivo, ayudan a minimizar los retrasos y a adaptarse a las condiciones cambiantes [5]. Sin embargo, para que esta diversificación sea eficaz, es necesario contar con sistemas que permitan un análisis predictivo preciso. La integración de datos meteorológicos con la optimización de rutas puede ofrecer soluciones que puedan contribuir al aumento de la seguridad operativa. Las empresas que logran implementar estas tecnologías tienen la oportunidad de anticiparse a los problemas, seleccionando rutas más seguras; lo que se traduce en una alternativa en un sector cada vez más desafiante.

En el caso específico del Estado de México, es una de las entidades con mayor industrialización y con una ubicación geográfica estratégica lo cual lo convierte en un foco importante para el almacenamiento y la distribución de mercancías hacia otras regiones; por ello durante la temporada de lluvias, su infraestructura vial suele verse afectada, lo que desencadena en retrasos operativos y aumento en costos logísticos.

El proyecto propuesto surge precisamente de esta necesidad de herramientas tecnológicas que permitan a las empresas tomar decisiones logísticas informadas. Esto se logrará mediante la generación de rutas, a través de algoritmos genéticos y de modelos de Machine Learning, que eviten áreas afectadas por condiciones climáticas pluviales en zonas de interés del usuario, lo que ofrecerá una alternativa en el sector, mejorando la fiabilidad de las operaciones de transporte. Por otra parte, la implementación de un sistema de este tipo, al evitar contratiempos ocasionados por lluvias, contribuye con un impacto positivo al buscar la protección de las personas involucradas en el transporte y de los bienes transportados.

2. Marco referencial

2.1. Inteligencia Artificial

La inteligencia artificial (IA) es una rama de la ciencia computacional que busca diseñar sistemas capaces de realizar tareas que, en humanos, requieren habilidades cognitivas como el razonamiento, el aprendizaje, la percepción y la toma de decisiones autónomas. Estos sistemas operan mediante algoritmos y modelos que procesan información, adaptan su comportamiento a partir de datos o experiencias previas, y optimizan su desempeño para alcanzar objetivos específicos. Su esencia radica en emular la capacidad humana de resolver problemas complejos, ya sea mediante lógica formal, análisis estadístico o mecanismos de inferencia [7].

2.1.1. Algoritmos bioinspirados

La literatura en optimización recoge diversas técnicas determinísticas y heurísticas para abordar una amplia gama de problemas, teniendo en cuenta las características y restricciones particulares de cada caso. En este contexto, los algoritmos metaheurísticos (pertenecientes a la familia de algoritmos aproximados) integran operaciones estocásticas al incorporar elementos aleatorios en el proceso de búsqueda. Este enfoque les permite explorar el espacio de soluciones de manera no determinística y evitar quedar atrapados en óptimos locales, lo que los clasifica como algoritmos de búsqueda global.

Dentro de este marco, los algoritmos bioinspirados destacan por imitar procesos adaptativos de la naturaleza y basarse en la supervivencia del mejor individuo, siendo un individuo una solución potencial del problema que se implementa como una estructura de datos [8]. Trabajan sobre poblaciones de soluciones que evolucionan de generación en generación mediante operadores genéticos adaptados al problema, lo que se ejemplifica en técnicas como los algoritmos genéticos, algoritmos de cúmulo de partículas y algoritmos de colonia de hormigas [9].

2.1.1.1. El Problema del Vendedor Viajero (TSP)

Uno de los problemas de enrutamiento más estudiados en investigación operativa es el Problema del Vendedor Viajero (TSP). Este se define como la búsqueda del recorrido óptimo que permita visitar cada ciudad exactamente una vez y regresar al punto de partida, minimizando el costo total del trayecto; a cada trayecto entre dos ciudades se le asocia un costo [10].

La complejidad del TSP es tal que, al ser un problema NP-hard, encontrar la solución óptima resulta difícil incluso para instancias de tamaño moderado [11]. Por ello, se han desarrollado métodos alternativos capaces de generar soluciones eficientes en tiempos computacionalmente razonables.

2.1.1.2. Métodos metaheurísticos para abordar el TSP

Algoritmo	Descripción	Pseudocódigo	Ventajas y desventajas
Algoritmos Genéticos (GA) [12]	Optimiza soluciones mediante selección natural: genera una población de rutas, las combina (cruce) y modifica (mutación) iterativamente.	1. Inicializar población aleatoria 2. Para cada generación: a. Evaluar fitness (distancia + penalización) b. Seleccionar padres c. Cruzar y mutar d. Reemplazar población 3. Devolver mejor ruta	Ventajas: - Capacidad para explorar amplios espacios de soluciones. - Evita mínimos locales gracias a la diversidad poblacional - Tienen la capacidad de ser paralelizables. Desventajas: - Alto costo computacional. - Riesgo de convergencia lenta o prematura si los parámetros (mutación, cruce) no se ajustan correctamente.
Colonia de Hormigas (ACO) [12]	Simula hormigas que depositan feromonas en tramos óptimos, guiando a otras a seguir rutas cortas y evitar tramos penalizados por clima.	1. Inicializar feromonas en tramos 2. Para cada iteración: a. Hormigas construyen rutas (probabilidad basada en feromonas) b. Actualizar feromonas (evaporación + refuerzo en mejores rutas) 3. Devolver ruta con más feromonas	Ventajas: - Adecuado para problemas de optimización en grafos y rutas. - Puede encontrar múltiples soluciones de buena calidad simultáneamente. Desventajas: - Sensible a la configuración de parámetros (coeficientes

			de evaporación y refuerzo de feromonas). - Puede requerir muchas iteraciones para converger.
Enjambre de Partículas (PSO) [13]	Cada partícula (ruta) ajusta su posición en el espacio de soluciones según su mejor experiencia individual y la del enjambre (colectiva).	1. Inicializar partículas con posición y velocidad aleatoria 2. Para cada iteración: a. Calcular costo (distancia + penalización) b. Actualizar mejor local y global c. Ajustar velocidad y posición 3. Devolver mejor posición	Ventajas: - Algoritmo de bajo costo computacional. - Convergencia rápida en espacios continuos. Desventajas: - Sensible a la selección de parámetros (inercia, factores sociales).
Recocido Simulado (SA) [12]	Acepta soluciones temporalmente peores con una probabilidad decreciente, evitando quedar atrapado en mínimos locales durante la exploración.	1. Inicializar solución actual y temperatura alta 2. Mientras temperatura > límite: a. Generar vecino aleatorio b. Si vecino es mejor: aceptar c. Si no: aceptar con probabilidad $P(\Delta \text{costo}, \text{temperatura})$ d. Reducir temperatura 3. Devolver mejor solución	Ventajas: - Algoritmo con un concepto sencillo de entender y de implementar. - Capacidad para escapar de óptimos locales al aceptar soluciones peores con cierta probabilidad. - Requiere menos memoria que métodos poblacionales. Desventajas: - Ritmo de enfriamiento crítico: demasiado rápido (atrapamiento) o lento (ineficiencia).

Búsqueda Tabú (TS) [12]	Utiliza una lista de movimientos prohibidos (tabú) para evitar ciclos y explorar nuevas regiones del espacio de soluciones de manera eficiente.	1. Inicializar solución actual y lista tabú vacía 2. Para cada iteración: a. Generar vecinos no tabúes b. Seleccionar mejor vecino c. Actualizar lista tabú (movimientos recientes) 3. Devolver mejor solución encontrada	Ventajas: - Evita ciclos mediante memoria a corto plazo. Desventajas: - Complejidad en la gestión de la lista tabú (tamaño y criterios). - Potencialmente costoso en términos computacionales para problemas de gran escala.
----------------------------	---	--	--

Tabla 1: Algoritmos que abordan el problema del TSP

Además de estos enfoques tradicionales, en los últimos años han surgido nuevas metaheurísticas bioinspiradas que amplían el repertorio de soluciones para el TSP:

- Algoritmo del Murciélago (BA): Se basa en la ecolocalización de los murciélagos, adaptando sus parámetros para explorar eficazmente el espacio de búsqueda [13][14].
- Algoritmo de las Luciérnagas (FA): Emula la atracción entre luciérnagas, donde cada individuo se desplaza hacia aquellos que emiten destellos más intensos (mejores soluciones) [14][15].
- Algoritmo del Cuco (CS): Inspirado en el comportamiento parasitario de algunas especies de cucos, utiliza patrones de búsqueda específicos para explorar el espacio de soluciones de forma eficiente TSP [15][16].

2.1.1.3. Modelado de la Función Objetivo en Optimización

La función objetivo es el elemento central de cualquier problema de optimización, ya que cuantifica la medida de calidad o costo de una solución propuesta. En problemas clásicos como el TSP (Problema del Vendedor Viajero), la función objetivo se modela normalmente como la suma total de las distancias recorridas o el costo asociado de pasar por cada tramo de la ruta. Esta formulación se basa en una evaluación directa de la variable que se desea minimizar (o maximizar), sin considerar en un principio restricciones adicionales, lo que permite que la búsqueda se enfoque únicamente en el rendimiento de la solución en términos de distancia, tiempo o costo. [17]

2.1.1.4. Integración de restricciones en la función objetivo

En la práctica, muchos problemas de optimización presentan restricciones adicionales (por ejemplo, restricciones operativas, de capacidad o ambientales) que deben ser cumplidas para que la solución sea viable. Para integrar estas restricciones en la función objetivo, se extiende el modelo original añadiendo un término penalizador. Este término incrementa el valor de la función objetivo en función del grado de violación de las restricciones, de tal manera que las soluciones que infringen alguna limitación resulten en una evaluación global menos favorable. [18]

De manera general, la función objetivo con restricciones se puede expresar como:

$$Fp(x) = f(x) \pm Q(x)$$

$$Q(x) = \lambda \times P(x)$$

donde:

- $f(x)$ es la función objetivo original (por ejemplo, la distancia total del recorrido).
- $Fp(x)$ es la nueva función penalizada
- $Q(x)$ es el término de penalización.

El término $Q(X)$ es fundamental para ajustar el modelo de optimización y se compone de dos elementos clave: por un lado, el factor de escala (λ), definido por el usuario, que actúa como un multiplicador determinando la importancia o peso relativo de las penalizaciones en relación con la medida original de la solución; este factor permite ajustar la severidad de la penalización, es decir, cuánto se incrementará el valor de la función de aptitud cuando se violen restricciones. Por otro lado, la medida de penalización $P(x)$ cuantifica la magnitud de la violación de las restricciones.

2.1.1.5. Técnicas para manejo de restricciones

En la Tabla 2 se muestran las principales técnicas de penalización¹ y métodos utilizados para integrar restricciones en la función de aptitud de algoritmos evolutivos. Cada técnica aborda de manera distinta cómo penalizar a las soluciones infactibles [19]:

Técnica	Descripción
Pena de Muerte	Asigna una aptitud de cero a cualquier individuo que no cumpla las restricciones, descartando por completo las soluciones infactibles.
Penalizaciones Estáticas	Se definen niveles fijos de penalización en función del número de restricciones violadas, utilizando coeficientes predefinidos para cada nivel.
Penalizaciones Dinámicas	Ajusta los coeficientes de penalización a lo largo de las generaciones, incrementando la presión conforme avanza la búsqueda y la posibilidad de violaciones.
Penalizaciones Adaptativas	Ajusta la penalización en función de un proceso de retroalimentación: si el mejor individuo reciente es factible, se reduce la penalización; si no, se aumenta.
Algoritmo Genético Segregado	Emplea dos funciones de penalización utilizando poblaciones separadas para evaluar soluciones, combinando aquellas que presentan penalizaciones moderadas con otras más fuertes.
Penalización Basada en la Factibilidad	Evalúa a los individuos según la factibilidad: si la solución es factible se evalúa normalmente, y si no, se le asigna un valor basado en la peor solución factible de la población.

Tabla 2: Técnicas de penalización

2.1.2. Machine Learning

El aprendizaje máquina (comúnmente conocido como Machine Learning) es una disciplina del campo de la Inteligencia Artificial que, a través de algoritmos, dota a los ordenadores de la capacidad de identificar patrones en datos masivos y elaborar predicciones (análisis predictivo). Este aprendizaje permite a los computadores realizar tareas específicas de forma autónoma, es decir, sin necesidad de ser programados [16][17].

La predicción de precipitaciones ha adquirido gran relevancia en los últimos tiempos debido a su complejidad y a sus aplicaciones persistentes, como la predicción de inundaciones y la monitorización de la concentración de contaminantes, entre otras [17][18]. Los modelos existentes utilizan modelos estadísticos complejos que suelen ser demasiado costosos, tanto computacional como presupuestariamente, o bien no se aplican a aplicaciones posteriores. Por lo tanto, se están explorando enfoques que emplean algoritmos de aprendizaje automático junto con datos de series temporales como alternativa para superar estas desventajas [17][18].

2.1.2.1. Tipos de algoritmos de Machine Learning

- Aprendizaje supervisado: estos algoritmos cuentan con un aprendizaje previo basado en un sistema de etiquetas asociadas a unos datos que les permiten tomar decisiones o hacer predicciones.
- Aprendizaje no supervisado: estos algoritmos no cuentan con un conocimiento previo. Se enfrentan al caos de datos con el objetivo de encontrar patrones que permitan organizarlos de alguna manera.
- Aprendizaje por refuerzo: su objetivo es que un algoritmo aprenda a partir de la propia experiencia, lo que lo hace capaz de tomar la mejor decisión ante diferentes situaciones de acuerdo con un proceso de prueba y error en el que se recompensan las decisiones correctas [22].

2.1.2.2. Aplicaciones del Machine Learning

- Recomendaciones: permite hacer sugerencias personalizadas de compra en plataformas online o recomendar canciones.
- Vehículos inteligentes: los vehículos pueden ajustar la configuración interna de acuerdo con las preferencias del conductor e, incluso, mover el volante solos para reaccionar al entorno.
- Procesamiento de Lenguaje Natural: a través de la comprensión del lenguaje humano.
- Medicina: para la detección del cáncer de mama, algo de vital importancia ya que su detección temprana aumenta las probabilidades de curación.

2.1.2.3. Modelos utilizados en predicción meteorológica

Existen diversos modelos de machine learning que permiten procesar grandes volúmenes de datos para poder realizar la clasificación de nuevos datos de entrada. A continuación, se presentan algunos modelos que se utilizan usualmente para la predicción de condiciones meteorológicas.

- Redes neuronales recurrentes (RNN por sus siglas en inglés): es una red neuronal entrenada con datos secuenciales o series temporales para crear un modelo de machine learning que pueda hacer predicciones [18][19].




Figura 1: Ejemplo de red neuronal recurrente. Elaboración propia.

- Red de memoria a corto-largo plazo (LSTM por sus siglas en inglés): son una forma especializada de la arquitectura de RNN, dan solución al problema de gradiente evanescente. Este trabajo abordó el problema de las dependencias a largo plazo. Es decir, si el estado anterior que influye en la predicción actual no está en el pasado reciente, el modelo RNN podría no ser capaz de predecir con precisión el estado actual [24].




Figura 2: Ejemplo de red LSTM. Elaboración propia.

- Máquinas de soporte vectorial (SVM por sus siglas en inglés): es un algoritmo de aprendizaje automático supervisado que clasifica los datos al encontrar una línea o hiperplano óptimo que maximice la distancia entre cada clase en un espacio N-dimensional [19][20].




Figura 3: Ejemplo de máquina de soporte vectorial. Elaboración propia.

- Árboles de Decisión: es un algoritmo de aprendizaje supervisado, que se utiliza tanto para tareas de clasificación como de regresión. Tiene una estructura jerárquica, de árbol, que consta de un nodo raíz, ramas, nodos internos y nodos de hoja, se basa en dividir el conjunto de datos en subconjuntos que garantices una separación óptima [26].




Figura 4: Ejemplo de Árbol de Decisión. Elaboración propia.

- Random Forest: es un algoritmo de aprendizaje automático supervisado que se usa para solucionar problemas de clasificación y regresión. Construye árboles de decisión a partir de diferentes muestras y toma su voto mayoritario para decidir la clasificación y el promedio en caso de regresión [20][21].




Figura 5: Ejemplo de random forest. Elaboración propia.

2.1.2.4. Métricas de evaluación de modelos de Machine Learning

En esta sección se describen las métricas utilizadas para evaluar los modelos de Machine Learning. Estas métricas permiten medir el desempeño de los modelos, demostrando si las predicciones se realizan de manera correcta en relación con los valores reales [28].

Las métricas se calculan a partir de los cuatro posibles resultados que puede tomar una predicción, con base en el valor predicho por el modelo y el valor real que se espera:

- Verdadero Positivo (TP): Dato predicho como Verdadero con valor real Verdadero
- Verdadero Negativo (TN): Dato predicho como Falso y valor real Falso
- Falso Positivo (FP): Dato predicho como Verdadero y valor real Falso
- Falso Negativo (FN): Dato predicho como Falso y valor real Verdadero

Estos valores sirven como variables para realizar el cálculo de las distintas métricas que permiten evaluar el comportamiento y precisión del modelo. En la Tabla 3 se listan las principales métricas utilizadas para evaluar los modelos de Machine Learning.

Nombre	Descripción	Formula
Exactitud (Accuracy)	Se encarga de medir el porcentaje de predicciones correctamente clasificadas, mide el desempeño general del modelo.	$\text{Accuracy} = \frac{TP + TN}{(TP + FP + TN + FN)}$
Precisión (Precision)	Calcula el porcentaje de predicciones que fueron correctamente clasificados entre todas las instancias predichas como correctas.	$\text{Precision} = \frac{TP}{TP + FP}$
Sensibilidad (Recall)	Mide el porcentaje de datos que fueron predichos como correcto sobre el total de datos positivos reales.	$\text{Recall} = \frac{TP}{TP + FN}$
F1-score	Es la media armónica entre Precision y Recall, equilibra tanto la Precision como Recall.	$F1 = \frac{2 * \text{Precision} * \text{Recall}}{\text{Precision} + \text{Recall}}$

Tabla 3: Métricas de evaluación en Machine Learning

La matriz de confusión es una herramienta visual que permite comprobar de desempeño del modelo de Machine Learning, cada columna representa el número de predicciones de cada clase y las filas representan las instancias de la clase real. Los valores en la diagonal principal indican las predicciones que concuerdan con el dato real con el predicho, mientras que los valores fuera de la diagonal son los errores predichos. En la Figura 6 se muestra un ejemplo de una matriz de confusión binaria, correspondiente a un modelo que clasifica entre dos clases.

Clase Predicha			
Clase Original		Avión	Carro
		Avión	Carro
	Avión	75	12
	Carro	25	68

Figura 6: Ejemplo de matriz de confusión. Elaboración propia

Cuando los problemas de clasificación son multiclase (más de dos clases), la matriz de confusión se extiende a un formato de $n \times n$, siendo n el número de clases que se deben de clasificar. En este caso la diagonal principal sigue representando las predicciones correctamente clasificadas. Al analizar una clase en específico, se pueden identificar los cuatro posibles resultados de la clasificación: el valor de la diagonal corresponde al TP, la suma de los valores de la misma columna excepto la diagonal son los FP, los FN se obtienen sumando los valores de la fila sin la diagonal, y los TN es la suma de los valores que no pertenecen ni a la fila ni a la columna. En la Figura 7 y Figura 8 se muestra en ejemplo de una matriz de confusión con cuatro clases analizando la clase 1.

		Clase Predicha			
Clase Original	TP	FN	FN	FN	
	FP	TN	TN	TN	
	FP	TN	TN	TN	
	FP	TN	TN	TN	

Figura 7: Distribución de valores en una matriz de confusión 4x4. Elaboración propia

Clase Analizar	1				
TP	750	Avión	Carro	Tren	Barco
FP	65	750	12	29	25
FN	66	25	686	103	17
TN	2948	32	33	932	33
		8	48	135	961

Figura 8: Ejemplo de matriz de confusión 4x4. Elaboración propia

2.1.2.5. Características y fuentes de datos en predicción meteorológica

Para la selección de los parámetros a utilizar en los modelos de machine learning se deben elegir características que sean lo suficientemente discriminativas para lograr una distinción de las diferentes clases que se desean identificar. Los datos enfocados al ámbito de predicción del clima se obtienen de estaciones meteorológicas que están ubicadas en distintos puntos de las ciudades para obtener información climatológica de ese lugar. Los datos utilizados frecuentemente para las predicciones meteorológicas son [17][21][18][22]:

- Temperatura: Es la cantidad de calor acumulado en el aire. Se puede medir en grados centígrados (°C) o Fahrenheit (°F) según el sistema de medida utilizado.
- Presión atmosférica: es la fuerza que ejerce el aire sobre una superficie. Es causada por el peso de la columna de aire que se encuentra sobre un punto determinado. Se mide en hectopascales (hPa) o milibares (mbar).
- Humedad: Cantidad de vapor de agua presente en la atmósfera, esta cantidad de vapor puede depender de la temperatura del aire. Se mide en porcentajes de humedad relativa (%HR) o en gramos por metro cúbico (g/m³) de humedad absoluta.
- Velocidad del viento: Mide la componente horizontal del desplazamiento del aire en un punto y en un instante determinados. Se mide en metros por segundo (m/s).

2.2. Meteorología

La meteorología es la ciencia que se encarga del estudio de la atmósfera, los fenómenos que ocurren en ella y su influencia en el clima. Este último se define a partir de las características que una serie de variables físicas como la temperatura, la humedad, la presión o el viento presentan sobre un lugar determinado. La meteorología, estudia las leyes que gobiernan el funcionamiento del sistema climático y la climatología, estudia la localización y distribución espacial de las variables del clima y su relación con la vegetación, los cultivos o el hombre [30].

El clima tiene un impacto directo en los ecosistemas y en la vida humana, pues actividades esenciales como la producción de alimentos o la distribución de bienes están fuertemente condicionados por las condiciones climáticas. Además, el clima es uno de los elementos más difíciles de controlar por el ser humano, lo que provoca que la única acción posible para hacerle frente sea la prevención y adaptación para evitar los efectos negativos del mismo [30]. Estudiar y comprender el clima requiere tener claras cuatro ideas esenciales: la diferencia entre tiempo y clima, los factores que lo condicionan, sus elementos y las escalas que lo delimitan.

El tiempo es la situación meteorológica que se observa sobre un lugar en un momento determinado y varía con frecuencia. Por otro lado, el clima es un estado medio que se define por unos valores estadísticos deducidos de series largas. La Organización Mundial de Meteorología (OMM) define treinta años como el periodo que

toma de referencia para definir los climas y a este intervalo temporal se le denomina “periodo internacional”. A diferencia del tiempo, el clima sigue unos ritmos estacionales que se suceden con bastante regularidad y es el clima el que explica algunos de los rasgos geográficos más característicos de una zona [30].

2.2.1. El agua en la atmósfera

El agua se presenta en la atmósfera bajo los tres estados: sólido, líquido y gaseoso, formando respectivamente, cristales de hielo, gotas de agua y vapor de agua. Para la realización del presente trabajo, es de interés saber más acerca de la presencia del agua en la atmósfera en forma de precipitaciones, información que se obtuvo de [31]; se llama precipitación a la caída del agua de las nubes, sea en estado líquido o en estado sólido.

2.2.1.1. Tipos de precipitación

- Lluvia: Es una precipitación líquida formada por gotas grandes que caen de modo uniforme y es producida por nubes bajas, espesas y de desarrollo horizontal.
- Llovizna: Procede de nubes densas y muy bajas, está formada por gotas muy pequeñas y numerosas que caen pausadamente.
- Chubasco: Tipo de precipitación formada por gotas muy gruesas, que empieza y termina de una manera brusca, y varía drásticamente su intensidad a lo largo de la precipitación.
- Nieve: Es una precipitación formada por la agrupación de cristales de hielo en forma de copo, que caen lentamente. Cabe recalcar, que las nubes que producen la nieve son las mismas que producen la lluvia y lo que las diferencia es la temperatura del aire, la nevada se produce cuando la temperatura de la nube es inferior a los cero grados Celsius.
- Lluvia helada: Precipitación de agua, con la particularidad que las gotas de lluvia se hielan al ponerse en contacto con el suelo.
- Granizo: Es una precipitación de agua helada que se produce en las nubes de tormenta, y cuando el granizo es de gran tamaño se le denomina pedrisco.

2.2.1.2. Medida de la precipitación

La precipitación caída en el suelo se mide con un pluviómetro el cual es un recipiente de forma cilíndrica abierto por la parte superior y la medición se expresa en forma de milímetros de lluvia caída en 24 horas; la medida también se puede expresar en forma de litros de agua caída por metro cuadrado de superficie horizontal, un milímetro de altura equivale a un litro por metro cuadrado de superficie. Por otra parte, cuando la precipitación cae en forma de nieve o granizo se mide el agua que proviene de su derretimiento y generalmente, 10 milímetros de nieve equivalen a un mililitro de agua [32].

2.2.2. Accidentes viales y precipitaciones

Durante las lluvias las condiciones de las vialidades y caminos se ven severamente afectadas y los accidentes viales se vuelven más frecuentes. Según estudios del Centro de Experimentación y Seguridad Vial México (CESVI) estima que en época de lluvias los accidentes viales pueden incrementar entre 15 y 20%, y el 7% de los factores que contribuyen a la ocurrencia de un siniestro corresponde a un agente natural, ya sea lluvia, nieve o granizo, niebla, vientos fuertes entre otros pero la lluvia es el que mayor ocurrencia tiene, durante ese año, hubo 852 accidentes y debido a conducir sobre un camino mojado o resbaloso en el 2020 hubo 1,817 siniestros en vías federales [33].

2.3. Estado del Arte

2.3.1. Modelos de logística

Cuando se habla de logística hacemos referencia al transporte y almacenaje de mercancías. Por tanto, son todas las operaciones realizan para que un producto salga de donde se obtienen las materias primas, pase por el lugar de producción y llegue al consumidor final [34] .

La logística desempeña varias funciones cruciales en el éxito de una empresa. Algunas de las funciones principales incluyen [35]:

- Gestión de inventarios: Controla y supervisa el flujo de productos, asegurando que haya suficientes existencias para satisfacer la demanda de los clientes.
- Transporte y distribución: Organiza y coordina el movimiento de mercancías desde el origen hasta el destino. Selecciona los medios de transporte adecuados, planifica rutas eficientes y asegura la entrega oportuna de productos.
- Almacenamiento y manejo de materiales: Gestiona los espacios de almacenamiento y la organización de productos dentro del almacén.

En el ámbito de la logística, la optimización de rutas se ha convertido en un factor importante para mejorar la eficiencia operativa, reducir costos y minimizar el impacto ambiental. Diversas empresas líderes en el campo han desarrollado soluciones de software especializadas que ofrecen funcionalidades clave para abordar estos desafíos. Entre las herramientas más destacadas se encuentra Routal, GreenPlan y Rout4Me, cada una con características especiales que las hacen un referente en el mercado.

Software	Características Clave	Algoritmos utilizados
Routal [22][23]	Optimización de rutas en tiempo real, planificación con recogidas y entregas, simulación de tráfico.	Algoritmos heurísticos avanzados.
EPG (Greenplan) [23][24]	Planificación dinámica de rutas, cumplimiento de regulaciones, reducción de CO ₂ , monitoreo en tiempo real.	Algoritmos de optimización y simulación de CO ₂ .
Route4Me [24][25]	Software industrial de optimización y planificación de rutas, integración con múltiples plataformas.	Algoritmos heurísticos y genéticos, lo que le permite manejar una amplia variedad de restricciones, como ventanas de tiempo, capacidades de vehículos y preferencias de los clientes.

Tabla 4: Modelos de logística existentes

De los modelos presentados en la Tabla 4, el modelo de Rout4Me muestra una base sólida y un referente en la implementación de algoritmos similares a los propuestos en la solución de este documento. Sin embargo, el presente trabajo busca ampliar esta funcionalidad al incorporar la consideración de las condiciones climáticas pluviales, con el objetivo de prever contratiempos derivados de estos fenómenos.

2.3.2. Predicción del clima con machine learning

Para entender el impacto y aplicaciones de los modelos de machine learning en las predicciones meteorológicas, a continuación, se presentan algunos artículos en donde se utilizan estas técnicas para hacer la predicción de diferentes variables climatológicas, así como sus resultados obtenidos para los modelos implementados.

- Aprendizaje máquina aplicado a la predicción meteorológica: (Machine Learning Applied to Weather Forecasting): En este artículo se utiliza un modelo de regresión lineal y una variante de regresión funcional para pronosticar temperaturas en un periodo de siete días. Ambos modelos fueron superados por los servicios profesionales de pronóstico del tiempo, sin embargo, la discrepancia entre los modelos de ML y los servicios profesionales disminuyó a medida que se pronosticaban días más

lejanos, lo que sugiere que, para períodos más largos, los modelos de ML podrían ser competitivos [30][31].

- Predicción del clima usando el modelo de aprendizaje máquina Random Forest: (Weather prediction using Random Forest machine learning model): En este artículo se utiliza un modelo de Random Forest para la predicción de la radiación solar y velocidad del viento en una ciudad de la India. El modelo demostró un rendimiento alto en las predicciones comparado con modelos de regresión lineal [21][22].
- Aprendizaje Máquina con aplicaciones predicción de lluvia (Machine Learning with Applications Rainfall prediction): En este artículo se centra en la comparación de diferentes arquitecturas de redes neuronales y modelos de machine learning. Los modelos basados en LSTM implementados demostraron ser efectivos para la predicción de lluvias, especialmente cuando se utilizan con un número moderado de capas ocultas [17][18].

3. Propuesta a desarrollar

Se propone un software que implemente un algoritmo capaz de generar rutas que tome en cuenta las predicciones meteorológicas pluviales, basándose en datos históricos obtenidos a través de APIs como Weather Underground o Metheored. Estos datos se integrarán en un modelo de Machine Learning, cuyos resultados se utilizarán como parámetros de restricción para un algoritmo bioinspirado encargado de la generación de rutas. El prototipo incluirá además una interfaz web que permitirá al usuario visualizar la ruta optimizada en un mapa, considerando las condiciones meteorológicas de los puntos de la ruta que el usuario haya seleccionado visitar.




Figura 9: Arquitectura del sistema. Elaboración propia.

Para la metodología del proyecto, se ha decidido emplear un enfoque basado en prototipos. Este enfoque se adapta perfectamente a la naturaleza iterativa del proyecto, permitiendo la creación y evaluación continua de entregables que serán ajustados en función de los resultados obtenidos en cada ciclo de desarrollo. **Fases del Proyecto:**

1. Planificación y Recolección de Requisitos

En esta primera fase, se definirán los requisitos del sistema de optimización de rutas. Se identificarán variables clave, como las coordenadas de los lugares, tipos de clima en zonas geográficas e investigar riesgos y desastres asociados a cambios meteorológicos.

2. Selección de Algoritmos

Para abordar el problema de optimización de rutas, se propone el uso de algoritmos metaheurísticos, como algoritmos genéticos o de búsqueda. Conjuntando técnicas de inteligencia artificial enfocadas en Machine Learning y Redes neuronales para la predicción de condiciones climáticas. Esto permitirá optimizar la selección de rutas, considerando factores externos que puedan afectar la seguridad de los trayectos. Se investigarán y evaluarán las distintas opciones de algoritmos. Una vez desarrollados los algoritmos, se aplicarán técnicas de optimización multiobjetivo para encontrar un conjunto de soluciones que representen un equilibrio entre los diferentes objetivos, utilizando estrategias como el método de Pareto para identificar soluciones no dominadas en el espacio de búsqueda.

3. Desarrollo del Primer Prototipo

Se desarrollará un prototipo básico que incorporará las funcionalidades esenciales para calcular las rutas más eficientes. Este prototipo inicial será sometido a pruebas de funcionamiento y rendimiento para obtener retroalimentación, incluyendo la verificación de su capacidad para generar rutas eficientes y ajustar los resultados según los datos ingresados. Esta retroalimentación permitirá realizar ajustes antes de avanzar hacia la siguiente versión del sistema.

4. Evaluación y Validación del Prototipo

La retroalimentación obtenida se utilizará para validar los objetivos planteados. Se evaluará la usabilidad del sistema, donde se medirán la facilidad de navegación, la comprensión de la interfaz y el rendimiento general del sistema mediante la evaluación de tiempos de respuesta en el cálculo de rutas.

5. Refinamiento del Prototipo

En esta fase, se incorporarán las mejoras sugeridas en la evaluación. Se añadirá la capacidad de ajustar rutas de manera dinámica y se perfeccionará la interacción con el usuario, mejorando la interfaz gráfica.

6. Implementación Avanzada y Pruebas

Después de mejorar el prototipo, se procederá a una implementación más avanzada del sistema, enfocada en optimizar su rendimiento y ampliar sus capacidades. Se llevarán a cabo más pruebas para asegurar su funcionalidad y eficiencia operativa.

7. Monitoreo y Mejora Continua

Tras la implementación final, el sistema seguirá en constante mejora. La metodología basada en prototipos garantiza un proceso de mejora continua, donde el sistema podrá adaptarse a nuevos requerimientos y cambios en el entorno logístico.

4. Análisis de Diseño

El análisis de diseño consiste en identificar que ocurre dentro del sistema y cómo se relacionarán los distintos procesos dentro de la computadora. Este análisis permite entender el problema y documentar las relaciones entre los usuarios, el programa y los componentes que conforman la lógica del sistema. Además, está orientado al desarrollo de diagramas que ilustren dichas relaciones, combinando el lenguaje del usuario con el enfoque técnico del programador, sin necesidad de escribir líneas de código ni definir el lenguaje final de programación [40].

Por otro lado, el diseño se encarga de la implementación del sistema. A partir de los diagramas generados se decide cómo se codificará el sistema, incluyendo el sistema operativo, número de usuarios, cómo se almacenará la información y que lenguajes de programación se emplearán, así como los recursos necesarios.

4.1. Requerimientos

4.1.1. Requerimientos funcionales

- RF1: El sistema deberá proveer una interfaz web al usuario, donde el usuario pueda interactuar para ingresar los detalles de su ruta.
- RF2: El sistema utilizará un modelo de machine learning para realizar las predicciones meteorológicas.
- RF3: El sistema usará algoritmos bioinspirados para realizar la optimización de la ruta con base en la distancia total del recorrido.
- RF4: El sistema tomará como restricciones las predicciones meteorológicas de la ruta al momento de hacer la optimización.
- RF5: El sistema permitirá la selección de las diferentes naves industriales del Estado de México como puntos de interés de la ruta.
- RF6: El sistema proporcionará detalles de la ruta final al usuario, como la distancia total del recorrido y las condiciones meteorológicas presentes en la ruta.
- RF7: El sistema le permitirá al usuario interactuar con sus funcionalidades sin crear una cuenta.
- RF8: El sistema permitirá al usuario crear una cuenta para guardar los datos de su ruta para su posterior uso y evitar ingresar la información nuevamente.
- RF9: El sistema contará con una base de datos para la gestión y almacenamiento de las rutas históricas del usuario.
- RF10: El sistema permitirá la integración con una API meteorológica con el fin obtener los datos necesarios para la predicción con el modelo de machine learning.

4.1.2. Requerimientos no funcionales

- RNF1: Proveer documentación completa y detallada para los usuarios y desarrolladores.
- RNF2: En caso de un error con el servicio web se mostrará una página donde se indique un error con el sistema.

4.2. Casos de uso

Los casos de uso representan las distintas funcionalidades del sistema, definidas a partir de los requerimientos funcionales, cada caso de uso describe una acción específica que se debe de realizar para cumplir con las necesidades o expectativas de los interesados.

Los actores del sistema son los roles que se le asignan a los individuos que interactúan con las distintas funcionalidades. En la Tabla 5 se presentan los actores que intervienen con el sistema junto con la descripción de las funciones que realizan.

Actor	Descripción
Administrador	Es el encargado del sistema. Tiene la capacidad de configurar los parámetros del algoritmo bioinspirado para validar el desempeño del algoritmo mediante ciertas métricas que demuestren su funcionamiento tras cierto número de iteraciones, con el fin de brindar al usuario las configuraciones correctas del algoritmo al momento de realizar la optimización de rutas con restricciones meteorológicas.
Usuario	Es el actor principal del sistema. Puede seleccionar los puntos de interés de su recorrido y visualizar la ruta resultante del algoritmo de optimización. Además, puede crear una cuenta en el sistema para guardar los datos de la ruta, para posteriormente consultar los datos de los puntos de interés que haya seleccionado.
API meteorológica	Este actor es el encargado de proporcionar los datos meteorológicos necesarios para realizar las predicciones sobre cada punto de interés de la ruta del usuario.

Tabla 5: Tabla descriptiva de actores

A continuación, se muestran las tablas descriptivas de los casos de uso, organizadas de acuerdo a las áreas que conforman al sistema.

4.2.1. Casos de uso del algoritmo bioinspirado

Caso de uso	Configurar parámetros del algoritmo bioinspirado
Identificador	CU_1
Requisitos asociados	RF3, RF4
Actor	Administrador
Descripción	Permite definir y ajustar los parámetros iniciales del algoritmo bioinspirado, así como especificar los archivos que contienen la información de distancias, restricciones meteorológicas y destinos seleccionados para considerar en la optimización.
Precondición	El ejecutable y los archivos de distancias, destinos y restricciones meteorológicas deben estar ubicados en la misma carpeta o ruta de trabajo.
Pasos: 1. El administrador ejecuta el programa. 2. El sistema muestra los valores actuales de los parámetros del algoritmo, junto con los nombres de los archivos donde se almacenan las distancias, las restricciones meteorológicas y destinos seleccionados. 3. El administrador puede modificar dichos valores o conservar la configuración existente 4. El sistema confirma la configuración exitosa para su uso en la optimización.	
Errores: 1. Rango de parámetros incorrectos: Los valores ingresados en los parámetros no están en los rangos preestablecidos para el correcto funcionamiento del algoritmo de optimización. Se despliega el mensaje “Valores incorrectos para los parámetros”.	

Tabla 6: Caso de uso configurar parámetros del algoritmo bioinspirado

Caso de uso	Ejecutar optimización de ruta con restricciones meteorológicas
Identificador	CU_2
Requisitos asociados	RF3, RF4
Actor	Sistema
Descripción	El sistema aplica un algoritmo bioinspirado para encontrar la ruta óptima que minimice la distancia total, incorporando penalizaciones en tramos con probabilidad de lluvia como restricción.
Precondición	Los puntos de la ruta y las predicciones meteorológicas por tramo deben estar definidos.
Pasos: 1. El usuario inicia la ejecución de la optimización. 2. El sistema carga los parámetros del algoritmo bioinspirado, los datos de la ruta (distancias) y las predicciones meteorológicas. 3. El sistema aplica las restricciones meteorológicas al identificar los tramos de la ruta con probabilidad de lluvia y asignarles un costo adicional (penalización). 4. El algoritmo bioinspirado se ejecuta: • Inicializa soluciones (p. ej., rutas aleatorias o basadas en heurísticas). • Evalúa cada solución considerando la distancia total + penalización por clima. • Modifica las soluciones mediante operaciones específicas del algoritmo (cruza, mutación, actualización de feromonas, ajuste de partículas, etc.). • Repite el proceso hasta cumplir el criterio de paro (iteraciones, convergencia, tiempo). 5. Al finalizar, el sistema devuelve la ruta con menor costo total (distancia + penalizaciones).	
Errores: 1. Fallo de la conexión con la API: No se obtiene una respuesta al realizar una solicitud a la API.	

Tabla 7: Caso de uso ejecutar optimización de ruta con restricciones meteorológicas

Caso de uso	Visualizar iteraciones de la optimización
Identificador	CU_3
Requisitos asociados	RF3
Actor	Administrador, usuario
Descripción	Permite al administrador monitorear la evolución del algoritmo bioinspirado en cada iteración y analizar el desempeño de las rutas generadas.
Precondición	El algoritmo de optimización debe de estar en ejecución.
Pasos: 1. El sistema muestra, por cada iteración, la mejor ruta encontrada y su costo asociado. 2. Al finalizar la ejecución, el sistema muestra la solución con el menor costo, la solución con el mayor costo, el costo promedio y la desviación estándar, a partir del conjunto de soluciones obtenidas durante las iteraciones. 3. El usuario finaliza la visualización cuando lo desee.	
Errores: 1. No se muestran los resultados de las iteraciones: Durante alguna de las iteraciones se presentó un error de ejecución y no se logra visualizar el resultado de dicha iteración. Se muestran solo los resultados de las iteraciones correctas.	

Tabla 8: Caso de uso visualizar iteraciones de la optimización

4.2.2. Casos de uso del algoritmo de machine learning

Caso de uso	Realizar predicciones meteorológicas con modelo de machine learning
Identificador	CU_4
Requisitos asociados	RF2
Actor	Sistema
Descripción	El sistema realiza el pronóstico de las condiciones climatológicas sobre cada punto de la ruta del usuario por medio del modelo de machine learning.
Precondición	El usuario debe de haber proporcionado los puntos de interés de su ruta.
Pasos: 1. Obtener los datos climatológicos sobre cada punto de la ruta del usuario. 2. Evaluar el modelo de machine learning con la información de cada punto 3. El modelo regresa la clase perteneciente de cada punto (despejado, nublado, con lluvia).	
Errores: 1. Puntos de interés no definidos por el usuario: El usuario olvida ingresar puntos de interés a su ruta para hacer la predicción. Se despliega el mensaje “Falta seleccionar puntos”.	

Tabla 9: Caso de uso realizar predicciones meteorológicas con modelo de machine learning

Caso de uso	Obtener los datos para realizar las predicciones meteorológicas
Identificador	CU_5
Requisitos asociados	RF10
Actor	Sistema, API meteorológica
Descripción	Se obtendrán los datos de las condiciones climatológicas sobre cada uno de los puntos de interés de la ruta del usuario por medio de API's que regresen los datos necesarios para realizar la predicción.
Precondición	Se debe de tener conexión con la API y el usuario debe de indicar sus puntos de interés.
Pasos:	
1. Recibir la solicitud del sistema para realizar la predicción. 2. Hacer la solicitud a la API meteorológica por cada punto de la ruta. 3. Adquirir los datos para cada uno de los puntos.	
Errores:	
1. Fallo de la conexión con la API: No se obtiene una respuesta al realizar una solicitud a la API. 2. Puntos de interés no definidos por el usuario: El usuario olvida ingresar puntos de interés a su ruta para hacer la predicción. Se despliega el mensaje "Falta seleccionar puntos"	

Tabla 10: Caso de uso obtener los datos para realizar las predicciones meteorológicas

4.2.3. Casos de uso de la interfaz web

Caso de uso	Seleccionar puntos de interés
Identificador	CU_6
Requisitos asociados	RF5, RNF2
Actor	Usuario
Descripción	El usuario selecciona de la lista pre guardada los puntos de interés que desea visitar en su recorrido.
Precondición	El usuario ha iniciado la interfaz y está cargada correctamente.
Pasos: 1. Desplegar la lista de todas las naves industriales del Estado de México. 2. Seleccionar puntos de interés 3. Registrar los puntos seleccionados. 4. Mostrar lista de lugares seleccionados con opción para eliminarlos o reordenarlos.	
Errores: 1. El usuario no selecciona ningún punto de interés: El sistema detecta la falta de selección y despliega el mensaje en pantalla "Falta seleccionar puntos. Por favor seleccione al menos un punto de interés para continuar". Mientras no se seleccione al menos un punto, el sistema no permitirá avanzar al siguiente paso. 2. Fallo en la conexión o en la base de datos: El sistema no logra obtener los datos debido a un fallo en la conexión o en la base de datos. Si esto ocurre, se mostrará al usuario el mensaje "No se pudo cargar la lista de puntos de interés. Intente nuevamente más tarde" y se le dará la opción de reintentar la carga.	

Tabla 11: Caso de uso seleccionar puntos de interés

Caso de uso	Generar ruta optimizada
Identificador	CU_7
Requisitos asociados	RF6
Actor	Sistema
Descripción	Se generan opciones de rutas óptimas tomando en cuenta las restricciones meteorológicas y distancias del usuario.
Precondición	El usuario ha seleccionado al menos un punto de interés.
Pasos: 1. Enviar puntos seleccionados y datos climáticos al algoritmo de optimización. 2. Ejecutar modelo de Machine Learning para estimar condiciones adversas. 3. Aplicar algoritmo bioinspirado con restricciones climáticas. 4. Obtener y almacenar rutas optimizadas temporalmente.	
Errores: 1. Falla el envío de la información al algoritmo de optimización: El sistema no logra transmitir correctamente los puntos seleccionados y los datos climáticos al algoritmo que se encarga de generar las rutas optimizadas.	

Tabla 12: Caso de uso generar ruta optimizada

Caso de uso	Visualizar ruta
Identificador	CU_8
Requisitos asociados	RF6
Actor	Usuario
Descripción	El usuario puede ver la ruta generada sobre el mapa.
Precondición	Se ha generado una ruta óptima.
Pasos:	
1. Cargar mapa y rutas. 2. Marcar los puntos de interés establecidos por el usuario. 3. Mostrar leyenda y datos relevantes de la ruta generada (distancia, condiciones).	
Errores:	
1. No se puede cargar el mapa: El sistema muestra al usuario un mensaje que indique: "No se pudo cargar el mapa. Intente más tarde." Como consecuencia, la visualización de la ruta quedará suspendida hasta que sea posible cargar el mapa. 2. No se pueden recuperar los datos asociados a la ruta generada: El sistema informa al usuario mediante el siguiente mensaje: "No se pudieron recuperar los datos de la ruta. Intente nuevamente." No podrá continuar con la visualización hasta que la información esté disponible.	

Tabla 13: Caso de uso visualizar ruta

Caso de uso	Guardar ruta
Identificador	CU_9
Requisitos asociados	RF8 y RF9
Actor	Usuario
Descripción	El usuario puede guardar una ruta para futuras consultas
Precondición	Una ruta ha sido generada y visualizada.
Pasos: 1. Cargar ruta. 2. Ofrece un botón de “Guardar ruta”. 3. Guardar ruta en base de datos. 4. Confirmar al usuario que la ruta ha sido guardada.	
Errores: 1. Error de conexión con la base de datos: La ruta histórica del usuario no se logra guardar en la base de datos debido a un error de conexión. Se despliega el mensaje “Error al guardar ruta”	

Tabla 14: Caso de uso guardar ruta

Caso de uso	Consultar rutas guardadas
Identificador	CU_10
Requisitos asociados	RF9
Actor	Usuario
Descripción	El usuario puede visualizar rutas previamente guardadas y cargarlas nuevamente.
Precondición	Existen rutas guardadas en el perfil de usuario.
Pasos: 1. Consultar base de datos de rutas del usuario. 2. Mostrar lista con resumen (nombre, lugares,). 3. Permitir seleccionar una ruta. 4. Generar ruta optimizada con los puntos de la ruta seleccionada.	
Errores: 1. El usuario no cuenta con rutas guardadas: El usuario no cuenta con alguna ruta histórica guardada en la base de datos. Se despliega un mensaje informativo que indique: "No existen rutas guardadas". De esta manera, se le notifica al usuario que no hay información disponible para visualizar o seleccionar.	

Tabla 15: Caso de uso consultar rutas guardadas

Caso de uso	Crear una cuenta de usuario
Identificador	CU_11
Requisitos asociados	RF8
Actor	Usuario
Descripción	El usuario puede crear una cuenta para guardar sus rutas y acceder a ellas en el futuro sin tener que ingresar los datos nuevamente.
Precondición	El usuario no tiene cuenta en el sistema.
Pasos: 1. Mostrar formulario de registro (nombre, correo, contraseña). 2. Validar datos. 3. Guardar la información en la base de datos. 4. Confirmar al usuario que la cuenta fue creada correctamente. 5. Redirigir al usuario a su perfil o inicio.	
Errores: 1. Fallo de conexión con la base de datos: El sistema no logra conectar con la base de datos para crear una cuenta para el usuario. Se despliega el mensaje “Error al crear cuenta” 2. Duplicidad de datos: Ya existe una cuenta con un nombre de usuario similar al que se intenta guardar. Se despliega el mensaje “Ya existe una cuenta con estos datos”	

Tabla 16: Caso de uso crear cuenta de usuario

Caso de uso	Iniciar sesión en el sistema
Identificador	CU_12
Requisitos asociados	RF8
Actor	Administrador, Usuario
Descripción	El usuario puede iniciar sesión en su cuenta para acceder a sus rutas guardadas.
Precondición	Existe una cuenta creada por el usuario.
Pasos: 1. Mostrar formulario de inicio de sesión (correo y contraseña). 2. Validar las credenciales en la base de datos. 3. Si las credenciales son correctas, permitir acceso al sistema. 4. Si las credenciales son incorrectas, mostrar mensaje de error y permitir intentos adicionales. 5. Redirigir al usuario a la interfaz principal.	
Errores: 1. Datos incorrectos: El usuario ingresa su nombre de usuario o contraseña de manera incorrecta. Se despliega el mensaje “Datos incorrectos” 2. Cuenta inexistente: No existe una cuenta con los datos con los que el usuario intenta ingresar. Se despliega el mensaje “No existe cuenta con estos datos”	

Tabla 17: Caso de uso iniciar sesión en el sistema

Una vez descritos los casos de uso, junto con las funcionalidades que estos contienen, en la Figura 10 y la Figura 11 se muestran los diagramas de casos de uso según los actores que intervienen en ellos, además se puede distinguir el flujo que sigue el sistema para cada funcionalidad.




Figura 10: Diagrama de casos de uso para Usuario




Figura 11: Diagrama de casos de uso para Administrador

4.3. Modelo relacional de la base de datos

En la Figura 12 se muestra el modelo relacional de la base de datos del sistema, la cual está diseñada para que los usuarios con una cuenta puedan guardar los datos de su ruta, permitiéndoles consultarlas y evaluarlas posteriormente, sin necesidad de ingresar los puntos nuevamente. La base de datos con una tabla para guardar los datos de acceso del usuario, como nombre, correo electrónico, contraseña y un identificador único para cada usuario. En la otra tabla se almacenarán los datos de las rutas de los usuarios, como los distintos puntos de interés de dicha ruta, el identificador del usuario al que pertenece la ruta y el edificador único de la ruta.




Figura 12: Modelo relacional base de datos

4.4. Diagrama de Clases

En la Figura 13, se presenta el diagrama de clases del sistema, el cual define la estructura y la organización de los componentes que conforman la solución a nivel de código. Este diagrama especifica los tipos de datos, las funciones (métodos) y la declaración de variables de cada clase, diferenciándose así de la representación de instancias que se ofrece en el diagrama de objetos. Se describen las clases correspondientes a los actores, como Administrador y Usuario, con sus métodos específicos para interactuar (por ejemplo, seleccionar puntos de interés, visualizar rutas, guardar rutas, consultar rutas guardadas, crear cuenta de usuario e iniciar sesión). Además, se incluyen las clases de la capa de presentación (Interfaz Web), los módulos de obtención y procesamiento de datos climáticos (API_Meteorologica y ModeloMachineLearning) y el núcleo del algoritmo de optimización (AlgoritmoBioinspirado), junto con sus clases auxiliares, tales como Parametros, Iteracion, RutaOptima y los archivos de entrada.




Figura 13: Diagrama de clases del sistema

4.5. Diagrama de Objetos

En la Figura 14, se muestra el diagrama de objetos del sistema, el cual presenta de forma detallada las instancias en ejecución de los componentes involucrados. Asimismo, ilustra la interacción entre los actores, como el Administrador y el Usuario, y los elementos funcionales del sistema: la Interfaz Web que actúa como puente de comunicación, el servicio externo de la API meteorológica, el modelo de Machine Learning responsable de predecir las condiciones climáticas, y el motor de optimización basado en algoritmos bioinspirados. Además, se exponen los objetos internos del algoritmo, tales como los parámetros de configuración, los archivos de entrada (de distancias, restricciones meteorológicas y destinos), las iteraciones generadas durante el proceso y la ruta optimizada resultante con sus detalles.




Figura 14: Diagrama de objetos del sistema

4.6. Diagramas de Flujo

4.6.1. Preprocesamiento de datos

La página de Weather Underground ayuda a obtener datos históricos del 2022 al 2024 en un formato que permite el entrenamiento de los distintos modelos de Machine Learning, con un vector de características y la clase a la que pertenecen estas mismas. Cada dato cuenta con la información de la hora en que se tomaron los datos, la temperatura, punto de rocío, humedad, dirección del viento, velocidad del viento, ráfaga de viento, presión atmosférica, precipitación y la condición meteorológica del dato en la hora de registro.

Observaciones diarias

Tiempo	Temperatura	Punto de rocío	Humedad	Viento	Velocidad del viento	Ráfaga de viento	Presión	Precipitación	Condición
05:48 p. m.	24 °C	6 °C	31%	SE	28 km/h	0 km/h	779.59 hPa	0.0 mm	Nublado
06:28 p. m.	22 °C	7 °C	38%	SSE	41 km/h	0 km/h	779.84 hPa	0.0 mm	Trueno / Viento
07:55 p. m.	22 °C	2 °C	27%	SSE	19 km/h	0 km/h	781.14 hPa	0.0 mm	Lluvia ligera con truenos
08:59 p. m.	20 °C	8 °C	46%	W	22 km/h	0 km/h	782.43 hPa	0.0 mm	Trueno
09:44 p. m.	19 °C	7 °C	46%	W	19 km/h	0 km/h	782.43 hPa	0.0 mm	Mayormente nublado
10:45 p. m.	18 °C	8 °C	52%	WNW	9 km/h	0 km/h	782.17 hPa	0.0 mm	Parcialmente nublado
11:50 p. m.	16 °C	7 °C	55%	NW	7 km/h	0 km/h	782.17 hPa	0.0 mm	Despejado

Figura 15: Ejemplo de datos en Weather Underground

En el preprocesamiento de los datos, se limpian y se transforman los datos brutos obtenidos con anterioridad, para convertirlos en un formato numérico capaz de entrenar al modelo de Machine Learning, en la Figura 16 se muestra el diagrama de flujo con el proceso del preprocesamiento de los datos.




Figura 16: Diagrama de flujo del preprocesamiento de los datos

El proceso comienza eliminando las columnas de Ráfaga de viento y Precipitación, debido a que en todos los registros siempre tienen un valor de cero, lo que puede indicar un error de la estación meteorológica al momento de tomar el registro. Luego se elimina la columna de Presión, ya que estos valores corresponden a la presión atmosférica al nivel del mar, que si bien es información es relevante para la predicción de la condición meteorológica, no representa la presión atmosférica real en los puntos de interés del Estado de México. Después se eliminan las unidades de medida como grados centígrados (°C), kilómetros por hora (km/h) y porcentaje (%) con el fin de quitar estos caracteres y dejar los datos en su formato numérico.

En cuanto al formato de la hora de registro, este se transforma a minutos transcurridos desde la medianoche, por ejemplo, un registro con hora 3:17 AM se convierte en 197 minutos ($3 \text{ horas} \times 60 \text{ minutos} + 17 \text{ minutos}$), lo cual permite manejar la hora con un formato numérico.

Para el caso de la dirección del viento, los datos originales presentan los datos en un formato similar al de una brújula indicando la dirección del viento, con valores como “N” para norte, “SW” para suroeste, entre otros. Para transformar estos datos a formato numérico se asignan valores angulares equivalentes con la dirección de la brújula, considerando un círculo de 360°, con lo que la nueva representación del dato de la dirección del viento es 0 para “N”, 180 para “S”, 315 para “NW”.

Los datos originales cuentan con un total de 31 tipos de condiciones meteorológicas, las cuales presentan un desbalance en la cantidad de datos, a continuación, se muestran las categorías originales y la cantidad de datos:

Condición	Núm. datos
Tormenta eléctrica intensa	30
Niebla	1059
Despejado	9135
Bruma	400
Mayormente nublado	7657
Parcialmente nublado	4497
Lluvia ligera con truenos	320
Nublado	2617
Trueno	150
Trueno/Viento	6
Lluvia ligera	641
Lluvia	185

Parcialmente nublado/Viento	37
Humo/Viento	1
Despejado/Viento	30
Tormenta eléctrica	171
Tormenta eléctrica intensa/Viento	7
Lluvia intensa	10
Lluvia ligera/Viento	9
Humo	254
Lluvia/Viento	7
Llovizna	3
Tormenta eléctrica/Viento	9
Lluvia intensa/Viento	3
Bancos de niebla	1
Nublado/Viento	12
Llovizna ligera	21
Neblina	678
Mayormente nublado/Viento	56
Neblina/Viento	1
Granizo	1

Tabla 18: Datos originales de Weather Underground

Como se observa en la Tabla 18 hay categorías con un solo dato único, por lo cual se tiene que hacer una reducción en el número de clases para no afectar el desempeño del modelo de Machine Learning, para ello se agrupan las condiciones con mayor relación en los tipos de climas, incorporando las condiciones con viento a su equivalente sin viento, por ejemplo los datos de la categoría Despejado/Viento se agrupan a la categoría de Despejado, aumentando el número de datos en estas categorías y pasando de 31 a 19 categorías en total.

Del mismo modo la categoría de Bancos de niebla se agrupó con la categoría de Niebla, las categorías de Llovizna, Llovizna ligera y Lluvia ligera con truenos se juntaron con Lluvia ligera, ya que estas categorías representan condiciones similares. Finalmente, se eliminó la clase de Granizo, la cual solo tiene un único dato en el periodo de los 3 años.

Después de agrupar las condiciones climáticas que representan condiciones meteorológicas similares, se obtienen las siguientes 14 clases: Humo, Niebla, Despejado, Bruma, Mayormente nublado, Parcialmente nublado, Nublado, Trueno, Lluvia ligera, Lluvia, Tormenta eléctrica, Lluvia intensa, Tormenta eléctrica intensa y Neblina.

Para reducir el número de clases, los datos son procesados por un algoritmo de agrupamiento K-means, el cual, a pesar de ser un algoritmo de aprendizaje no supervisado, tiene la ventaja de que al especificar el número de centroides divide los datos en K grupos, permitiendo agrupar datos con características similares y simplificar el problema de clasificación. Además, este algoritmo destaca por su simplicidad y escalabilidad, lo que lo hace el adecuado para reducir a un total de 10 categorías para entrenar al modelo de Machine Learning, el cual da como resultado las clases que se muestran en la Tabla 19.

Clases anteriores agrupadas	Nuevo nombre
Trueno	Trueno
Humo, Bruma	Bruma
Neblina	Neblina
Lluvia ligera, Tormenta eléctrica	Lluvia
Niebla	Niebla
Nublado, Lluvia ligera	Nublado
Mayormente nublado, Parcialmente nublado	Considerablemente nublado
Despejado	Despejado
Lluvia intensa	Lluvia intensa
Lluvia, Tormenta eléctrica intensa	Tormenta eléctrica intensa

Tabla 19: Nuevas clases con datos agrupados

Una vez que se han identificado las 10 clases se hace un balance en la cantidad de datos para que todos los grupos tengan la misma cantidad y no exista un sesgo hacia alguna clase en particular. Para ello, se utilizó la herramienta Resample del software Weka, que permite ajustar la distribución de las clases mediante técnicas de remuestreo, para ello se configuraron los siguientes parámetros:

- `biasToUniformClass = 1.0`: Este valor fuerza a que el muestreo sea completamente uniforme entre las clases, es decir, intenta dar a cada clase la misma probabilidad de ser seleccionada.
- `sampleSizePercent = 300`: Este valor indica que el nuevo conjunto de datos generado debe tener un tamaño equivalente al 300% del original, permitiendo así realizar sobremuestreo sobre las clases minoritarias para igualarlas en cantidad a las clases con más datos.

En la Figura 17 se muestran las 10 clases con su número de muestras antes de balancear, y en la Figura 18 se observan las 10 clases ya balanceadas con un total de 8399 muestras por clase.




Figura 17: Clases sin balancear




Figura 18: Clases después de balancear

4.6.2. Entrenamiento de los modelos

Una vez que los datos han sido convertidos a un formato numérico, se procede al entrenamiento de los modelos de Machine Learning. Para ello, primero se carga el dataset con los datos preprocesados, luego dependiendo del modelo a entrenar, se configuran sus parámetros.

El dataset se divide en un 70% para entrenamiento y un 30% para pruebas. Una vez completado el entrenamiento, se obtienen las métricas de desempeño y la matriz de confusión, lo que permite comparar los distintos modelos y seleccionar aquel que logre la mejor clasificación de los datos. En la Figura 19 se presenta el diagrama de flujo que ilustra el proceso de entrenamiento de los modelos.




Figura 19: Diagrama de flujo entrenamiento de los modelos

4.7. Índice de penalización y encuesta

El presente trabajo introduce un índice de riesgo climático con el objetivo de cuantificar la percepción del peligro al conducir en carretera bajo diversas condiciones meteorológicas. Para integrar esta evaluación en el algoritmo bioinspirado, se utilizará un índice de penalización dinámico, determinado por las predicciones climáticas del modelo de machine learning. Este tipo de penalización, característica de los algoritmos bioinspirados, es adaptable al problema que se desea resolver.

El índice de riesgo se expresará en una escala discreta del 1 al 10, donde 1 representa el riesgo mínimo y 10 el riesgo máximo, correspondiente a las diez categorías climáticas consideradas.

Para validar esta propuesta y recopilar la información necesaria, se realizó una encuesta a través de Microsoft Forms, dirigida a 200 participantes, entre los cuales se incluyeron transportistas y conductores de vehículos particulares. En la encuesta, se solicitó a los usuarios que clasificaran en orden ascendente diez tipos de clima según el nivel de peligro percibido como se muestra en la Figura 20 (bruma, niebla, despejado, considerablemente nublado, lluvia, nublado, truenos, tormenta eléctrica intensa, lluvia intensa y neblina). Estas categorías corresponden a las clases con las que se entrenará el modelo de machine learning.

Evaluación del riesgo al manejar según las condiciones climáticas

Este formulario tiene como objetivo identificar cuáles son las condiciones climáticas que generan mayor sensación de riesgo o inseguridad al conducir. Por favor, ordena las siguientes condiciones según tu percepción personal, desde la que consideras más riesgosa hasta la menos riesgosa.

Dato importante:
Bruma: Es muy ligera, parece una capa delgada en el aire. Se puede ver bastante bien.
Neblina: Es más densa que la bruma, pero aún permite cierta visibilidad. Se puede ver a una distancia media, aunque con dificultad.
Niebla: Es la más densa de las tres. Reduce mucho la visibilidad, no se puede ver lo que está frente a ti.

* Obligatorio

1. Ordena las siguientes condiciones climáticas según qué tan inseguro o riesgoso te sientes al conducir en ellas (1 = Menor riesgo, 10 = Mayor riesgo) .

*

Bruma
Niebla
Despejado
Considerablemente nublado
Lluvia
Nublado
Truenos
Tormenta eléctrica intensa
Lluvia intensa
Neblina

Enviar

Figura 20: Entrevista realizada a conductores. Elaboración propia

A partir de los datos recopilados en la encuesta, se elaboró un concentrado en Excel que permite visualizar de manera más clara la información y sus tendencias, mostrado en la Figura 21. El análisis reveló que la condición climática percibida como menos riesgosa por la mayoría de los encuestados fue “Despejado”, la cual acumuló un total de 181 menciones. Este resultado sugiere una percepción generalizada de seguridad bajo esta condición, posiblemente asociada a la buena visibilidad y la ausencia de fenómenos meteorológicos adversos.

Por otra parte, la condición considerada como más riesgosa fue “Tormenta eléctrica intensa”, con 62 menciones, seguida muy de cerca por “Niebla”, que recibió 59 menciones. Ambos escenarios climáticos comparten características que afectan significativamente la seguridad vial.

A partir de los datos obtenidos se sugiere que la condición “Despejado” reciba la penalización mínima de 1 punto, dada su baja percepción de riesgo. Además, se propone asignar 10 a la condición “Tormenta eléctrica intensa” y 9 a “Niebla”, reflejando su alta percepción de peligrosidad entre los participantes.

ID	Condiciones climáticas
1	Despejado;Nublado;Considerablemente nublado;Truenos;Tormenta eléctrica intensa;Lluvia;Niebla;Bruma;Lluvia intensa;Neblina;
2	Despejado;Nublado;Considerablemente nublado;Truenos;Lluvia;Lluvia intensa;Tormenta eléctrica intensa;Neblina;Niebla;Bruma
3	Despejado;Nublado;Considerablemente nublado;Truenos;Bruma;Lluvia;Lluvia intensa;Neblina;Tormenta eléctrica intensa;Niebla;
4	Despejado;Bruma;Nublado;Considerablemente nublado;Lluvia;Truenos;Lluvia intensa;Tormenta eléctrica intensa;Neblina;Niebla;
5	Despejado;Nublado;Bruma;Truenos;Considerablemente nublado;Tormenta eléctrica intensa;Lluvia;Lluvia intensa;Neblina;Niebla
6	Despejado;Nublado;Considerablemente nublado;Bruma;Lluvia;Neblina;Lluvia intensa;Truenos;Tormenta eléctrica intensa;Niebla;
7	Despejado;Bruma;Nublado;Considerablemente nublado;Lluvia;Truenos;Neblina;Lluvia intensa;Niebla;Tormenta eléctrica intensa;
8	Despejado;Nublado;Considerablemente nublado;Neblina;Bruma;Niebla;Truenos;Lluvia;Tormenta eléctrica intensa;Lluvia intensa
9	Despejado;Nublado;Considerablemente nublado;Bruma;Niebla;Neblina;Truenos;Lluvia;Lluvia intensa;Tormenta eléctrica intensa;
10	Despejado;Nublado;Considerablemente nublado;Truenos;Bruma;Tormenta eléctrica intensa;Lluvia;Niebla;Lluvia intensa;Neblina;
11	Despejado;Truenos;Bruma;Considerablemente nublado;Tormenta eléctrica intensa;Neblina;Lluvia;Lluvia intensa;Niebla
12	Despejado;Truenos;Considerablemente nublado;Bruma;Nublado;Lluvia;Tormenta eléctrica intensa;Lluvia intensa;Neblina;Niebla;
13	Despejado;Bruma;Nublado;Considerablemente nublado;Truenos;Niebla;Neblina;Lluvia;Lluvia intensa;Tormenta eléctrica intensa
14	Despejado;Considerablemente nublado;Nublado;Truenos;Bruma;Tormenta eléctrica intensa;Lluvia;Lluvia intensa;Niebla;Neblina
15	Despejado;Considerablemente nublado;Nublado;Truenos;Bruma;Neblina;Niebla;Lluvia;Lluvia intensa;Tormenta eléctrica intensa;
16	Despejado;Nublado;Bruma;Considerablemente nublado;Truenos;Neblina;Tormenta eléctrica intensa;Lluvia;Lluvia intensa;Niebla;
17	Despejado;Nublado;Considerablemente nublado;Truenos;Tormenta eléctrica intensa;Lluvia;Lluvia intensa;Bruma;Neblina;Niebla;
18	Despejado;Lluvia;Nublado;Truenos;Neblina;Bruma;Considerablemente nublado;Lluvia intensa;Tormenta eléctrica intensa;Niebla;
19	Despejado;Bruma;Lluvia;Niebla;Nublado;Considerablemente nublado;Truenos;Neblina;Tormenta eléctrica intensa;Lluvia intensa;
20	Despejado;Nublado;Considerablemente nublado;Lluvia;Bruma;Truenos;Neblina;Niebla;Tormenta eléctrica intensa;Lluvia intensa;
21	Despejado;Nublado;Considerablemente nublado;Lluvia;Tormenta eléctrica intensa;Lluvia intensa;Truenos;Bruma;Neblina;Niebla;
22	Despejado;Niebla;Considerablemente nublado;Truenos;Bruma;Neblina;Nublado;Lluvia intensa;Lluvia;Tormenta eléctrica intensa
23	Despejado;Bruma;Nublado;Neblina;Considerablemente nublado;Truenos;Lluvia;Tormenta eléctrica intensa;Lluvia intensa;Niebla
24	Despejado;Considerablemente nublado;Nublado;Bruma;Truenos;Lluvia;Lluvia intensa;Tormenta eléctrica intensa;Neblina;Niebla;
25	Despejado;Truenos;Nublado;Considerablemente nublado;Bruma;Lluvia;Neblina;Tormenta eléctrica intensa;Lluvia intensa;Niebla
26	Bruma;NieblaDespejado;Lluvia;Neblina;Considerablemente nublado;Nublado;Truenos;Tormenta eléctrica intensa;Lluvia intensa;
27	Neblina;Lluvia;Niebla;BrumaDespejado;Nublado;Tormenta eléctrica intensa;Considerablemente nublado;Truenos;Lluvia intensa;
28	Despejado;Nublado;Truenos;Tormenta eléctrica intensa;Considerablemente nublado;Bruma;Lluvia;Neblina;Niebla;Lluvia intensa;
29	Despejado;Considerablemente nublado;Nublado;Bruma;Neblina;Niebla;Lluvia;Lluvia intensa;Truenos;Tormenta eléctrica intensa;
30	Despejado;Nublado;Considerablemente nublado;Truenos;Tormenta eléctrica intensa;Bruma;Lluvia;Neblina;Lluvia intensa;Niebla;
31	Despejado;Nublado;Considerablemente nublado;Bruma;Lluvia;Neblina;Truenos;Tormenta eléctrica intensa;Lluvia intensa;Niebla
32	Despejado;Considerablemente nublado;Nublado;Bruma;Neblina;Truenos;Tormenta eléctrica intensa;Niebla;Lluvia;Lluvia intensa;
33	Bruma;NieblaDespejado;Considerablemente nublado;Lluvia;Nublado;Truenos;Tormenta eléctrica intensa;Neblina;Lluvia intensa;
34	Despejado;Considerablemente nublado;Nublado;Neblina;Niebla;Bruma;Lluvia;Truenos;Lluvia intensa;Tormenta eléctrica intensa;
35	Despejado;Considerablemente nublado;Nublado;Truenos;Bruma;Niebla;Neblina;Lluvia;Lluvia intensa;Tormenta eléctrica intensa;
36	Bruma;Neblina;Niebla;LluviaDespejado;Nublado;Truenos;Tormenta eléctrica intensa;Lluvia intensa;Considerablemente nublado;
37	Despejado;Truenos;Lluvia;Nublado;Neblina;Considerablemente nublado;Bruma;Niebla;Lluvia intensa;Tormenta eléctrica intensa
38	Despejado;Nublado;Considerablemente nublado;Bruma;Neblina;Truenos;Lluvia;Lluvia intensa;Tormenta eléctrica intensa;Niebla;
39	Despejado;Lluvia;Truenos;Tormenta eléctrica intensa;Lluvia intensa;Bruma;Nublado;Considerablemente nublado;Niebla;Neblina
40	Despejado;Bruma;Nublado;Considerablemente nublado;Lluvia;Lluvia intensa;Truenos;Tormenta eléctrica intensa;Neblina;Niebla;
41	Nublado;Considerablemente nublado;Truenos;Lluvia intensaDespejado;Lluvia;Bruma;Neblina;Niebla;Tormenta eléctrica intensa;
42	Despejado;Bruma;Neblina;Nublado;Considerablemente nublado;Lluvia;Lluvia intensa;Truenos;Niebla;Tormenta eléctrica intensa
43	Despejado;Bruma;Neblina;Nublado;Lluvia;Niebla;Truenos;Considerablemente nublado;Lluvia intensa;Tormenta eléctrica intensa
44	Despejado;Neblina;Bruma;Niebla;Lluvia intensa;Truenos;Considerablemente nublado;Lluvia;Nublado;Tormenta eléctrica intensa;
45	Despejado;Considerablemente nublado;Truenos;Nublado;Bruma;Neblina;Lluvia;Lluvia intensa;Tormenta eléctrica intensa;Niebla

Figura 21: Concentrado de datos encuesta. Elaboración propia

4.8. Diagramas de secuencia

Los diagramas de secuencia ofrecen una visión más clara y detallada de la interacción entre los objetos y actores a lo largo del tiempo, permitiendo comprender cómo se lleva a cabo una tarea específica. En la Figura 23 a Figura 28 se presentan los diagramas que ilustran las interacciones entre los usuarios y el sistema de cada uno de los casos de uso previamente descritos.




Figura 22: Diagrama de secuencia iniciar sesión




Figura 23: Diagrama de secuencia crear nueva cuenta




Figura 24: Diagrama de secuencia consultar rutas guardadas




Figura 25: Diagrama de secuencia guardar ruta




Figura 26: Diagrama de secuencia visualizar ruta




Figura 27: Diagrama de secuencia seleccionar puntos de interés




Figura 28: Diagrama de secuencia generación de ruta

4.9. Mockups

Un mockup es una representación visual estática y detallada de la interfaz de usuario, que tiene como propósito reflejar la apariencia final del producto antes de su desarrollo, como se observa en este caso de la Figura 29 a la Figura 33. Permiten validar la experiencia de usuario y asegurar que el diseño gráfico cumple con los objetivos funcionales antes de invertir recursos en la codificación.

En la Figura 29 observa el diseño propuesto para la pantalla principal, en este se integra la parte de poder calcular la ruta sin necesidad de contar con una cuenta en el sistema. Aunque también se ofrece la posibilidad de iniciar sesión con la cuenta del usuario previamente creada o en su defecto crear una nueva.




Figura 29: Mockup pantalla principal

Posteriormente en la Figura 30 se aprecia la propuesta de cómo se visualizará la ruta generada con los puntos a visitar, se propone un mapa estático donde la ruta se pueda previsualizar gráficamente, así como el listado de acciones que debe realizar el usuario. También se brinda la opción de guardar ruta en caso de que el usuario tenga una cuenta.






Figura 30: Mockup ruta generada

Por otro lado, en la Figura 31 y Figura 32 se muestran las interfaces para crear una nueva cuenta e iniciar sesión respectivamente, en cada caso se le pedirá al usuario que ingrese su correo, su nombre y una contraseña. Datos que serán validados y alojados en la base de datos.



The image shows a web browser window with the address bar displaying 'LogistiClima' and 'www.logistiClima.com'. The page has a light blue background. At the top center is the 'LogistiClima' logo, which consists of a stylized globe icon with a sun and a gear, followed by the text 'LogistiClima' in a bold, dark green font. Below the logo is the text 'Nueva Cuenta' in a smaller, dark green font. There are three input fields stacked vertically: the first is labeled 'Email' with an envelope icon, the second is labeled 'Nombre' with a person icon, and the third is labeled 'Password' with an asterisk icon. Below these fields is a large, rounded, teal button with the text 'Registrarse' in white.

Figura 31: Mockup Nueva Cuenta



The image shows a web browser window with the address bar displaying 'LogistiClima' and 'www.logistiClima.com'. The page has a light blue background. At the top center is the 'LogistiClima' logo, which consists of a stylized globe icon with a sun and a gear, followed by the text 'LogistiClima' in a bold, dark green font. Below the logo is the text 'Ingresa' in a smaller, dark green font. There are two input fields stacked vertically: the first is labeled 'Email' with an envelope icon, and the second is labeled 'Password' with an asterisk icon. Below these fields is a large, rounded, teal button with the text 'Iniciar Sesión' in white.

Figura 32: Mockup Iniciar Sesión

Por último, se tiene la pantalla del usuario al iniciar sesión en su cuenta, donde podrá acceder a sus rutas guardadas, evitando así repetir todo el proceso desde el inicio. También tendrá la opción de generar una nueva ruta según sus necesidades.




Figura 33: Mockup página usuario

5. Selección de modelos

5.1. Selección de lenguajes de programación

El módulo de algoritmos bioinspirados constituye el corazón del sistema, pues integra y coordina la entrada de datos proveniente de la API, el modelo de Machine Learning y el componente web. Su responsabilidad es asegurar que cada operación compleja se ejecute con la máxima eficiencia en un entorno dinámico. Para ello, debe responder de forma ágil a cada solicitud y mantener una comunicación fluida con el resto de los módulos, sin sacrificar ni la rapidez en el tiempo de respuesta ni la capacidad de adaptarse a nuevas tecnologías. Además, dado que los algoritmos bioinspirados exigen un ajuste fino de parámetros, el sistema debe permitir actualizaciones ágiles sin comprometer su estabilidad.

Ante los requisitos planteados, se evaluaron cuatro lenguajes de programación en función de dos ejes: rendimiento (eficiencia temporal) e integración con componentes de machine learning y web [41], [42]. MATLAB cuenta con módulos especializados en optimización numérica y simulación, pero su conectividad con APIs modernas y plataformas web es limitada en comparación con otros lenguajes. Java presenta un tiempo de ejecución eficiente, superando a Python en velocidad dentro de las pruebas realizadas en [43], aunque con menor rendimiento que C en operaciones de bajo nivel; su ecosistema empresarial incluye herramientas como Spring y Java EE, orientadas al desarrollo de aplicaciones escalables, aunque su arquitectura requiere configuraciones más extensas para interactuar con bibliotecas de ciencia de datos. Python destaca por su compatibilidad con frameworks de análisis de datos (NumPy, TensorFlow) y desarrollo web (Django, Flask), permitiendo una conexión directa con APIs y modelos de machine learning, pero su gestión de memoria y velocidad en bucles intensivos es inferior a la de lenguajes compilados. C proporciona un control directo sobre la gestión de memoria y un desempeño elevado en operaciones de bajo nivel, condición que resulta útil en algoritmos con alto coste computacional, pero carece de bibliotecas nativas que simplifiquen la interacción con módulos de Machine Learning y servicios web.

La elección de C y Python para el módulo de algoritmos bioinspirados se basa en aprovechar las fortalezas de cada lenguaje, equilibrando eficiencia temporal. El lenguaje C se adoptó como núcleo de procesamiento debido a su capacidad para ejecutar operaciones complejas con un rendimiento óptimo, especialmente en escenarios que demandan velocidad y control preciso sobre los recursos del sistema. Al trabajar con control directo sobre la memoria, sin las capas de complejidad que tienen lenguajes más avanzados, C logra que cada operación sea más eficiente, maneja estructuras de datos con precisión y minimiza los retrasos en algoritmos que requieren repetir procesos o tomar decisiones probabilísticas. Esta eficacia es crucial para asegurar respuestas ágiles en cada consulta, especialmente porque los algoritmos bioinspirados no se ejecutan indefinidamente hasta alcanzar un óptimo global absoluto, sino que operan bajo criterios de parada específicos, como un número máximo de iteraciones o un umbral de convergencia.

La combinación de ambos lenguajes se logra compilando el código de C en una DLL (biblioteca de enlace dinámico), un tipo de archivo que permite integrar funciones escritas en C directamente en programas de Python. Esto es clave porque, al usar una DLL, Python puede "llamar" al algoritmo en C como si fuera una función normal, sin perder velocidad. Por ejemplo, cuando un usuario hace una consulta, Python recibe los datos, los organiza, y luego llama a la DLL para que el algoritmo en C los procese. Finalmente, Python toma el resultado y lo envía a donde corresponda (como la interfaz web). Además, las DLL permiten actualizar el algoritmo en C sin modificar el resto del sistema: basta con recompilar la biblioteca y mantener la misma interfaz en Python.

Por otro lado, Python se eligió por su flexibilidad y capacidad para conectar componentes externos de forma sencilla (API, modelo de Machine Learning y componente web) y por su capacidad de comunicarse con las interfaces web, evitando así la complejidad de implementar estas funcionalidades en lenguajes de bajo nivel. Para mejorar el desempeño de los modelos de Machine Learning, se optó por el uso de librerías enfocadas en el desarrollo de modelos de Machine Learning (como Scikit-learn y TensorFlow) con el objetivo de obtener modelos que tengan un mejor desempeño, ya que la implementación manual de los modelos no solo aumenta el tiempo de desarrollo y entrenamiento, sino también afecta en el desempeño del mismo, en cambio las librerías utilizadas ofrecen implementaciones optimizadas y ampliamente probadas en entornos reales, lo que asegura resultados consistentes. Esto permite centrar el esfuerzo en el diseño y evaluación del modelo dentro del contexto del sistema propuesto, asegurando un equilibrio entre calidad, tiempo de desarrollo y viabilidad técnica.

Por otra parte, en lo que respecta al desarrollo de la interfaz web se evaluaron distintas posibilidades que comprendieron Java, JavaScript, CSS, HTML y Python. La decisión final consistió en una implementación que conjunte JavaScript, CSS y HTML porque esto nos permitirá crear una interfaz interactiva como la propuesta mostrada en la sección 4.9 y que permita manipular el contenido, gestionar eventos de usuario y actualizar la interfaz de manera dinámica permitiendo la integración entre las distintas partes del sistema.

Además de las tecnologías y lenguajes mencionados, se contempla la implementación de la base de datos, para la cual se hizo la revisión de las opciones que comprendieron MySQL, MongoDB y Firebase, en donde se comparó compatibilidad con las otras tecnologías a utilizar, relacionalidad, simplicidad, y seguridad. Después de revisar los aspectos anteriores se decidió realizar una implementación en MySQL esto es debido a que primeramente la estructura de datos es relacional, esto descarta MongoDB y Firebase que son no relacionales, además MySQL brinda una integración sencilla y eficiente con Python que aunado con su amplia documentación y soporte permite mantener la simplicidad y finalmente para el ámbito de la seguridad y el control de acceso, permite gestionar permisos por usuario y conexiones cifradas lo cual lo hace apropiado para aplicaciones donde se manejan datos sensibles como correos electrónicos y contraseñas.

5.2. Evaluación de modelos de Machine Learning

Según [44] los modelos usualmente utilizados para realizar predicciones meteorológicas son las Redes neuronales recurrentes (RNN), Red de memoria a corto-largo plazo (LSTM), Máquinas de soporte vectorial (SVM), Árboles de decisión y Random Forest.

El objetivo principal es clasificar correctamente los 80,910 datos que corresponden a las 10 categorías de condiciones meteorológicas que se describen en la sección 4.6, para seleccionar el que mejor desempeño demuestre en la clasificación de las condiciones climatológicas.

Para definir los conjuntos de entrenamiento y prueba, se empleó una proporción del 70% de los datos para el entrenamiento y 30% para la evaluación. Este enfoque evita generar un sesgo hacia algún modelo en particular, permitiendo una comparación justa del desempeño de los modelos.

Entre las métricas para evaluar el desempeño de los modelos se encuentra el Accuracy, Precision, Recall y F1-score, descritas en la sección 2.1.2.4. En cuanto a la matriz de confusión, para este problema corresponde al caso de clasificación multiclase, ya que se cuenta con las 10 categorías del conjunto de datos antes mencionado. En los reportes de clasificación de cada modelo, se muestran las métricas de la evaluación para cada una de las clases del conjunto de datos, lo que permite un mejor desglose y análisis del desempeño del modelo al clasificar cada categoría, junto el número de muestras que se utilizaron para las pruebas y un promedio que demuestra el resumen del desempeño total del modelo.

En la Figura 34 se muestran los distintos parámetros para el entrenamiento de los modelos de Machine Learning, estos parámetros fueron escogidos para comprobar el desempeño de los modelos sin generar un sesgo hacia algún modelo, para así determinar cuál de ellos tiene el mejor desempeño al clasificar las condiciones meteorológicas descritas anteriormente.

Adicionalmente de la Figura 35 a la Figura 39, se muestran los pseudocódigos que describen la secuencia de pasos necesarios para el entrenamiento de cada uno de los modelos implementados.

Modelo	Parámetro	Descripción
RNN	SimpleRNN(64)	Capa recurrente con 64 neuronas para procesar secuencias.
	activation='softmax'	Función de activación softmax para clasificación multiclase.
	optimizer='adam'	Optimizador adaptativo eficiente.
	loss='sparse_categorical_crossentropy'	Función de pérdida para clasificación multiclase con etiquetas enteras.
	metrics=['accuracy']	Precisión utilizada como métrica principal.
	epochs=100	Número total de épocas.
	batch_size=32	Tamaño del lote de datos por iteración de entrenamiento.
LSTM	LSTM(64)	Capa LSTM con 64 unidades para manejo de secuencias.
	activation='softmax'	Función de activación para clasificación multiclase.
	optimizer='adam'	Optimizador adaptativo eficiente.
	loss='sparse_categorical_crossentropy'	Función de pérdida para clasificación multiclase con etiquetas enteras.
	metrics=['accuracy']	Precisión utilizada como métrica principal.
	epochs=100	Número total de épocas.
	batch_size=32	Tamaño del lote de datos por iteración de entrenamiento.
SVM	kernel='poly'	Kernel polinomial para clasificación con fronteras no lineales.
	C=10	Parámetro de regularización.
	probability=True	Habilita predicción de probabilidades además de clases.
Árbol de decisión	max_depth=30	Profundidad máxima del árbol para evitar sobreajuste.
	random_state=42	Semilla para garantizar resultados reproducibles.
Random Forest	n_estimators=100	Número total de árboles en el bosque.
	max_depth=None	Sin límite de profundidad para los árboles.
	random_state=42	Semilla para obtener resultados reproducibles.
	n_jobs=-1	Utiliza todos los núcleos disponibles del CPU para entrenamiento.

Figura 34: Parámetros del entrenamiento de los modelos de Machine Learning

5.2.1. Pseudocódigos de modelos de Machine Learning

: Entrenar Modelo RNN

Input: X : Secuencias de entrada, Y : Etiquetas objetivo, H :
Hiperparámetros (tasa de aprendizaje, épocas, tamaño de lote)

Output: Modelo RNN entrenado

```
1 Inicializar pesos y estado oculto  $h = 0$ ;  
2 for cada época do  
3   for cada ejemplo de entrenamiento  $(x_t, y_t)$  do  
4     for cada paso de tiempo  $t$  do  
5        $h_t \leftarrow \text{activación}(W_x x_t + W_h h_{t-1} + b)$ ;  
6        $y_{pred} \leftarrow \text{capa\_de\_salida}(h_t)$ ;  
7       Calcular la pérdida entre  $y_{pred}$  y  $y_t$ ;  
8       Actualizar pesos usando retropropagación a través del tiempo  
        (BPTT);  
9 return modelo RNN entrenado;
```

Figura 35: Pseudocódigo del modelo RNN

: Entrenar Modelo LSTM/GRU

Input: Entrada preparada de forma [sujetos, pasos de tiempo, características], hiperparámetros (optimizador, tasa de aprendizaje, tamaño de lote)

Output: Modelo LSTM/GRU entrenado

```
1 Inicializar: Definir un número suficientemente alto de épocas;  
2 foreach elección de número de neuronas do  
3   foreach cantidad de réplicas do  
4     Entrenar el modelo, monitorear pérdida de entrenamiento;  
5     while pérdida de validación en época  $n + 1 \leq$  pérdida en  
      época  $n + 2$  o número máximo de épocas no alcanzado do  
6       Continuar entrenamiento;  
7       Evaluar modelo con datos de prueba;  
8       Calcular exactitud, sensibilidad, especificidad y AUC;  
9 Calcular media, mínimo, máximo y desviación estándar de las  
   métricas;  
10 Guardar resultados;
```

Figura 36: Pseudocódigo del modelo LSTM

```

: Entrenar SVM
Input:  $X$ : Vectores de características,  $Y$ : Etiquetas de clase,  $C$ :
        Parámetro de regularización,  $runs$ : Número de ejecuciones
Output: Modelo SVM
1 Inicializar la tasa de aprendizaje aleatoriamente;
2 for  $r \leftarrow 1$  to  $runs$  do
3   foreach  $i \in X$  do
4     if  $Y[i] \cdot (X[i] \cdot w) < 1$  then
5        $w \leftarrow w + \eta \cdot (X[i] \cdot Y[i] - 2 \cdot (1/runs) \cdot w);$ 
6     else
7        $w \leftarrow w + \eta \cdot (-2 \cdot (1/runs) \cdot w);$ 
8 return  $w$ ;

```

Figura 37: Pseudocódigo del modelo SVM

```

: Entrenar Árbol de Decisión
Input:  $D$ : Conjunto de datos, Características: Conjunto de
        atributos
Output: Modelo de árbol de decisión
1 if todas las muestras en  $D$  pertenecen a la misma clase then
2   return nodo hoja con esa clase;
3 if Características está vacío then
4   return nodo hoja con la clase mayoritaria;
5 Seleccionar la mejor característica  $F$  usando ganancia de
  información u otro criterio;
6 Crear un nodo de decisión sobre  $F$ ;
7 foreach valor  $v$  de la característica  $F$  do
8    $D_v \leftarrow$  subconjunto de  $D$  donde  $F = v$ ;
9   if  $D_v$  está vacío then
10    Adjuntar nodo hoja con la clase mayoritaria en  $D$ ;
11  else
12    Llamar recursivamente al algoritmo con  $D_v$  y
       $Características - \{F\}$ ;
13    Adjuntar resultado como nodo hijo;
14 return nodo de decisión;

```

Figura 38: Pseudocódigo del modelo Árboles de decisión

: Entrenar Random Forest

Input: N : Número de muestras bootstrap, M : Total de características, m : Tamaño del subconjunto, k : Siguiendo nodo

Output: Modelo de Bosque Aleatorio entrenado

```

1 for  $i \leftarrow 1$  to  $N$  do
2   Generar muestra bootstrap  $D_i$  del conjunto de datos;
3   while el árbol no esté completamente crecido do
4     Seleccionar aleatoriamente  $m$  características de  $M$ ;
5     Encontrar la mejor división usando el subconjunto de
      características y determinar el nodo  $k$ ;
6     Dividir el árbol en el nodo  $k$ ;
7   Entrenar árbol  $T_i$  con  $D_i$ ;
8 Usar los  $N$  árboles para hacer predicciones mediante votación
   mayoritaria;
9 return modelo de Bosque Aleatorio final;

```

Figura 39: Pseudocódigo del modelo Random Forest

5.2.2. Resultados del entrenamiento de los modelos




Figura 40: Matriz de confusión y métricas del modelo RNN




Figura 41: Matriz de confusión y métricas del modelo LSTM




Figura 42: Matriz de confusión y métricas del modelo SVM




Figura 43: Matriz de confusión y métricas del modelo Árboles de decisión




Figura 44: Matriz de confusión y métricas del modelo Random Forest

Con base en los resultados obtenidos para realizar la predicción meteorológica mediante los modelos de Machine Learning, se obtuvieron los siguientes resultados para el Accuracy de cada modelo evaluado.

Modelo	Accuracy
SVM	39.69%
RNN	63.92%
LSTM	66.65%
Árboles de decisión	92.18%
Random Forest	93.03%

Tabla 20: Resumen del desempeño los modelos

Además del valor de los valores del Accuracy en cada modelo, se puede comprobar el desempeño de los modelos con base en las matrices de confusión. Las matrices de confusión en las que se observa una mayoría de datos dentro de la diagonal principal son las correspondientes a los modelos de Árboles de decisión y al modelo de Random Forest (Figura 43 y Figura 44 respectivamente). Por otro lado, en la matriz de confusión del modelo de SVM (Figura 42) se presentan valores más dispersos, lo que representa un bajo desempeño en la clasificación de los datos.

5.3. Evaluación de Algoritmos Bioinspirados

Según [45], las recomendaciones de algoritmos bioinspirados para resolver el Problema del Viajante (TSP, por sus siglas en inglés) incluyen los Algoritmos Genéticos (AG), la Optimización por Enjambre de Partículas (PSO), el Recocido Simulado (RS) y la Búsqueda Tabú (BT), todos ellos presentados en la sección 2.1.1.2 de este trabajo.

Aunque algoritmos heurísticos clásicos como Dijkstra o A* pueden brindar soluciones eficientes al TSP, estos no incorporan de forma nativa mecanismos de penalización tan sofisticados como los que ofrecen los algoritmos bioinspirados (mencionados en la sección 2.1.1.5). En nuestra propuesta, la gestión de penalizaciones constituye un componente fundamental para integrar variables meteorológicas en la optimización de rutas, razón por la cual se descartó el uso de estas heurísticas clásicas, optando en su lugar por los algoritmos bioinspirados antes mencionados.

A continuación, se presentan, los pseudocódigos de los algoritmos bioinspirados junto con una breve descripción de sus parámetros y pasos básicos. Estos esquemas servirán como guía para su implementación y posterior análisis comparativo:

5.3.1. Pseudocódigos de algoritmos bioinspirados

Algorithm 1 Algoritmo Genético para Rutas

```
1: Input: Tamaño de población  $N$ , generaciones  $G$ , probabilidad de cruce  $p_c$ ,  
   probabilidad de mutación  $p_m$   
2: Output: Mejor ruta encontrada  
3: function GA( $N, G, p_c, p_m$ )  
4:   Inicializar población:  
5:   for  $i \leftarrow 1$  to  $N$  do  
6:     Generar ruta aleatoria  $\text{ind}_i$   
7:   end for  
8:    $\text{gbest} \leftarrow \arg \min_i \text{fitness}(\text{ind}_i)$   
9:   for  $g \leftarrow 1$  to  $G$  do  
10:    (a) Evaluar fitness  
11:    for  $i \leftarrow 1$  to  $N$  do  
12:       $\text{fitness}_i \leftarrow \text{distancia}(\text{ind}_i) + \text{penalización}(\text{ind}_i)$   
13:    end for  
14:    (b) Selección por torneo  
15:     $P \leftarrow \text{torneo}(\{\text{ind}_i\}, N)$   
16:    (c) Cruzamiento y mutación  
17:     $Q \leftarrow \{\}$   
18:    for cada par  $(p_1, p_2)$  en  $P$  do  
19:      if  $\text{rand}() < p_c$  then  
20:         $(c_1, c_2) \leftarrow \text{cruce}(p_1, p_2)$   
21:      else  
22:         $(c_1, c_2) \leftarrow (p_1, p_2)$   
23:      end if  
24:      if  $\text{rand}() < p_m$  then  
25:         $c_1 \leftarrow \text{mutar}(c_1)$   
26:      end if  
27:      if  $\text{rand}() < p_m$  then  
28:         $c_2 \leftarrow \text{mutar}(c_2)$   
29:      end if  
30:       $Q \leftarrow Q \cup \{c_1, c_2\}$   
31:    end for  
32:    (d) Reemplazo con elitismo  
33:     $Q \leftarrow Q \cup \{\arg \min_i \text{fitness}(\text{ind}_i)\}$   
34:     $\{\text{ind}_i\} \leftarrow \text{mejores } N \text{ individuos de } Q$   
35:    Actualizar  $\text{gbest}$  si corresponde  
36:  end for  
37:  return  $\text{gbest}$   
38: end function
```

Figura 45: Pseudocódigo algoritmo genético

Algorithm 2 PSO para Rutas (Implementación basada en swaps)

```
1: Input:  $N, G, \omega, p_p, p_g$ 
2: Output: Mejor ruta gbest

3: function PSO( $N, G, \omega, p_p, p_g, m$ , heurística)
4:   Inicializar enjambre con rutas aleatorias
5:   for cada partícula  $i$  do
6:      $pbest_i \leftarrow ruta_i$ 
7:      $fitness\_pbest_i \leftarrow calcular\_fitness(ruta_i)$ 
8:   end for
9:   Ordenar enjambre por fitness
10:   $gbest \leftarrow pbest_1$ 
11:  for  $g \leftarrow 1$  to  $G$  do
12:    for cada partícula  $i$  do
13:      Clonar ruta actual  $ruta_{temp}$ 
14:      Aplicar swaps de inercia con probabilidad  $\omega$ 
15:      Generar swaps candidatos comparando con  $pbest$  y  $gbest$ 
16:      Seleccionar mejores swaps por posición (maximizando  $p_p/p_g$ )
17:      Aplicar swaps seleccionados con sus probabilidades
18:      Actualizar  $pbest_i$  si mejora el fitness
19:    end for
20:    Ordenar enjambre por fitness
21:    Actualizar  $gbest$  si  $pbest_1$  es mejor
22:  end for
23:  return  $gbest$ 
24: end function
```

Figura 46: Pseudocódigo PSO

Algorithm 3 Recocido Simulado

```
1: Input: Número de generaciones  $G$ , tasa de enfriamiento  $\alpha$ , temperatura  
   final  $T_{\min}$ , vecinos máximos  $V_{\max}$   
2: Output: Mejor solución encontrada  
3: function SA( $G, \alpha, T_{\min}, V_{\max}$ )  
4:   Inicializar:  
5:   Generar solución aleatoria  $S_{\text{actual}}$   
6:    $T \leftarrow T_{\text{alta}}$   
7:    $S_{\text{mejor}} \leftarrow S_{\text{actual}}$   
8:   while  $T > T_{\min}$  do  
9:     for  $v \leftarrow 1$  to  $V_{\max}$  do  
10:      Generar vecino  $S_{\text{vecino}}$  a partir de  $S_{\text{actual}}$   
11:       $\Delta E \leftarrow \text{costo}(S_{\text{vecino}}) - \text{costo}(S_{\text{actual}})$   
12:      if  $\Delta E < 0$  then  
13:         $S_{\text{actual}} \leftarrow S_{\text{vecino}}$   
14:        if  $\text{costo}(S_{\text{vecino}}) < \text{costo}(S_{\text{mejor}})$  then  
15:           $S_{\text{mejor}} \leftarrow S_{\text{vecino}}$   
16:        end if  
17:      else  
18:        Aceptar  $S_{\text{vecino}}$  con probabilidad  $\exp(-\Delta E/T)$   
19:      end if  
20:    end for  
21:     $T \leftarrow \alpha \cdot T$   
22:  end while  
23:  return  $S_{\text{mejor}}$   
24: end function
```

Figura 47: Pseudocódigo Recocido Simulado

Algorithm 4 Búsqueda Tabú

```
1: Input: Número de generaciones  $G$ , tenencia tabú  $L$ , umbral de estanca-  
   miento global  $U_g$ , umbral de estancamiento local  $U_l$ , vecinos máximos  $V_{\text{máx}}$   
2: Output: Mejor solución encontrada  
3: function TS( $G, L, U_g, U_l, V_{\text{máx}}$ )  
4:   Inicializar:  
5:   Generar solución inicial  $S_{\text{actual}}$   
6:   Inicializar lista tabú  $T \leftarrow \emptyset$   
7:    $S_{\text{mejor}} \leftarrow S_{\text{actual}}$   
8:    $C_g \leftarrow 0, \quad C_l \leftarrow 0$   
9:   for  $g \leftarrow 1$  to  $G$  do  
   (a) Generar vecinos no tabúes  
10:   $\mathcal{N} \leftarrow$  explorar  $V_{\text{máx}}$  vecinos excluyendo movimientos en  $T$   
   (b) Seleccionar mejor vecino  
11:   $S_{\text{vecino}} \leftarrow \arg \min_{S \in \mathcal{N}} \text{costo}(S)$   
   (c) Actualizar lista tabú  
12:  Registrar movimiento asociado a  $S_{\text{vecino}}$  en  $T$   
13:  if  $|T| > L$  then  
14:    Eliminar el elemento más antiguo de  $T$   
15:  end if  
   (d) Actualizar soluciones  
16:   $S_{\text{actual}} \leftarrow S_{\text{vecino}}$   
17:  if  $\text{costo}(S_{\text{actual}}) < \text{costo}(S_{\text{mejor}})$  then  
18:     $S_{\text{mejor}} \leftarrow S_{\text{actual}}$   
19:     $C_g \leftarrow 0$   
20:  else  
21:     $C_g \leftarrow C_g + 1$   
22:     $C_l \leftarrow C_l + 1$   
23:  end if  
   (e) Gestionar estancamiento  
24:  if  $C_l \geq U_l$  then  
25:    Aplicar perturbación aleatoria a  $S_{\text{actual}}$   
26:     $C_l \leftarrow 0$   
27:  end if  
28:  if  $C_g \geq U_g$  then  
29:    Reiniciar búsqueda desde  $S_{\text{mejor}}$   
30:     $C_g \leftarrow 0$   
31:  end if  
32: end for  
33: return  $S_{\text{mejor}}$   
34: end function
```

Figura 48: Pseudocódigo Búsqueda Tabú

Con base en lo revisado en el estado del arte, se presentan los resultados de evaluar los cuatro algoritmos aplicados a una versión simplificada del TSP en un contexto de 32 ciudades mexicanas (puntos de interés). Esta prueba, diseñada como un caso de estudio independiente al proyecto principal, tiene como objetivo principal minimizar la distancia total del recorrido entre las ciudades. Las distancias se calcularon utilizando las coordenadas geográficas de cada ubicación. Los algoritmos, implementados en lenguaje C, se ejecutaron 30 veces bajo tres configuraciones distintas: 100.000, 500.000 y 2.000.000 de evaluaciones, con el fin de analizar su escalabilidad y adaptabilidad en diferentes escalas computacionales.

Si bien el número de puntos de interés en esta prueba es menor al previsto en el problema central del proyecto, los resultados son fundamentales para entender el comportamiento de los algoritmos en un entorno controlado. Esta comparación permite identificar patrones de rendimiento, como la adaptabilidad a cargas computacionales variables o la capacidad para mantener soluciones estables, información crítica que servirá como base para seleccionar el algoritmo más equilibrado antes de escalarlo a desafíos de mayor complejidad o con restricciones adicionales.

Entre las métricas utilizadas para cuantificar el rendimiento de los algoritmos, se consideraron:

- Tiempo de ejecución: Medido en segundos, evalúa la eficiencia computacional. Se registraron los valores mínimo, máximo, promedio y la desviación estándar.
- Calidad de la solución: Determinada por la distancia mínima, máxima y promedio obtenida en las 30 ejecuciones, junto con la desviación estándar, que refleja la consistencia del algoritmo.
- Estabilidad del algoritmo: Calculada mediante el coeficiente de variación ($CV = \text{desviación estándar} / \text{media}$), donde valores cercanos a cero indican soluciones reproducibles y confiables.

Para garantizar una comparación justa, los algoritmos poblacionales (AG y PSO) ajustaron su número de evaluaciones mediante el producto entre el tamaño de la población y las generaciones, mientras que los algoritmos de trayectoria única (RS y BT) utilizaron el producto entre vecinos explorados y generaciones. Esta metodología aseguró que todos los algoritmos operaran bajo una carga computacional similar, priorizando la equidad en la evaluación.

Adicionalmente, se analizó la complejidad paramétrica de cada método. Los algoritmos poblacionales requieren ajustar múltiples parámetros, como tasas de mutación, cruce o inercia de partículas, lo que puede aumentar la dificultad de implementación. Por otro lado, los métodos de trayectoria única, como RS y BT, dependen de parámetros más intuitivos, como la tasa de enfriamiento o el tamaño de la lista tabú, simplificando su configuración.

En la Figura 49 se presenta la configuración de parámetros utilizada en los algoritmos de optimización evaluados. Para cada algoritmo se definieron múltiples configuraciones (indicadas mediante valores separados por punto y coma) con el fin de evaluar su desempeño bajo distintos escenarios de complejidad computacional.

Algoritmo	Parámetro	Descripción y valores
Genético	Tamaño de población: 200; 500; 1000	Número de individuos en la población (3 pruebas)
	Generaciones: 500; 1000; 2000	Número máximo de iteraciones (3 pruebas)
	Prob. de cruce: 0.8	Probabilidad de recombinación entre padres
	Prob. de mutación: 0.02	Probabilidad de alteración aleatoria en hijos
PSO	Tamaño de población: 200; 500; 1000	Número de partículas en el enjambre (3 pruebas)
	Generaciones: 500; 1000; 2000	Número máximo de iteraciones (3 pruebas)
	Prob. social: 0.7	Probabilidad de influencia de la mejor solución global
	Prob. cognitivo: 0.35	Probabilidad de influencia de la mejor solución personal
	Prob. de inercia: 0.3	Probabilidad de conservación de movimientos anteriores
Recocido Simulado	Generaciones: 10000; 20000; 80000	Ciclos totales de enfriamiento (3 pruebas)
	Tasa de enfriamiento: 0.95	Factor de reducción de temperatura (α)
	Temp. final: 1×10^{-3}	Temperatura mínima para detención
	Vecinos máx.: 10; 25; 25	Soluciones vecinas evaluadas por iteración (3 pruebas)
Tabú	Generaciones: 10000; 20000; 40000	Iteraciones totales del algoritmo (3 pruebas)
	Tenencia tabú: 7	Iteraciones que un movimiento permanece prohibido
	Umbral estanc. global: 0.1	Porcentaje de generaciones totales sin mejora para reinicio completo
	Umbral estanc. local: 0.05	Porcentaje de generaciones totales sin mejora para perturbación local
	Vecinos máx.: 10; 25; 50	Movimientos evaluados por iteración (3 pruebas)

Figura 49: Parámetros de algoritmos bioinspirados

5.3.2. Resultados obtenidos y análisis

5.3.2.1. Tiempos de Ejecución

A continuación, se presentan los gráficos comparativos de tiempos de ejecución obtenidos para cada algoritmo:



Figura 50: Comparación de los tiempos de ejecución de los algoritmos con 100,000 evaluaciones.




Figura 51: Comparación de los tiempos de ejecución de los algoritmos con 500,000 evaluaciones.




Figura 52: Comparación de los tiempos de ejecución de los algoritmos con 2,000,000 de evaluaciones.

Los resultados demuestran consistentemente que los algoritmos de búsqueda local (Búsqueda Tabú y Recocido Simulado) superan significativamente en eficiencia temporal a los métodos poblacionales (Algoritmo Genético y PSO) en todas las escalas de evaluación analizadas. Esta ventaja se manifiesta tanto en los promedios de ejecución como en las menores desviaciones estándar, indicando no solo mayor rapidez sino también estabilidad operacional entre iteraciones.

En el escenario más demandante (2,000,000 de evaluaciones), la Búsqueda Tabú registra un tiempo medio de 0.261 s (desviación 0.013 s), mientras el Recocido Simulado alcanza 0.344 s (desviación 0.012 s). Estos valores contrastan radicalmente con los 4.018 s del Algoritmo Genético (desviación 0.085 s) y los 1.255 s del PSO (desviación 0.037 s). La diferencia se acentúa en los métodos poblacionales debido a la sobrecarga computacional propia del manejo de múltiples soluciones simultáneas, limitando su uso en entornos que demandan rapidez.

En el nivel de 500,000 evaluaciones, la Búsqueda Tabú registra un tiempo promedio de 0.067 s con una desviación mínima de 0.002 s, seguida de cerca por el Recocido Simulado que alcanza 0.086 s (desviación 0.005 s). Estos valores contrastan marcadamente con los métodos poblacionales: el Algoritmo Genético requiere 0.995 s (desviación 0.014 s) y el PSO 0.319 s (desviación 0.014 s). Al reducir el número de evaluaciones a 100,000, la diferencia temporal se mantiene: la Búsqueda Tabú opera en 0.0155 s y el Recocido Simulado en 0.0193 s, mientras que el Algoritmo Genético y el PSO muestran tiempos significativamente mayores (0.1807 s y 0.0702 s respectivamente).

Algoritmo	Tiempo medio (s)	Desviación estándar (s)
Búsqueda Tabú	0.261	0.013
Recocido Simulado	0.344	0.012
Algoritmo Genético	4.018	0.085
PSO	1.255	0.037

Tabla 21: Rendimiento en tiempo de ejecución (2 000 000 evaluaciones)

5.3.2.2. Calidad de las Soluciones

Seguidamente, se incluyen los gráficos que ilustran la calidad de las soluciones alcanzadas:



Figura 53: Comparación de la calidad de la solución de los algoritmos con 100,000 evaluaciones.



Figura 54: Comparación de la calidad de la solución de los algoritmos con 500,000 evaluaciones.



Figura 55: Comparación de la calidad de la solución de los algoritmos con 2,000,000 de evaluaciones.

Los resultados demuestran de manera contundente que los métodos de búsqueda local (Búsqueda Tabú y Recocido Simulado) superan significativamente a los algoritmos poblacionales (Algoritmo Genético y PSO) en calidad de solución, demostrando mayor precisión y consistencia en todas las escalas de evaluación. Esta superioridad se refleja tanto en las distancias medias más cercanas al óptimo teórico como en las desviaciones estándar notablemente menores, reflejando una convergencia estable y confiable durante las ejecuciones.

En el escenario más demandante (2,000,000 de evaluaciones), la Búsqueda Tabú alcanza una distancia media de 8,820.03 km con una desviación prácticamente nula (0.00 km), igualando el óptimo global. El Recocido Simulado, por su parte, registra una distancia de 8,832.45 km con una desviación mínima de 15.47 km, demostrando un desempeño muy similar al de Búsqueda Tabú. Por otro lado, los métodos poblacionales muestran un desempeño claramente inferior: el Algoritmo Genético obtiene una distancia de 10,626.65 km (desviación de 797.96 km) y el PSO 10,821.15 km (desviación de 753.76 km).

Al reducir las evaluaciones a 500,000, la ventaja de los métodos locales se mantiene: la Búsqueda Tabú obtiene una distancia de 8,881.31 km (desviación de 28.54 km) y el Recocido Simulado de 8,868.11 km (desviación de 49.80 km), ambos conservando proximidad al óptimo global. Mientras tanto, los algoritmos poblacionales muestran un deterioro significativo: el Algoritmo Genético se sitúa en 10,558.61 km (desviación de 799.26 km) y el PSO en 11,495.92 km (desviación de 923.70 km), ampliando la diferencia a casi 2,000 unidades respecto a los métodos locales. Este patrón subraya la capacidad de las técnicas de búsqueda local para aprovechar al máximo los recursos computacionales disponibles, incluso en condiciones restrictivas.

Incluso en la escala más reducida (100,000 evaluaciones), el Recocido Simulado reafirma su eficacia con una distancia de 8,943.46 km (desviación de 84.71 km), superando a la Búsqueda Tabú (9,554.91 km, desviación de 104.73 km), sugiriendo que RS gestiona de mejor manera las fases iniciales de exploración a comparación de BT. Por otro lado, los métodos poblacionales acentúan su debilidad: el Algoritmo Genético registra 11,428.11 km (desviación de 979.88 km) y el PSO 12,656.70 km (desviación de 1,081.65 km), evidenciando una alta dependencia a un gran número de evaluaciones para lograr soluciones aceptables.

La combinación de precisión y estabilidad establece a los métodos locales como recursos clave para problemas que exigen resultados confiables y reproducibles, incluso en escenarios con recursos computacionales limitados.

5.3.2.3. Estabilidad de soluciones

Finalmente, se muestran los gráficos comparativos de estabilidad de los algoritmos:




Figura 56: Estabilidad de los algoritmos durante el total de evaluaciones

Los resultados revelan una clara superioridad de los métodos de búsqueda local en estabilidad operacional. Con 2,000,000 de evaluaciones, la Búsqueda Tabú demuestra un CV de 0.0, evidenciando que todas las ejecuciones arrojan exactamente el mismo resultado. Esta gran consistencia la posiciona como ideal para aplicaciones que exigen resultados fiables. El Recocido Simulado, aunque ligeramente más variable, mantiene un CV de 0.18, confirmando una fluctuación mínima alrededor de su media y reforzando su confiabilidad en entornos demandantes.

En contraste, los algoritmos poblacionales exhiben una mayor variabilidad. Aun con el máximo de evaluaciones, el Algoritmo Genético registra un CV de 7.51 y el PSO un CV de 6.97, valores que reflejan inconsistencias significativas entre ejecuciones. Esta dispersión sugiere que, aunque ocasionalmente alcancen soluciones destacadas, su desempeño depende críticamente de factores como la configuración de parámetros (tasas de mutación, tamaño de población) o la aleatoriedad inicial. En contextos donde la robustez ante perturbaciones es importante, esta imprevisibilidad representa una limitación.

Al reducir las evaluaciones a 500,000, los resultados son similares: los métodos locales conservan CV bajos (0.56 para Recocido Simulado y 0.32 para Búsqueda Tabú), mientras los poblacionales continúan con coeficientes elevados (7.5–8.5). Incluso en la escala más reducida (100,000 evaluaciones), la diferencia en estabilidad sigue siendo amplia: aunque los CV locales aumentan levemente (0.95 para Recocido y 1.10 para Tabú), estos valores siguen siendo mucho más bajos que los de los algoritmos poblacionales, cuyos CV se mantienen entre 8.5 y 9.0.

Este análisis del coeficiente de variación confirma lo que ya se había observado: los métodos de búsqueda local no solo superan en precisión de solución y velocidad de ejecución a los algoritmos poblacionales, sino que además ofrecen una fiabilidad superior en este problema.

Algoritmo	Distancia media (km)	Desviación estándar (km)	CV (%)
Búsqueda Tabú	8 820.03	0.00	0.00
Recocido Simulado	8 832.45	15.47	0.18
Algoritmo Genético	10 626.65	797.96	7.51
PSO	10 821.15	753.76	6.97

Tabla 22: Rendimiento en distancia y estabilidad (2 000 000 evaluaciones)

5.4. Selección de tecnologías

5.4.1. Selección del algoritmo bioinspirado

Tras la realización del análisis comparativo de los algoritmos, la decisión final recae en el algoritmo de Recocido Simulado. Aunque la búsqueda Tabú obtuvo resultados ligeramente mejores ($\approx 8,820$ de media frente a $\approx 8,832$ de RS) y fue totalmente estable ($CV=0.0$ frente a 0.18), RS destaca por su simplicidad operativa y su menor carga paramétrica.

BT necesita calibrar cinco parámetros clave: el tiempo que cada movimiento permanece en la lista tabú, cuántos vecinos se prueban en cada iteración, los umbrales de estancamiento global y actual para fomentar la exploración, y el número total de iteraciones. Esta combinación de ajustes no solo incrementa el tiempo de configuración, sino que exige experiencia para evitar desequilibrios entre exploración y explotación. En cambio, RS funciona con cuatro parámetros más intuitivos: tasa de enfriamiento, criterio de parada (límite de iteraciones o temperatura mínima), número máximo de vecinos, y un porcentaje fijo de soluciones aceptadas por cada paso. La sintonización de estos parámetros resulta más ágil, reduciendo horas de experimentación sin comprometer la calidad de las soluciones.

La ventaja de RS se basa principalmente en su gran flexibilidad. En su fase inicial de alta temperatura, el algoritmo explora de forma dinámica diversas rutas, evitando convergencias prematuras. A medida que el sistema se enfría, prioriza el refinamiento local de las soluciones más prometedoras, acercándose progresivamente al óptimo global incluso bajo restricciones adicionales. Este comportamiento no solo optimiza la búsqueda, sino que se traduce en eficiencia temporal: con 2 millones de evaluaciones, RS completa el proceso en $\approx 0,34$ segundos, un tiempo competitivo para sistemas que exigen rapidez. Además, su adaptabilidad brilla en contextos con recursos limitados: incluso con solo 100 000 evaluaciones, genera soluciones cercanas al óptimo (media ≈ 8943), un factor que toma relevancia en entornos computacionalmente restrictivos.

La estabilidad perfecta de BT, pierde relevancia ante su complejidad operativa. La necesidad de gestionar múltiples parámetros interdependientes (como los umbrales de estancamiento o la tenencia tabú) introduce rigidez y riesgos de sobreajuste, especialmente en escenarios con entornos cambiantes como lo puede ser la penalización arbitraria en las rutas. RS, por otro lado, combina eficiencia y practicidad: su configuración sencilla (con pocos ajustes) y un mecanismo automático de balance para equilibrar la búsqueda de nuevas soluciones con el refinamiento de las existentes facilitan su uso en proyectos reales. Esta combinación de velocidad, adaptabilidad y facilidad de implementación lo posiciona como la opción óptima, no por superioridad numérica, sino por su capacidad para integrarse en sistemas donde la agilidad técnica y la escalabilidad son prioritarias. La elección refleja un equilibrio entre precisión aceptable, eficiencia operacional y garantía de que funcione bien incluso en escenarios cambiantes.

5.4.2. Selección del modelo de Machine Learning

El modelo de Machine Learning integra uno de los elementos más importantes del sistema, ya que es el responsable de realizar las predicciones de las condiciones meteorológicas. Estos modelos se entrenan antes de su integración con el sistema, para que el modelo ya se encuentre optimizado para responder a las solicitudes del sistema.

Durante el análisis de los resultados obtenidos por los distintos modelos implementados se implementaron cinco modelos distintos para la clasificación, Redes neuronales recurrentes, Red de memoria a corto-largo plazo, Máquinas de soporte vectorial, Árboles de decisión y Random Forest. Los resultados obtenidos muestran desempeños variables, el modelo para SVM alcanzó un 39.69% de accuracy, mientras que LSTM obtuvo un 67.17%, y Random Forest un 93.11%, estos valores se pueden comprobar de igual manera al observar las matrices de confusión obtenidas para cada modelo. Por lo cual, dado su desempeño y capacidad de clasificación, el modelo de Random Forest se considera la opción más adecuada para realizar las predicciones de condiciones meteorológicas del sistema propuesto.

5.4.3. Selección de la API meteorológica

La API meteorológica es el método por el cual se obtienen los datos para realizar la predicción con el modelo de Machine Learning, por lo cual la elección de la API que proporcione los datos exactos de la hora de registro, temperatura, punto de rocío, humedad, dirección del viento, dirección y velocidad del viento, conlleva una gran importancia, debido a que sin estos datos en específico el modelo no puede realizar la predicción meteorológica que servirá para realizar la penalización del algoritmo bioinspirado.

La página de Weather Underground cuenta con una API que permite obtener los datos necesarios para realizar la predicción con el modelo de Machine Learning, pero para acceder a estos valores es necesario que exista una estación meteorológica en las cercanías del área que proporcione estos valores. En el caso del Estado de México, la cantidad de estaciones es menor en comparación con otras entidades federativas, además la ubicación de estas estaciones no está bien distribuida en todo el estado, lo limita la obtención de los datos para los puntos de interés del sistema. En la Figura 57 se muestran los datos obtenidos de la solicitud a la API de Weather Underground.

```
Estación ID: IVALLE282
Localidad: Valle de Bravo

Fecha y hora local: 2025-05-13 00:03:17
Temperatura: 20 °C
Punto de rocío: 12 °C
Humedad: 60 %
Dirección del viento: 168
Velocidad del viento: 0 km/h
```

Figura 57: Datos obtenidos de la API de Weather Underground

Por otro lado, WeatherAPI permite realizar solicitudes indicando únicamente las coordenadas geográficas, lo cual facilita la integración con el sistema, al solo tener que indicar las coordenadas del punto de interés para realizar su predicción meteorológica. En la Figura 58 se muestran los datos obtenidos mediante Weather API, los cuales representan las variables necesarias para entrenar el modelo de Machine Learning.

```
Coordenadas: 19.176663, -100.166665
Localidad: El Cerrillo (San Jose El Cerrillo)

Fecha y hora local: 2025-05-12 23:12
Temperatura: 18.8 °C
Punto de rocío: 9.2 °C
Humedad: 53 %
Dirección del viento: ENE
Velocidad del viento: 4.3 km/h
```

Figura 58: Datos obtenidos de Weather API

Esta comparativa demuestra que WeatherAPI es una opción más eficiente para la obtención de los datos meteorológicos en los puntos de interés del sistema.

6. Alcance del sistema

El alcance del sistema permite definir cuáles son las características, funcionalidades y limitaciones del mismo, con el objetivo identificar las restricciones que pueden poner en riesgo el correcto funcionamiento del proyecto.

1. Datos Históricos:

- Los datos históricos para el entrenamiento de los modelos de Machine Learning corresponderán a las condiciones meteorológicas diarias registradas en el Estado de México de los años 2022 a 2024.

2. Algoritmos Bioinspirados:

- Se implementarán algoritmos bioinspirados para la optimización de rutas, teniendo en cuenta las condiciones meteorológicas predichas por el modelo de machine learning y las distancias del recorrido.

3. Machine Learning:

- El modelo de machine learning se enfocarán en realizar las predicciones meteorológicas de los climas que afectan el sistema de logística de las empresas del Estado de México.

4. Desarrollo e Integración:

- Se desarrollará un modelo de Machine Learning predictivo basado en los datos históricos obtenidos de años anteriores.
- Este modelo, junto con los algoritmos bioinspirados, será integrado en una interfaz web.
- La interfaz web permitirá a los usuarios finales visualizar los resultados de su ruta optimizada en un mapa resaltando sus puntos de interés y las condiciones climatológicas.
- El sistema no contara con una navegación en tiempo real siguiendo la ruta del usuario.
- Después de que se genere la ruta original con los puntos y condiciones climatológicas establecidos no se generara una nueva ruta ante el cambio de los elementos antes mencionados.

7. Estudio de factibilidad

En este apartado se incluyen los costos estimados para llevar a cabo el desarrollo del prototipo del sistema, contemplando los elementos de hardware necesarios para el desarrollo del proyecto, los recursos humanos y los costos asociados a la infraestructura.

7.1. Recursos humanos

Los recursos humanos corresponden a las personas que se encargaran de implementar los algoritmos necesarios para la optimización de rutas, y al encargado para el desarrollo de la interfaz donde los usuarios puedan interactuar para optimizar sus rutas.

Cantidad	Rol	Descripción	Salario mensual	Subtotal (10 meses)	Total
2	Desarrollador IA	Responsable de desarrollar e implementar los modelos de machine learning y algoritmos bioinspirados.	22,500	225,000	450,000
1	Desarrollador web	Encargado del desarrollo de la interfaz web para los usuarios.	14,000	140,000	140,000
				Total	590,000

Tabla 23: Recursos humanos

7.2. Recursos de hardware

En los recursos de hardware se listan las tecnologías necesarias para llevar a cabo realizar el proyecto. Para las computadoras portátiles se estima su costo individual de \$20,000 pesos mexicanos (MXN), la depreciación de los equipos de cómputo es de 30% anual, por tanto, la depreciación anual por equipo es de \$6,000 MXN, pero al considerar solo 10 meses para el desarrollo del proyecto el costo de la depreciación del equipo es de solo \$5,000 MX. En el caso de Visual Studio Professional se contempla una suscripción mensual por usuario de \$45 dólares americanos (USD), haciendo la conversión de USD a MXN tomando el cambio a \$20.29 MXN, se tiene una suscripción mensual de \$912.92 MXN por usuario. Para la API meteorológica se contempla su uso para cinco meses con un costo de \$4 USD mensuales, obteniendo un costo de \$81.16 MXN al mes.

Cantidad	Nombre	Descripción	Costo	Subtotal (10 meses)
3	Computadora portátil con sistema operativo Windows 11	Equipos para el desarrollo y documentación del proyecto.	5,000	15,000
3	Visual Studio Professional	Entorno de desarrollo integrado.	912.92	27,387.60
3	Python	Lenguaje de programación.	0	0
1	MySQL	Sistema gestor de base de datos.	0	0

1	Microsoft 365 Familia	Librerías para la documentación.	2,299	2,299
1	WeatherAPI	API meteorológica para la obtención de datos para el modelo de Machine Learning.	81.16	811.60
1	Servicio de Hosting	Alojamiento en línea para hospedar la página web del proyecto.	500-750	625
			Total aprox.	46,123.20

Tabla 24: Recursos de hardware

7.3. Infraestructura

La infraestructura corresponde a los servicios básicos indispensables para que se pueda poner en operación el lugar donde se planea trabajar a lo largo del periodo para realizar el proyecto, estos elementos incluyen los servicios de internet, luz y agua. El desglose que se presenta a continuación contempla los costos de manera bimestral que es manera en que se pagan los servicios de luz y agua en la Ciudad de México.

Nombre	Descripción	Costo bimestral	Subtotal (10 meses)
Servicio de luz	Costo bimestral estimado por el pago de servicios de electricidad.	180	900
Servicio de agua	Costo bimestral estimado por el pago del servicio de agua potable.	950	4750
Servicio de internet	Servicio de internet de 100 Megas.	798	3990
		Total aprox.	9640

Tabla 25: Infraestructura

Después de analizar los costos para cada uno de los aspectos necesarios para realizar el proyecto, en la Tabla 26 se muestra el costo total estimado del proyecto a lo largo de 10 meses.

Nombre	Costo
Costo recursos humanos	\$ 590,000 MXN
Costo recursos de hardware	\$ 46,123.20 MXN
Costo de infraestructura	\$ 9,640 MXN
Costo Total	\$ 645,763.20 MXN

Tabla 26: Costo total estimado del proyecto

8. Implementación de la herramienta LogistiClima

Para iniciar con la implementación del sistema descrito previamente, se optó por dividir el trabajo en dos componentes principales, con el propósito de desarrollar ambas de forma simultánea y establecer una separación de responsabilidades dentro del sistema.

El frontend que se centró en la interfaz de usuario, la cual representa la parte visual e interactiva mediante la cual el usuario podrá comunicarse con el sistema. Por otra parte, el backend que integró el algoritmo bioinspirado responsable de la optimización de rutas, así como el modelo de Machine Learning destinado a la predicción meteorológica, tal como se explicó en capítulos anteriores.

El objetivo de esta etapa fue desarrollar una primera versión funcional del sistema, pasando de programas aislados a un flujo de trabajo estructurado que permitiera calcular rutas y visualizarlas a través de la interfaz de usuario, como punto de partida para la ejecución de las primeras pruebas del prototipo.

8.1. Desarrollo del backend del sistema

8.1.1. Preparación de los datos de las Naves Industriales

El primer paso del desarrollo consistió en obtener las coordenadas geográficas correspondientes a las 219 naves industriales previamente investigadas. Para ello, se partió de las direcciones físicas recopiladas y se aplicó un procedimiento de geocodificación, el cual permitió transformar dichas direcciones en sus equivalencias geoespaciales, expresadas en valores de latitud y longitud.

Este procedimiento resultó ser una parte fundamental del trabajo, ya que disponer de coordenadas precisas nos permitirá obtener las condiciones meteorológicas del lugar y, sobre todo, asegurar la correcta representación y trazado de rutas dentro del sistema.

Como resultado de esta etapa, se generó un archivo en formato CSV que concentra los datos relevantes: el nombre de la nave industrial, la dirección completa y sus coordenadas geográficas exactas. Este archivo sirvió como base para posteriores análisis y modelado.

Posteriormente, se creó un script de preprocesamiento en Python con el propósito de limpiar y estructurar la información contenida en el archivo CSV original. Esto permitió eliminar registros redundantes o incompletos, así como de conservar únicamente los campos más significativos para el proyecto: nombre de la nave, latitud y longitud.

Durante este mismo proceso se aprovechó para ordenar alfabéticamente los registros según el nombre de cada nave industrial. Esta organización facilita la gestión de los datos dentro del sistema y mejora la presentación en las vistas de usuario, permitiendo una búsqueda y visualización estructurada. En la Figura 59 se muestran

los primeros registros del CSV original que contiene los datos completos de las naves industriales, mientras que en la Figura 60 se muestra el CSV modificado, el cual lleva el formato previamente descrito.

N	PARQUE INDUSTRIAL	MUNICIPIO	DIRECCION	ADMINISTRACION	LATITUD	LONGITUD
1	PARQUE INDUSTRIAL POLO INN	POLOTTILÁN	CALLE ABEL MEJA NO. 8, CARR. PALMILLAS TOLUCA KM. 126, SAN ANTONIO ESCOBEDO, POLOTTILÁN MEXICO	PRIVADO	20.253056	-99.915000
2	PARQUE INDUSTRIAL JILOTEPEC	JILOTEPEC	KM. 3 CARR. JILOTEPEC SOVANIQUILPAN A UN COSTADO DE LA AUTOPISTA ARCO NORTE, EL XHITEY, JILOTEPEC, MÉXICO, C.P. 54240.	MUNICIPALIZADO	19.979619	-99.528053
3	PARQUE INDUSTRIAL EL CONVENTO	TEPOTZOTLÁN	ENTRE AV. CIRCUNVALACIÓN, AV DEL CONVENTO Y AV DE LA INDUSTRIA, COL EL TREBOL, TEPOTZOTLÁN, MEXICO C.P.54614.	PRIVADO	19.715366	-99.203221
4	PARQUE INDUSTRIAL EL CONVENTO II	TEPOTZOTLÁN	LIBRAMIENTO SUR S/N, COL. TEXCOCO TEPOTZOTLÁN, MEXICO C.P. 54630	PRIVADO	19.704083	-99.215111
5	PARQUE INDUSTRIAL TREBOL	TEPOTZOTLÁN	AUTOPISTA MEXICO QUERETARO ENTRE RÍO TEPOTZOTLÁN Y AV INDUSTRIA, COL. EL TREBOL, TEPOTZOTLÁN, MEXICO, C. P. 54614.	MUNICIPALIZADO	19.721556	-99.203739
6	PARQUE INDUSTRIAL PROLOGIS PARK CEDROS	TEPOTZOTLÁN	ENTRE LA AUTOPISTA MÉXICO QUERÉTARO Y EL CAMINO A COYOTEPEC SOBRE EL RIO CUAUTITLÁN, TEXCOCO, COL. CEDROS, TEPOTZOTLÁN, MÉXICO, C.P. 54605.	PRIVADO	19.707499	-99.205740
7	PARQUE INDUSTRIAL PROLOGIS CARRIZAL	TEPOTZOTLÁN	AV. DE LA CIRCUNVALACIÓN NO. 1, COL. EL TREBOL, TEPOTZOTLÁN, MÉXICO, C. P. 54605.	PRIVADO	19.713317	-99.198608
8	MEGAPARK	TEPOTZOTLÁN	CARR. PUENTE GRANDE LAS ANIMAS S/N, LAS ANIMAS, TEPOTZOTLÁN, MÉXICO, C.P. 54616.	PRIVADO	19.736205	-99.206204
9	TEPOZPARK IV	TEPOTZOTLÁN	ANTIGUO CAMINO A COYOTEPEC N° 97, COLONIA RICARDO FLORES MAGON, TEPOTZOTLÁN, ESTADO DE MÉXICO	PRIVADO	19.731760	-99.212910
10	CPA LOGISTIC CENTER TEPOTZOTLÁN	TEPOTZOTLÁN	AVENIDA DE LA INDUSTRIA, P. 1, EL CONVENTO, TEPOTZOTLÁN, MÉXICO.	PRIVADO	19.715824	-99.205511

Figura 59: CSV original con los datos de las naves industriales.

nombre	latitud	longitud
Advance Tepotzotlán I	19.718776	-99.2113516
Advance Tepotzotlán II	19.706043	-99.227541
Advance Toluca	19.296003	-99.575542
Atizapan Park	19.539376	-99.285799
Atizapark	19.583509	-99.225772
Centro Industrial Tlalnepantla	19.541366	-99.203062
Centro Logístico Puente Grande	19.819191	-99.205352
Ceylanpark	19.508272	-99.175993
Citypark	19.555128	-99.192462
Coacalco Park	19.622174	-99.077862

Figura 60: CSV después del preprocesamiento.

8.1.2. Implementación del algoritmo de optimización de rutas

Una vez estandarizada la estructura de los datos, se realizaron modificaciones en el módulo del algoritmo bioinspirado, adaptándolo a la nueva información de las naves industriales. Para el diseño inicial del prototipo, se propuso una matriz de distancias basada en la fórmula de Haversine; esta aproximación mide la distancia como una “línea recta” tomando en consideración la curvatura de la tierra. Esta primera propuesta permitió validar la lógica general del sistema y ajustar los parámetros necesarios. Los primeros registros de las distancias obtenidas por este método se muestran en la Figura 61.

1	0	50.6	95.4	95.3	95	95.8	95.9	93.7	93.5	95.2
2	50.6	0	44.9	44.8	44.4	45.3	45.4	43.2	43	44.7
3	95.4	44.9	0	1.77	0.69	0.91	0.53	2.34	2.09	0.25
4	95.3	44.8	1.77	0	2.28	1.05	2.01	3.69	3.09	1.65
5	95	44.4	0.69	2.28	0	1.58	1.06	1.65	1.49	0.66
6	95.8	45.3	0.91	1.05	1.58	0	0.99	3.19	2.8	0.93
7	95.9	45.4	0.53	2.01	1.06	0.99	0	2.67	2.54	0.77
8	93.7	43.2	2.34	3.69	1.65	3.19	2.67	0	0.86	2.27
9	93.5	43	2.09	3.09	1.49	2.8	2.54	0.86	0	1.93
10	95.2	44.7	0.25	1.65	0.66	0.93	0.77	2.27	1.93	0

Figura 61: Primeros registros del CSV utilizando la matriz de distancias por formula de Haversine

En una segunda etapa de desarrollo, se sustituyó la matriz de distancias basada en la fórmula de Haversine por una matriz construida a partir de las distancias reales por carretera. Esta nueva matriz fue generada utilizando la API de enrutamiento de OpenStreetMap, lo que permitió incorporar trayectos cercanos a la realidad geográfica y vial, proporcionando una base representativa para evaluar el rendimiento del algoritmo de optimización. En la Figura 62 se muestran los primeros 10 registros de las distancias calculadas por carreteras.

1	0.0	64.62	112.57	113.43	113.54	113.49	112.7	115.3	114.11	112.77
2	65.0	0.0	54.81	55.66	55.77	55.72	54.94	57.53	56.35	55.01
3	112.56	55.79	0.0	2.7	0.97	2.76	1.0	3.24	3.52	0.72
4	113.8	57.03	2.48	0.0	3.44	2.39	2.6	4.99	3.78	2.68
5	113.37	56.6	1.07	3.51	0.0	3.57	1.81	2.22	2.07	1.34
6	112.5	55.73	1.32	2.72	2.28	0.0	1.45	4.04	3.62	1.52
7	112.59	55.82	0.8	2.73	1.77	2.79	0.0	3.82	3.56	1.0
8	115.13	58.36	3.09	4.99	2.23	5.33	3.57	0.0	2.79	2.68
9	114.91	58.14	3.58	3.9	2.23	4.64	3.71	2.95	0.0	3.78
10	112.6	55.83	0.56	2.75	1.34	2.8	1.05	2.67	3.57	0.0

Figura 62: Primeros datos del CSV utilizando la matriz de distancias por carreteras

Aunado a lo anterior, se llevaron a cabo las primeras pruebas de funcionamiento del algoritmo, como parte de estas primeras pruebas se seleccionaron las 219 naves industriales (observado en la Figura 63) y se midió el tiempo de respuesta al solicitar datos a la API meteorológica, se analizó la calidad de las rutas generadas, al mismo tiempo que se compararon tanto la distancia total del recorrido como la duración de la ejecución en este escenario. En la Figura 64 se muestra la gráfica del valor de la aptitud a lo largo de las generaciones del recorrido simulado, como se observa el valor inicial del recorrido era superior a los 7000 km el cual a lo largo de las generaciones logró reducirse a poco más de 1000 km, lo que demuestra el correcto funcionamiento del algoritmo bioinspirado para realizar la optimización.

```

Selecciona los índices de las naves industriales, separados por comas (ej. 0,1,3,5,7), si ingresa -1 se seleccionan todos: -1
¿Desea realizar predicciones climáticas para las naves industriales seleccionadas? (s/n): s
Realizando predicciones climáticas para las naves industriales seleccionadas...
Predicciones completadas en 144.87 segundos.
Se han guardado las predicciones climáticas en 'c:\Users\albsa\Desktop\TT\TT2\Prototipo_1\Naves_Industriales_Con_Predicciones.csv'.
¿Desea aplicar penalizaciones por condiciones climáticas? (s/n): n
No se aplicarán penalizaciones por condiciones climáticas.
Naves Industriales disponibles para iniciar el recorrido:

```

	nombre	latitud	longitud	Prediccion
0	Advance Tepotzotlán I	19.718776	-99.211352	Lluvia
1	Advance Tepotzotlán II	19.706043	-99.227541	Nublado
2	Advance Toluca	19.296003	-99.575542	Nublado
3	Atizapan Park	19.539376	-99.285799	Lluvia
4	Atizapark	19.583509	-99.225772	Nublado
..	...	...	...	...
214	Zona Industrial Recursos Hidráulicos	19.622456	-99.177488	Lluvia
215	Zona Industrial Santa Clara Coatitla	19.533551	-99.069131	Considerablemente nublado
216	Zona Industrial Tecamac Zona Norte	19.775000	-98.975000	Lluvia
217	Zona Industrial Urbana Y/O Cuauhtémoc Xalostoc	19.516154	-99.083031	Considerablemente nublado
218	Zona Industrial Valle De Chalco Solidaridad	19.307510	-98.963647	Considerablemente nublado

Figura 63: Pruebas de estrés realizadas con todas las naves industriales




Figura 64: Evolución del fitness del algoritmo bioinspirado en las pruebas de estrés

8.1.3. Desarrollo de la base de datos

Por otra parte, se diseñó una propuesta estructurada para la base de datos definiendo claramente sus entidades, atributos y relaciones. Una vez concluido el diseño conceptual, se procedió a implementar el esquema en MySQL, lo que permitió implementar la base de datos en un entorno funcional. Para ello se utilizó la herramienta MySQL Workbench, la cual facilitó la creación, edición y visualización del modelo entidad-relación.

En la Figura 65 se presenta la estructura de la tabla Usuario, que contiene los datos relevantes de los usuarios registrados en el sistema. Mientras que, en la Figura 66 se muestra la descripción de la tabla Ruta encargada de almacenar los datos de las rutas generadas y guardadas por cada usuario.

Field	Type	Null	Key	Default	Extra
id_usuario	int	NO	PRI	NULL	auto_increment
nombre	varchar(50)	NO		NULL	
correo	varchar(100)	NO	UNI	NULL	
contraseña_hash	varchar(255)	NO		NULL	

Figura 65: Descripción de la tabla Usuario

Field	Type	Null	Key	Default	Extra
id_ruta	int	NO	PRI	NULL	auto_increment
id_usuario	int	NO	MUL	NULL	
destinos	varchar(1000)	NO		NULL	

Figura 66: Descripción de la tabla Ruta

8.2. Desarrollo del frontend del sistema

En paralelo a los trabajos de construcción de datos e implementaciones de los algoritmos contenidos en el backend, se desarrollaron las primeras vistas utilizando HTML, CSS Y JavaScript. Estas vistas incluyeron una primera representación del funcionamiento de las ventanas para la selección de naves, inicio de sesión, creación de una nueva cuenta en el sistema y visualización de las rutas guardadas por el usuario.

En la Figura 67 se muestra la ventana principal del sistema, en donde tanto un usuario sin registro como un usuario con registro pueden seleccionar entre las 219 naves industriales disponibles aquellas que desean incluir su recorrido. Para garantizar una optimización significativa, el sistema requiere que se seleccionen al menos cinco naves industriales; en caso de que se hayan seleccionado menos naves, el sistema despliega un mensaje de advertencia que solicita completar el mínimo requerido antes de proceder con el cálculo de la ruta óptima.




Figura 67: Vista de la ventana para seleccionar las naves industriales

De acuerdo con las primeras pruebas realizadas, el proceso de optimización puede tardar hasta 3 minutos si se seleccionan todas las naves industriales disponibles. Para mantener informado al usuario durante este tiempo, el sistema despliega una animación Lottie en la pantalla completa, lo cual funciona como una ventana de espera durante proceso de optimización. En la animación se muestra un camión moviéndose a través de algunos de los climas que predice el modelo, como lluvia, niebla, despejado etc., además del mensaje “Optimizando Ruta. Puede tardar unos minutos...”. En la Figura 68 se muestran algunos de los elementos de la animación Lottie.



Figura 68: Animación Lottie durante la espera de la optimización.

Por otra parte, en la Figura 69 se muestra la interfaz de iniciar sesión de la página web, donde el usuario previamente registrado puede ingresar al sistema; desde esta vista, el usuario puede ingresar sus credenciales para acceder a las funcionalidades personalizadas. El proceso de autenticación incluye diferentes validaciones para mantener la integridad de los datos ingresados, por ejemplo, si se ingresa un correo electrónico no registrado se mostrará el mensaje “Correo no encontrado”, indicando que no existe una cuenta asociada a ese correo. Por otro lado, si el correo es válido, pero se ingresa una contraseña errónea, se desplegará el mensaje “Contraseña incorrecta”. Cuando el inicio de sesión se realiza correctamente, el sistema confirma el acceso mostrando el mensaje de bienvenida: “¡Bienvenid@, Username!”.




Figura 69: Vista de la ventana para iniciar sesión en el sistema

En la Figura 70 se muestra la vista en la cual un usuario sin registro puede crear una cuenta en el sistema, ingresando su nombre, correo y una contraseña, la cual debe cumplir los siguientes criterios para proteger los datos y el acceso: debe contener al menos 8 caracteres, entre los cuales debe incluir una letra mayúscula, una letra minúscula, un número y un carácter especial, aquellos criterios que no se cumplan se mostrará un mensaje de advertencia, como, por ejemplo: “La contraseña debe tener al menos 8 caracteres” o “Debe incluir al menos un carácter especial”; además, si el correo electrónico ingresado ya está asociado a una cuenta existente, se muestra el mensaje: “El correo ya está registrado”, evitando duplicidad en el sistema.

Una vez que los datos son ingresados correctamente, la información se guarda en la base de datos y el sistema confirma la creación exitosa de la cuenta mostrando el mensaje: “¡Bienvenid@, Username!”, para proceder a iniciar sesión automáticamente, redirigiendo al usuario a la ventana principal donde podrá visualizar y gestionar sus rutas guardadas.




Figura 70: Vista de la ventana para crear una cuenta en el sistema

Aunado a lo anterior, se realizaron pruebas de visualización en la vista donde se muestra el resultado de la optimización generada por el algoritmo bioinspirado. Este algoritmo considera como restricciones las condiciones meteorológicas predichas por el modelo de Machine Learning en cada una de las naves industriales seleccionadas por el usuario. Para estas pruebas, se utilizaron datos simulados, ya que aún no se contaba con una conexión directa entre la ventana de selección de los puntos del usuario y el algoritmo bioinspirado.

En la Figura 71 y la Figura 72 se muestra una interfaz comparativa mediante pestañas que permite alternar la visualización entre dos mapas. El primero corresponde a la Ruta Sugerida, que muestra el recorrido optimizado considerando las penalizaciones meteorológicas, donde la nave de inicio se distingue en color verde y el resto en azul. El segundo mapa corresponde a la ruta sin contar la predicción meteorológica, la cual expone el recorrido óptimo sin tomar en cuenta las penalizaciones por el clima; en este mapa se utiliza un sistema visual de alertas donde las naves que varían su posición respecto a la ruta sugerida se marcan con pines rojos, facilitando así la identificación de los cambios realizados por el algoritmo. En ambas visualizaciones, las naves se encuentran conectadas por una línea negra que representa el trayecto por carretera, incluyendo el retorno al punto de inicio.

Así mismo, se muestra una tabla con los detalles de la ruta en donde se indica el número de destino que representa cada nave industrial en el recorrido, el nombre de la nave, y la condición meteorológica predicha con la cual se hizo la penalización de la ruta.

Debajo de esta tabla se presentan las métricas clave del recorrido: se visualiza la distancia penalizada (Fitness), que refleja el valor de aptitud obtenido por el algoritmo; la distancia real, que indica la longitud física total del recorrido en kilómetros para permitir al usuario conocer el impacto real del desvío por el clima; y el clima predominante, que señala la condición meteorológica más frecuente durante el trayecto.

Además, se incluye una gráfica que muestra la evolución de la aptitud conforme avanzan las generaciones. Finalmente, se muestra un mensaje en el que se indica que si se desea guardar la ruta debe de ser un usuario registrado, junto con un botón para volver a la ventana principal y generar una nueva ruta.




Figura 71: Vista del mapa con el trazado de la ruta penalizada




Figura 72: Vista del mapa con el trazado de la ruta sin penalizar

Tras las primeras pruebas de visualización, se refinó el diseño de las vistas con el objetivo de mejorar la experiencia del usuario y la interpretación de los resultados. Se ajustaron los elementos gráficos del mapa para optimizar la claridad del trazado de las rutas y la diferenciación de los puntos de interés.

En la Figura 73 se muestra la interfaz principal para el usuario administrador, en la cual se pueden ajustar los parámetros generales del algoritmo bioinspirado, tales como el multiplicador de la penalización, número de generaciones, tasa de enfriamiento, la temperatura final, el parámetro m y el uso o no de la heurística.

Asimismo, el sistema permite configurar las penalizaciones climáticas asignadas a cada tipo de condición meteorológica, las cuales afectan el cálculo de las rutas, incrementando el costo asociado a aquellas zonas con condiciones adversas y favoreciendo rutas más seguras y eficientes.

The screenshot displays the 'LogistiClima' Admin Panel. The header includes the logo and a 'App Principal' button. The main content area is titled 'Configuración del Algoritmo' with a subtitle 'Modifica los parámetros que influirán en la ejecución y la penalización climática'. It is divided into two sections: 'Parámetros Generales' and 'Penalizaciones Climáticas'. The 'Parámetros Generales' section contains input fields for Lambda (1.0), Number of Generations (800), Cooling Rate (0.99), Final Temperature (0.001), Parameter 'm' (3), and Heuristic (0). The 'Penalizaciones Climáticas' section lists various weather conditions with their corresponding penalty values: Nublado (1.1), Considerablemente nublado (1.2), Despejado (1.0), Niebla (1.8), Bruma (1.3), Lluvia intensa (1.7), Tormenta eléctrica intensa (1.9), Neblina (1.6), Lluvia (1.5), and Truenos (1.4). An 'Actualizar Parámetros' button is located at the bottom.

Parámetros Generales	
Lambda (Multiplicador Penalización):	1.0
Número de Generaciones:	800
Tasa de Enfriamiento (0.0 - 1.0):	0.99
Temperatura Final:	0.001
Parámetro 'm':	3
Heurística (0 o 1):	0

Penalizaciones Climáticas	
Nublado:	1.1
Considerablemente nublado:	1.2
Despejado:	1.0
Niebla:	1.8
Bruma:	1.3
Lluvia intensa:	1.7
Tormenta eléctrica intensa:	1.9
Neblina:	1.6
Lluvia:	1.5
Truenos:	1.4

Actualizar Parámetros

Figura 73: Vista principal del administrador.

8.3. Integración del backend y el frontend

Finalmente se realizó la integración del sistema, configurando el backend utilizando Flask, un framework de Python. Esta implementación permitió exponer endpoints que facilitan la consulta, registro y recuperación de rutas desde la base de datos.

El frontend se comunica con el backend para mostrar los datos y rutas correspondientes. En esta fase, las pruebas de visualización se realizaron utilizando datos previamente cargados como insumo; sin embargo, la estructura se preparó para sustituir esos datos de prueba por resultados generados en tiempo real.

Los resultados de este primer prototipo incluyen un archivo CSV limpio y estandarizado en el que se incluye como datos el nombre de las naves industriales y su ubicación espacial en un formato de latitud y longitud, así como el módulo bioinspirado adaptado al nuevo formato, que contiene un nuevo enfoque para el cálculo de distancias. Además, se ha desarrollado una interfaz web que se conecta a la base de datos, permitiendo a los usuarios iniciar sesión, crear nuevas cuentas, calcular rutas, visualizar estas rutas en un mapa y guardarlas para consultas posteriores; todo esto establece las bases necesarias para iniciar pruebas más extensas del sistema completo, asegurando su funcionalidad y rendimiento en escenarios más exigentes.

En la Figura 74 se muestran algunos ejemplos de usuarios registrados en la base de datos sistema, esto con el fin de resaltar la manera en que se guarda la información personal del usuario, como lo es su contraseña de inicio al sistema, la cual se encuentra cifrada de tal forma que no se guarde el texto en bruto de la contraseña del usuario, sino que al crear la cuenta el dato que se ingresa en el apartado contraseña es cifrado con la función `generate_password_hash()`, y al iniciar sesión se valida que la contraseña ingresada corresponda a la misma para el correo registrado en la base de datos con la función `check_password_hash()`.

id_usuario	nombre	correo	contraseña_hash
1	Alberto Flores	aflores1800@alumno.ipn.mx	sCrypt:32768:8:1\$uYZh7iCyh5rQIN5k\$6b16!
2	Ethel Padilla	ethelpadillar@hotmail.com	sCrypt:32768:8:1\$THdhspNlEmhBXXFs\$2e5
3	Sergio Calderas	sergiocalderas75@gmail.com	sCrypt:32768:8:1\$eYrLtiX8gqTRRn\$2c497e
4	Daniel Molina	danielmolina@example.com	sCrypt:32768:8:1\$VYgQMcdxUAz6dUH\$4e
5	Marco Ortiz	marcoortiz@example.com	sCrypt:32768:8:1\$JVErNqnBrFhvhfg6\$5082
NULL	NULL	NULL	NULL

Figura 74: Usuarios registrados en la base de datos.

La forma en que se almacenan las rutas en la base de datos consiste en guardar el identificador único del usuario que creó la ruta y los índices de las naves industriales seleccionadas, separados por comas. Esto permite que, al rehacer la optimización, dichos índices se pasen como parámetros al algoritmo bioinspirado para identificar las naves industriales que deben considerarse durante el proceso de optimización.

En la Figura 75 se observa como el sistema le presenta al usuario sus rutas guardadas en la base de datos, además se muestra la manera en que el usuario elige alguna de sus rutas históricas por medio de un radio button para

que al seleccionar el boton de “Optimizar Ruta” se despliegue la animación Lottie antes mencionada a manera de pantalla de espera.




Figura 75: Vista de la ventana de rutas guardadas para el usuario con cuenta en el sistema

En la columna de “Ruta” se muestran el nombre de las dos primeras naves industriales de cada recorrido, seguido de puntos suspensivos que representan las naves intermedias, y finalmente la última nave que conforma la ruta. Este formato se utiliza para evitar saturar la vista del usuario cuando una ruta contiene muchas naves industriales, lo que podría hacer que una sola fila ocupe demasiado espacio.

Para visualizar todas las naves industriales de la ruta, desde el inicio hasta el fin, el usuario puede seleccionar la opción “Ver más”. Esta opción despliega una ventana que muestra el recorrido completo tal como fue guardado. En la Figura 76 se muestran todas las naves industriales correspondientes a la ruta 1 de la Figura 75.




Figura 76: Detalles completos de la ruta del usuario.

En el caso que el usuario quiera borrar alguna de las rutas que tiene guardas en la base de datos con el botón “Eliminar” se despliega un mensaje para asegurar que no se elimine por error la ruta del usuario, si el usuario está seguro de eliminar la ruta, esta se elimina de la base de datos y se actualiza la tabla para mostrar únicamente

las rutas que tiene el usuario almacenadas en la base de datos. En la Figura 77 se muestra el mensaje para eliminar la ruta 2.




Figura 77: Borrar ruta del usuario de la base de datos.

8.4. Despliegue del sistema

Una vez concluida la fase de desarrollo e integración del sistema, se procedió con el despliegue. El objetivo de esta etapa fue realizar la transición de la aplicación desde un entorno de desarrollo local a un entorno de producción accesible y seguro, permitiendo así su operación en condiciones reales para la validación y uso.

Este proceso se estructuró en tres etapas fundamentales: el empaquetado de la aplicación, la gestión de la configuración de seguridad y el despliegue de la infraestructura en la nube.

8.4.1. Empaquetado con Docker

La estrategia fundamental para el despliegue se basó en el empaquetado mediante Docker. Esta tecnología se seleccionó para empaquetar la aplicación completa incluyendo el backend desarrollado en Python con Flask, la biblioteca de optimización en C y todas las dependencias listadas en el archivo requirements.txt en una unidad autónoma y portable denominada imagen de contenedor. Esto nos ofrece dos ventajas clave

- La imagen de contenedor resultante puede ejecutarse de manera idéntica en cualquier sistema que disponga de Docker, asegurando la reproducibilidad del entorno y mitigando las discrepancias comúnmente asociadas a la configuración de distintas máquinas.
- Se asegura que los entornos de desarrollo, pruebas y producción sean homólogos, minimizando la incidencia de errores derivados de inconsistencias en las configuraciones o dependencias de software.

8.4.2. Gestión de datos sensibles y Configuración Segura

Paralelamente a la configuración de los contenedores, se implementó una estrategia de gestión de datos sensibles para mejorar la seguridad de la aplicación. Para evitar la exposición de información sensible, todas las credenciales tales como las llaves de API (API keys) de servicios externos y las contraseñas de acceso a la base de datos fueron desacopladas del código fuente.

En su lugar, la aplicación fue modificada para leer estos valores desde variables de entorno. Este enfoque permite que la plataforma de despliegue (Google Cloud) inyecte dichas credenciales de forma segura en el contenedor exclusivamente durante el tiempo de ejecución. De esta manera, se preserva la confidencialidad de los datos sensibles, excluyéndolos del sistema de control de versiones y de la propia imagen de Docker.

Variables del entorno

Pega un archivo .env en el campo de entrada de nombre para propagar las variables de entorno de forma masiva.

Nombre 1 WEATHER_API_KEY p. ej., ENV o pegar el archivo .env	Valor 1 p. ej., prod
Nombre 2 DB_USER p. ej., ENV o pegar el archivo .env	Valor 2 p. ej., prod
Nombre 3 DB_PASS p. ej., ENV o pegar el archivo .env	Valor 3 p. ej., prod
Nombre 4 DB_NAME p. ej., ENV o pegar el archivo .env	Valor 4 p. ej., prod
Nombre 5 DB_HOST p. ej., ENV o pegar el archivo .env	Valor 5 p. ej., prod

Figura 78: Configuración de variables de entorno en GCP para la inyección segura de credenciales.

8.4.3. Despliegue de la Infraestructura en Google Cloud Platform (GCP)

Se seleccionó Google Cloud Platform (GCP) como el proveedor de servicios en la nube. La arquitectura de despliegue se centró en la utilización de dos servicios principales:

8.4.3.1. Alojamiento de la Aplicación (Cloud Run)

La imagen de Docker, generada en la primera etapa, fue desplegada utilizando Cloud Run. Este servicio resultó idóneo para la aplicación basada en contenedores, ya que GCP gestiona de forma automática los siguientes aspectos operativos:

- Inicia o detiene instancias del contenedor en respuesta directa a la demanda del tráfico, optimizando el uso de recursos.
- Asegura la operatividad continua de la aplicación.
- Distribuye eficientemente las solicitudes de los usuarios entre las instancias activas.




Figura 79: Panel de administración en GCP mostrando el servicio de aplicaciones activo.

8.4.3.2. Base de Datos Administrada (Cloud SQL para MySQL)

Para el almacenamiento de los datos, cuya estructura fue descrita en la sección anterior, se configuró una instancia de Cloud SQL para MySQL. La elección de este servicio se basó en las siguientes ventajas:

- Permite establecer conexiones privadas y seguras directamente desde el servicio Cloud Run, aislando la base de datos del tráfico público de Internet.
- GCP gestiona integralmente las copias de seguridad, la aplicación de parches de seguridad y las actualizaciones de versión del motor de base de datos.
- Ofrece capacidades avanzadas de monitorización, diagnóstico y escaneo de vulnerabilidades.

Filtro Escribir el nombre o valor de la propiedad					
☐ Estado	ID de instancia ? ↑	Problemas	Edición de Cloud SQL	Tipo	
☒	logisticlima123		Enterprise	MySQL 8.0	

Figura 80: Panel de administración en GCP mostrando la instancia de base de datos.

Así mismo durante la configuración de la instancia, se definieron credenciales de acceso únicas para asegurar una conexión única y segura con el sistema.

8.4.4. Resultado del Despliegue

Una vez que los servicios de cómputo (Cloud Run) y de base de datos (Cloud SQL) fueron implementados, enlazados y configurados, la plataforma generó un punto de acceso (endpoint) HTTPS público y seguro. Esta URL constituye el destino final a través del cual los usuarios acceden a la aplicación web LogistiClima. La cual es: <https://logisticlima-servicio-314848624313.northamerica-south1.run.app/>




Figura 81: Interfaz de usuario de LogistiClima desplegada en producción.




Figura 82: Interfaz de ruta de LogistiClima desplegada en producción.

9. Pruebas

Una vez desplegado el sistema, se procedió a realizar la fase de pruebas con el objetivo de verificar su correcto funcionamiento y validar el cumplimiento de los requerimientos establecidos. Durante esta etapa se evaluaron todos los módulos, la integración entre componentes y el desempeño general del sistema bajo diferentes condiciones de uso; así como detectar posibles áreas de mejora antes de su uso final.

Para comenzar, es importante destacar que algunas de las pruebas unitarias ya fueron desarrolladas y documentadas previamente y se pueden visualizar en el *Capítulo 5: Selección de modelos*. Estas pruebas fueron importantes desde etapas anteriores ya que permitieron probar y garantizar el funcionamiento individual de cada componente antes de llevar a cabo la validación integral del sistema, brindando así una base sobre la cual continuar con la evaluación del desempeño global.

9.1. Pruebas de integración

Una vez verificado el funcionamiento individual de cada uno de los módulos mediante pruebas unitarias, se procedió a realizar pruebas de integración. El objetivo de esta etapa fue verificar que los componentes del sistema trabajaran de manera conjunta de forma correcta y coherente, comprobando el flujo adecuado de datos y la comunicación entre módulos. Estas pruebas permitieron identificar posibles incompatibilidades, errores de alcance o fallas derivadas de la interacción entre partes que, aun funcionando bien por separado, podrían presentar inconsistencias al integrarse en un entorno común. De esta manera, las pruebas de integración descritas a continuación resultan esenciales para validar la operación del sistema como un conjunto unificado y estable.

9.1.1. Integración Backend (Python) – Algoritmo del núcleo (C)

Esta prueba se enfoca en la interfaz entre el servidor web y la biblioteca C (que incluyen las bibliotecas *.so* y *.dll*) que realiza el cálculo de optimización de ruta. Para realizar dichas pruebas se utilizó Postman, la cual es una plataforma de desarrollo de API que permite crear, probar y documentar APIs.

- Prueba de llamada exitosa

Acción: Hacer una llamada desde Python a la función principal del algoritmo C, proporcionando un conjunto válido y conocido de naves seleccionadas además de la matriz cargada.

Resultado esperado: Python debe recibir de vuelta una estructura de datos que represente una ruta ordenada y un costo total, sin errores de segmentación o tipos.

Resultado obtenido: Como se puede observar en las Figura 83 y Figura 84, utilizando Postman se envió una solicitud al servidor del sistema con una lista de naves para el cálculo de ruta y se obtuvo un código de estado “200 OK” que indica el servidor ha entendido la solicitud, la ha procesado y ha

devuelto los datos sin ningún problema. Además, en la consola del servidor no se observa ningún error de segmentación o referente a Python.




Figura 83: Resultado de la solicitud de rutas con postman




Figura 84: Resultado en el servidor de la solicitud enviada

- Prueba de manejo de errores (Entrada Vacía)

Acción: Llamar a la función C desde Python con una lista de naves vacía o con un solo nodo seleccionado.

Resultado esperado: La función C recibe los números correctamente, aseguramos que no permita seleccionar solo una nave industrial y que no hay desbordamientos.

Resultado obtenido: Como se muestra en la Figura 85, se recibió el error esperado que indica que se deben de seleccionar al menos 5 naves industriales para el funcionamiento del algoritmo, al igual que en la Figura 86 al mandar una entrada vacía, el servidor muestra un error y no genera desbordamientos (Figura 87).




Figura 85: Resultado de la prueba de entrada no válida




Figura 86: Resultado de la prueba al mandar una entrada vacía




Figura 87: Resultado en el servidor del error de la entrada no válida

9.1.2. Integración Backend – Base de datos

Estas pruebas validan que los endpoints de la API interactúan correctamente con la base de datos definida para el registro de datos (usuarios y rutas).

- Prueba de creación de usuario

Acción: Enviar una petición al endpoint de “Nueva Cuenta” con datos de un usuario nuevo.

Resultado esperado: Se debe responder con un código de éxito y se debe verificar que un nuevo registro existe en la tabla usuarios de la base de datos junto con la contraseña en hash.

Resultado obtenido: En la Figura 88 se muestra la respuesta de ingresar los datos de un nuevo usuario al crear una cuenta, mientras que en la Figura 89 se ve el registro del nuevo usuario con id_usuario 1 y otros ejemplos de usuarios registrados con el cifrado de su contraseña.




Figura 88: Resultado de crear un usuario nuevo

id_usuario	nombre	correo	contraseña_hash
1	User_test_001	test001@example.com	scrypt:32768:8:1\$AQaEfKqgU7tGWWdl\$45fd737e6fcd88a
2	User_test_002	test002@example.com	scrypt:32768:8:1\$djywm61cZXGaptq\$ee920cae26d9751c
3	User_test_003	test003@example.com	scrypt:32768:8:1\$dS42kQigyY9MWfjk\$feb53aa116946e14
4	User_test_004	test004@example.com	scrypt:32768:8:1\$hGN6MLt0biITgZLi\$2e70abd83e823fae9
5	User_test_005	test005@example.com	scrypt:32768:8:1\$XJKdPMUOx3sb5WZx\$ed6fe3b0b7d5d2
NULL	NULL	NULL	NULL

Figura 89: Resultado de registrar al usuario en la base de datos

- Prueba de conflicto usuario

Acción: Intentar registrar un usuario con un correo que ya existe en la base de datos.

Resultado esperado: Se debe consultar la base de datos, detectar el conflicto y devolver un error, impidiendo la inserción duplicada.

Resultado obtenido: Cuando se intenta crear una cuenta de usuario se verifica que no exista duplicidad en el correo ingresado, en la Figura 90 se muestra el mensaje de error indicando que ya hay una cuenta con ese correo.




Figura 90: Resultado de intentar crear otra cuenta con un correo ya registrado

- Prueba de guardado de ruta

Acción: Después de calcular una ruta exitosamente, solicitar la acción de “Guardar ruta”.

Resultado esperado: Se debe tomar los id de las naves industriales de la ruta y el id del usuario de la sesión activa para crear un nuevo registro en la tabla Ruta, asociándola correctamente al usuario.

Resultado obtenido: En la Figura 91 se observan los resultados de realizar la optimización para algunas naves industriales, después se selecciona la opción “Guardar Ruta” para guardar el id del usuario y los id’s de las naves industriales en la base de datos, lo cual se observa en la Figura 92, donde el id_ruta 7 tiene los datos del usuario en sesión con el id 6 y las naves industriales seleccionadas.




Figura 91: Guardar la ruta después de generar el resultado

id_ruta	id_usuario	destinos
1	1	0,1,2,3,4,214,215,216,217,218
2	1	7,32,57,82,107
3	4	4,5,54,55,65,79,80,83,112,121,133,138,170,171,192,218
4	3	0,1,2,3,5,6,7,8,9,10,11,13,14,15,16,17,20,21,22,23,25,70,73
5	2	9,10,11,134,159,160,175,184,185,207,212
6	5	0,1,2,217,218
7	5	0,1,2,3,4
8	5	1,7,28,50,72,93,99,116,124,147,170,192,206,209,214,218
9	5	1,7,28,50,72,93,99,116,124,147,170,192,206,209,214,218
NULL	NULL	NULL

Figura 92: Resultado de guardar la ruta del usuario en la base de datos

- Prueba de obtención de rutas recientes

Acción: Enviar una petición GET al endpoint de “Rutas Recientes” estando autenticado como un usuario que tiene rutas guardadas.

Resultado esperado: Se hace la consulta a la base de datos, se encontrará todas las rutas para ese id de usuario y devolver el historial de rutas.

Resultado obtenido: Dentro de la vista de rutas recientes para el usuario actual se observa como única ruta en la Figura 93 aquella con la cual se hizo la prueba de guardado de ruta, y en la Figura 94 se muestran las naves industriales que se seleccionaron anteriormente.



Figura 93: Resultado de ver rutas guardadas para el usuario




Figura 94: Detalles completos de la ruta guardada para el usuario

9.1.3. Integración Frontend – Backend

Estas pruebas verifican que la interfaz de usuario puede consumir y enviar datos correctamente al componente de Python.

- Prueba de carga de naves

Acción: Cargar la página *SeleccionarNaves.html*

Resultado esperado: El script *js_SeleccionarNaves.js* debe realizar la petición al backend, recibir el listado de las naves industriales desde el archivo CSV que las contiene.

Resultado obtenido: En la pestaña network observada en Figura 95, en la petición de naves está marcada como 200 OK que indica que el servidor ha recibido la petición y ha devuelto correctamente los datos. Además, como se muestra en la Figura 96 obtenemos el json con las naves industriales lo que demuestra que se obtuvieron correctamente.




Figura 95: Verificación de la petición a seleccionar-naves




Figura 96: JSON obtenido de la petición a seleccionar-naves

- Prueba de envío de cálculo de ruta y visualización de ruta exitosa

Acción: En el frontend, seleccionar varias naves y presionar el botón “Calcular Ruta”, y el backend responde a la petición anterior con una ruta exitosa.

Resultado esperado: El *js_MejorRuta.js* debe construir un JSON para calcular la ruta en el backend. Se debe obtener una respuesta y mostrarla visualmente al usuario dibujando la línea sobre el mapa desde las coordenadas del GeoJSON.

Resultado obtenido: Al seleccionar las naves industriales y dar clic en el botón de optimizar ruta, se ve una nueva petición marcada con “200 OK” a *mejor-ruta*, aunado a esto se aprecia el JSON que se envió y el JSON que el backend devolvió y la página cambió a la vista de *MejorRuta.html* donde se visualiza la ruta dibujada en el mapa (todo observado en la Figura 97).




Figura 97: Resultado prueba de envío de cálculo de ruta y visualización de ruta

- Prueba de manejo de error

Acción: El backend responde con un error de que no se seleccionaron suficientes naves industriales.

Resultado esperado: El frontend debe detectar la respuesta de error y mostrar un mensaje al usuario “No hay suficientes naves seleccionadas”.

Resultado obtenido: Al seleccionar solo 1 nave la página no crashea, únicamente aparece un alert de JavaScript de error que indica que se deben seleccionar al menos 5 naves industriales y no se genera el JSON correspondiente para generar una ruta como se puede apreciar en la Figura 98.




Figura 98: Resultado de la prueba de manejo de error

9.2. Pruebas del algoritmo de recocido simulado

Para la selección de los parámetros finos del algoritmo bioinspirado, los cuales son la tasa de enfriamiento, la temperatura inicial y el número de generaciones, se procedió a una evaluación exhaustiva mediante una búsqueda de cuadrícula (Grid Search) que abarcó la totalidad de las posibles combinaciones. Este análisis contempló un espacio de búsqueda delimitado por un rango de generaciones que se extiende desde 500 hasta 2300 con incrementos de 200; una tasa de enfriamiento definida en el intervalo de 0.95 a 0.99; y un conjunto de valores de temperatura que oscilan en una escala logarítmica descendente desde 0.1 hasta 0.000001.

Con el propósito de asegurar la consistencia estadística de los resultados, se evaluó tanto la función de aptitud (fitness) como el tiempo de ejecución mediante 5 iteraciones independientes para cada combinación, calculando posteriormente sus promedios. Como se observa en la Figura 99, el análisis permitió aislar las 5 configuraciones con mejor desempeño global. De este subconjunto, se eligió seleccionar la primera combinación mostrada, dado que ofrece el equilibrio más eficiente entre la minimización del riesgo y la velocidad de convergencia, justificando su implementación en la arquitectura final.

Top 5 Mejores Configuraciones (Menor Fitness):					
Generaciones	Tasa_Enfriamiento	Temp_Final	Avg_Fitness	Avg_Tiempo_Seg	
2300	0.99	0.000001	2877.61814	1.4	
500	0.98	0.000001	2922.49466	0.2	
700	0.99	0.000001	2944.79020	0.6	
1900	0.99	0.000001	2953.53574	2.2	
2300	0.99	0.001000	2954.61176	1.8	

Figura 99: Mejores combinaciones de Hiperparámetros para el algoritmo de optimización

Posteriormente, para validar la robustez y escalabilidad del algoritmo de optimización, se ejecutaron pruebas de estrés mediante un benchmarking incremental que evaluó el desempeño frente a lotes de 5, 20, 50, 100, 150 y la totalidad de las 219 naves industriales. Con el objetivo de mitigar la estocasticidad del algoritmo bioinspirado y obtener métricas representativas, cada lote se sometió a 20 iteraciones independientes utilizando un modelo de asignación climática ponderada; este modelo simula escenarios operativos basados en la distribución histórica climatológica (los datos obtenidos para entrenar el modelo de ML), donde predominan condiciones como "Despejado" o "Nublado" y, en menor proporción, categorías críticas como "Tormenta eléctrica intensa" o "Niebla".

El análisis se centró en contrastar la optimización sin restricciones frente a la optimización sujeta a condicionantes climáticas, con el objetivo primordial de minimizar la exposición al riesgo meteorológico. Para cuantificar esta variable, se empleó el cálculo de la exposición de riesgo acumulado, calculado como la suma de las distancias de los tramos entre las naves industriales multiplicadas por el incremento del factor de penalización respecto a la ponderación neutral (1.0). Como se evidencia en la tabla de resultados, el algoritmo prioriza la evasión de zonas de alta penalización para asegurar la integridad del trayecto. Este comportamiento

permite una reducción del riesgo que oscila entre el 19.6% y el 28.4%, validando que la función de aptitud cumple con evitar trayectorias de alto riesgo climatológico independientemente del costo en distancia.

# Naves	Disminución de Riesgo
5	28.47%
20	22.49%
50	23.75%
100	19.69%
150	25.43%
219	23.35%

Tabla 27: Comparación de la disminución de riesgo

Al examinar los datos por volumen, se observa que en instancias de 5 naves se reduce el riesgo en un 28.47%. A medida que aumenta el número de naves y la complejidad combinatoria, el sistema realiza los desvíos necesarios para mantener una reducción de riesgo superior al 23%, lo que confirma la capacidad del algoritmo para sostener la seguridad operativa en escenarios donde el espacio de búsqueda de soluciones aumenta.

Finalmente, el registro de los tiempos de ejecución, que oscilan entre 0.01 segundos para los lotes menores y 2.18 segundos para la totalidad de las naves industriales, evidencia el rendimiento de la arquitectura híbrida implementada. Estos valores cuantifican el impacto de alojar el núcleo de procesamiento en una biblioteca de enlace dinámico (DLL) compilada en lenguaje C, permitiendo la ejecución directa del recocido simulado sin la sobrecarga de tiempo de ejecución asociada a los lenguajes interpretados como Python. Esta implementación reduce la latencia acumulada a través de las generaciones del algoritmo, manteniendo el tiempo total de procesamiento por debajo de los 2 segundos incluso en el escenario de máxima carga computacional.

# Naves	Tiempo de Ejecución (s)
5	0.007
20	0.049
50	0.156
100	0.491
150	1.018
219	1.602

Tabla 28: Comparación de los tiempos de ejecución

9.3. Pruebas del modelo de predicción meteorológica

Para comprobar que las predicciones realizadas por el modelo Random Forest (seleccionado anteriormente debido a que obtuvo un 93% de exactitud las 10 condiciones meteorológicas más comunes en el Estado de México) realmente sean condiciones reales, se realiza una comparativa con el servicio de Google Clima, ya que este es una de las fuentes meteorológicas más utilizadas y con la que los usuarios finales contrastan el estado del clima en su ubicación.

Como primer parte de esta prueba se compararon las condiciones meteorológicas obtenidas por ambos métodos en los municipios de Toluca, Tlanepantla, Chalco y Ecatepec, ya que en estos municipios se encuentran algunas de las naves industriales que se tienen contempladas en el sistema, además de la localidad Lindavista norte. Dichos resultados de la comparativa de ambos métodos se muestran de la Figura 100 a la Figura 109, donde de manera inicial se muestra el clima obtenido por medio de Google Clima, seguido de la categoría predicha por el modelo Random Forest.




Figura 100: Clima obtenido por Google en Toluca de Lerdo, Edomex

DATOS PARA LA PREDICCIÓN OBTENIDOS DE LA API
 Coordenadas; 19.287846, -99.658191
 País: Mexico, Localidad: Toluca
 Hora: 2025-11-19 00:56
 Direccion Viento: SSE, Velocidad viento: 3.6 km/h
 Temperatura: 12.6 °C, Punto de Rocío: 8.0 °C, Humedad: 74%

Clase predicha: Despejado

Figura 101: Clima predicho por el modelo de Random Forest en Toluca de Lerdo, Edomex




Figura 102: Clima obtenido por Google en Tlanepantla, Edomex

DATOS PARA LA PREDICCIÓN OBTENIDOS DE LA API
 Coordenadas; 19.54509401324084, -99.19814739210115
 País: Mexico, Localidad: Tlanepantla
 Hora: 2025-11-19 16:06
 Direccion Viento: NE, Velocidad viento: 8.6 km/h
 Temperatura: 25.2 °C, Punto de Rocío: 6.6 °C, Humedad: 29%

Clase predicha: Considerablemente nublado

Figura 103: Clima predicho por el modelo de Random Forest en Tlanepantla, Edomex

Resultados para **Chalco de Díaz Covarrubias, Méx.** · [Elegir área](#) ⋮



Prob. de precipitaciones: 0%
Humedad: 22%
Viento: a 6 km/h

Clima
miércoles, 3:00 p.m.
Soleado

[Temperatura](#) | [Precipitaciones](#) | [Viento](#)

Figura 104: Clima obtenido por Google en Chalco, Edomex

DATOS PARA LA PREDICCIÓN OBTENIDOS DE LA API
Coordenadas; 19.274963221642533, -98.9014549241218
País: Mexico, Localidad: Chalco De Díaz Covarrubias
Hora: 2025-11-19 15:40
Direccion Viento: WNW, Velocidad viento: 3.6 km/h
Temperatura: 26.1 °C, Punto de Rocío: 10.9 °C, Humedad: 14%

Clase predicha: Considerablemente nublado

Figura 105: Clima predicho por el modelo de Random Forest en Chalco, Edomex

Resultados para **Agricultura 4-A, Ecatepec de Morelos, Méx.** · [Elegir área](#) ⋮



Prob. de precipitaciones: 0%
Humedad: 38%
Viento: a 6 km/h

Clima
miércoles, 1:00 p.m.
Parcialmente soleado

[Temperatura](#) | [Precipitaciones](#) | [Viento](#)

Figura 106: Clima obtenido por Google en Ecatepec de Morelos, Edomex

DATOS PARA LA PREDICCIÓN OBTENIDOS DE LA API
Coordenadas; 19.57022385643678, -99.03931145614546
País: Mexico, Localidad: Tierra Blanca Segunda Seccion (Ejido Ecatepec)
Hora: 2025-12-10 13:25
Direccion Viento: NNW, Velocidad viento: 5.8 km/h
Temperatura: 21.2 °C, Punto de Rocío: 11.4 °C, Humedad: 43%

Clase predicha: Considerablemente nublado

Figura 107: Clima predicho por el modelo de Random Forest en Ecatepec de Morelos, Edomex

Resultados para **Lindavista Nte., Ciudad de México** · [Elegir área](#) ⋮



Prob. de precipitaciones: 10%
Humedad: 61%
Viento: a 6 km/h

Clima
miércoles, 11:00 p.m.
Mayormente nublado

[Temperatura](#) | [Precipitaciones](#) | [Viento](#)

Figura 108: Clima obtenido por Google en Lindavista Norte, CDMX

DATOS PARA LA PREDICCIÓN OBTENIDOS DE LA API
 Coordenadas; 19.504060940135787, -99.14696274910372
 País: Mexico, Localidad: Colonia Lindavista
 Hora: 2025-12-10 23:24
 Direccion Viento: NNE, Velocidad viento: 9.7 km/h
 Temperatura: 17.1 °C, Punto de Rocio: 11.1 °C, Humedad: 52%

Clase predicha: Considerablemente nublado

Figura 109: Clima predicho por el modelo de Random Forest en Lindavista Norte, CDMX

Tras realizar la comparativa en los cinco lugares se observa que los resultados de observa que ambos métodos coinciden en la mayoría de las veces con respecto a la condición meteorológica, teniendo un único error en el municipio Chalco, el cual se observa en las Figura 104 y Figura 105, donde la categoría obtenida por Google Clima es Despejado, mientras que el modelo predijo la categoría de Considerablemente nublado, que si bien es un error de clasificación esto ya es algo esperado, ya que según la matriz de confusión del Random Forest que se muestra en la Figura 44 estas dos categorías tienen un error de clasificación de los datos.

Ademas las categorías de Parcialmente soleado y Mayormente nublado obtenidas por Google Clima que se muestran en la Figura 102, Figura 106 y Figura 108 no representan un error de clasificación, ya que estas categorías fueron reagrupadas en la categoría de Considerablemente nublado durante el proceso de limpieza del dataset para el entrenamiento de los modelos de Machine Learning.

El resumen general de los resultados obtenidos en esta primera etapa se muestra en la Tabla 29, desglosando las condiciones meteorológicas predichas por cada método en cada uno de los cinco lugares antes mencionados, asimismo se verifica si el modelo hizo la predicción correctamente.

Lugar	Condición obtenida por Google Clima	Condición obtenida por modelo Random Forest	¿El modelo predijo correctamente?
Toluca	Despejado	Despejado	Si
Tlalnepantla	Considerablemente nublado	Considerablemente nublado	Si
Chalco	Despejado	Considerablemente nublado	No
Ecatepec	Considerablemente nublado	Considerablemente nublado	Si
Colonia Lindavista	Considerablemente nublado	Considerablemente nublado	Si

Tabla 29: Resultados de la comparativa del modelo de predicción meteorológica en México

Como segunda parte de las pruebas al modelo de predicción, se realizaron comparaciones en lugares donde estuvieran presentes algunas de las condiciones meteorológicas que son percibidas como más riesgosas según la encuesta realizada, esto debido a que en al momento de realizar estas pruebas no hay una variación de las

condiciones meteorológicas en el Estado de México, estando mayormente presente las categorías de Considerablemente nublado y Despejada, por lo cual la comparativa de Google Clima y el modelo de Random Forest se realizó en localidades de los países Uruguay, Albania y Estados Unidos de América, ya que presentan precipitaciones pluviales con las que se puede comprobar el funcionamiento del modelo al predecir las categorías percibidas como más riesgosas, los resultados de esta etapa se muestran de la Figura 110 a la Figura 115.




Figura 110: Clima obtenido por Google en Vichadero, Uruguay

DATOS PARA LA PREDICCIÓN OBTENIDOS DE LA API
 Coordenadas; -31.733, -54.3413
 País: Uruguay, Localidad: Penarol
 Hora: 2025-12-10 03:00
 Direccion Viento: SSE, Velocidad viento: 34.9 km/h
 Temperatura: 19.4 °C, Punto de Rocio: 16.6 °C, Humedad: 100%

Clase predicha: Lluvia

Figura 111: Clima predicho por el modelo de Random Forest en Vichadero, Uruguay





Figura 112: Clima obtenido por Google en Librazhd, Albania

DATOS PARA LA PREDICCIÓN OBTENIDOS DE LA API
 Coordenadas; 38.69901, -79.9042
 País: Albania, Localidad: Librazhd
 Hora: 2025-11-19 20:26
 Direccion Viento: E, Velocidad viento: 9.0 km/h
 Temperatura: 12.0 °C, Punto de Rocio: 8.5 °C, Humedad: 94%

Clase predicha: Lluvia

Figura 113: Clima predicho por el modelo de Random Forest en Librazhd, Albania



Temperatura | Precipitaciones | Viento

Clima
 miércoles
 Lluvia

Figura 114: Clima obtenido por Google en University Place, EE.UU.

DATOS PARA LA PREDICCIÓN OBTENIDOS DE LA API
 Coordenadas; 47.32026, -122.60579
 País: United States of America, Localidad: University Place
 Hora: 2025-12-10 10:41
 Direccion Viento: SSW, Velocidad viento: 20.2 km/h
 Temperatura: 13.3 °C, Punto de Rocío: 11.2 °C, Humedad: 93%

Clase predicha: Lluvia

Figura 115: Clima predicho por el modelo de Random Forest en University Place, EE.UU.

Después de efectuar la comparativa de Google Clima y el modelo de Random Forest en las localidades fuera de México, en todos los casos analizados ambos métodos coincidieron en la categoría de Lluvia, por lo cual el modelo realizó correctamente la predicción de la condición meteorológica esperada. En la Tabla 30 se muestra el resumen de los resultados de esta segunda etapa de pruebas.

Lugar	Condición obtenida por Google Clima	Condición obtenida por modelo Random Forest	¿El modelo predijo correctamente?
Uruguay	Lluvia	Lluvia	Si
Albania	Lluvia	Lluvia	Si
Estado Unidos	Luvia	Lluvia	Si

Tabla 30: Resultados de la comparativa del modelo de predicción meteorológica fuera de México

9.4. Pruebas de estrés en el servidor

Las pruebas de estrés y de carga se realizaron con el objetivo de verificar la estabilidad y tiempos de respuesta del sistema bajo una carga concurrente, el despliegue dentro de Google Cloud tiene las condiciones que se muestran en la Tabla 31.

Componente	Configuración Actual
Cloud Run (Frontend/API)	CPU: 1 Memoria: 4GB RAM Min Instancias: 0 Máx Instancias: 35
Algoritmo Core (C)	Versión de biblioteca: librecocido.so
API Externa	Weather API
Base de Datos	Cloud SQL

Tabla 31: Condiciones actuales del sistema

9.4.1. Escenario A: “Cálculo Concurrente pocos datos”

Objetivo: Probar el CPU del contenedor de Cloud Run con operaciones simultaneas.

Acción: Los 30 usuarios seleccionan 5 naves industriales, todos hacen clic en “Calcular Ruta” simultáneamente.

Métrica y resultado: Tardó un promedio de 23 segundos en responder, con un tiempo de respuesta mínimo de 10 segundos y en el caso de mayor tiempo 49 segundos en ejecución.

9.4.2. Escenario B: “Cálculo Masivo Concurrente”

Objetivo: Saturar el CPU del contenedor de Cloud Run.

Acción: Los 30 usuarios van a seleccionar naves, cada usuario selecciona 219 naves, todos hacen clic en “Calcular Ruta” simultáneamente.

Métrica y resultado: En algunos casos tardo 79 segundos en responder, en otros 120 segundos. Sin embargo, al exceder los 150 segundos de espera falló el sistema, a pesar de que el servidor no estaba al 100%. Con esto se puede notar que primero se alentó el sistema y finalmente se cayó.

Al analizar los datos obtenidos en esta prueba, se notó que el error estaba siendo generado debido a una configuración de instancias máximas sin límite, lo que provocaba que dichas instancias se crearán en el momento y no con la configuración correcta

9.4.3. Escenario C: “Cálculo Masivo Concurrente con Correcciones”

Objetivo: Volver a saturar el CPU del contenedor de Cloud Run con las mejoras observadas en el escenario B. Una de las mejoras implementadas fue configurar correctamente el número máximo de instancias. Para esta prueba se configuraron 35, sin embargo, es importante considerar que este parámetro se puede ajustar según el contexto y número de usuarios.

Acción: Los 30 usuarios vuelven a seleccionar naves, cada usuario selecciona 219 naves, todos hacen clic en “Calcular Ruta” simultáneamente.

Métrica y resultado: Se redujo el tiempo promedio de ejecución a 60 segundos, finalmente después de 5 minutos termina el tiempo máximo de espera; esto según configuraciones de Google Cloud. Pero en esta ocasión no se presentaron usuarios en los que se les haya presentado el caso de que el sistema se cayera.

9.4.4. Paralelización de predicción de la condición meteorológica

Adicionalmente, para reducir el tiempo total de la optimización, el cual incluye las solicitudes a la API, realizar la predicción de condición meteorológica con el modelo de Machine Learning y optimización con el algoritmo bioinspirado, se implementó un esquema de paralelización con hilos en Python. Este enfoque emplea 20 hilos de ejecución en paralelo, los cuales realizan solicitudes a la API y hacen la predicción de la condición

meteorológica con el modelo Random Forest de manera simultánea, lo permite reducir el tiempo de espera, ya que el proceso de optimización utilizando el dll del Recocido Simulado tarda 1.61 segundos para el caso de las 219 naves industriales, mientras que el resto del tiempo se centra en realizar las peticiones a la API y la predicción de la condición meteorológica. En la Tabla 32 se muestran los tiempos totales del proceso de optimización con ambos métodos para las 219 naves industriales del Estado de México.

Método	Número de naves industriales	Tiempo total
Cómputo concurrente	219 naves industriales	121.14 segundo
Paralelización con hilos	219 naves industriales	73.27 segundos

Tabla 32: Tiempos totales de la optimización

Se observa que el tiempo total de la optimización para todas las naves industriales realizando la consulta y predicción para las naves industriales de manera individual, solamente con cómputo concurrente es de 2 minutos, mientras que el tiempo total con la paralelización con hilos es de 1 minuto con 13 segundos, lo cual representa una disminución del 40% del tiempo original, demostrando que este nuevo enfoque si permite reducir el tiempo de espera para conocer los resultados de la optimización.

9.5. Pruebas de aceptación

Las pruebas de aceptación se realizaron con dos perfiles distintos y se enfocaron en distintos aspectos relacionados con la funcionalidad del sistema:

1. **Planificador logístico:** Se enfocó en la optimización, la toma de decisiones y la configuración. El objetivo fue validar que el sistema genere rutas lógicas, ahorrar tiempo en planificación y manejo correctamente las variables del negocio. El resumen de esta prueba de aceptación se muestra en la Tabla 33.

Caso de prueba	Pasos para ejecutar	Criterio de aceptación	¿Si/No?	Comentarios
Carga de datos	1. Ir a “Seleccionar Naves” 2. Verificar que aparezcan todas las naves en el mapa y en la lista 3. Permite seleccionar más de 5 naves industriales.	Las naves se muestran correctamente y se permiten seleccionar.	Si	
Simulación de ruta	1. Selecciona entre 5 y 219 naves industriales 2. Haga clic en “Calcular ruta”	El sistema devuelve una ruta en un tiempo promedio de 30 segundos. El orden de visita tiene lógica.	Si	

Validación de clima	1. Identificar una zona con mal clima. 2. Generar una ruta que pase cerca de ahí	El sistema debe mostrar la predicción meteorológica (ej, Lluvia/Nublado) en el resultado y se debe reflejar en la generación de la ruta.	Si	
Gestión de rutas	1. Si desea guardar la ruta para otro momento, guardarla y en la cuenta registrada en “rutas recientes” recuperarla	El sistema permite la opción de “Guardar Ruta”, la ruta se guarda y se recupera (mismos puntos, pero con la predicción actual).	Si	

Tabla 33: Pruebas de aceptación a un planificador logístico

2. **Operador de tráiler:** Esta prueba de aceptación se enfocó en la claridad, la facilidad de uso y la visualización de ruta para validar su usabilidad en el campo. Los casos de pruebas y comentarios realizados se muestran en la Tabla 34.

Caso de prueba	Pasos para ejecutar	Criterio de aceptación	¿Si/No?	Comentarios
Claridad visual	1. Abrir una ruta ya calculada. 2. Mirar el mapa con la ruta trazada	¿Se distingue claramente los puntos a visitar? ¿La línea de ruta se ve bien sobre el mapa?	Si	
Instrucciones del viaje	1. Mirar la lista de naves ordenada a la derecha. 2. Leer los nombres ordenados de los puntos a visitar	El tamaño de letra es legible. Se entiende claramente qué nave sigue después de cuál. No hay confusión en los nombres.	Si	Me gustaría que las letras mejor distribuidas y un poco más grandes.
Información de riesgo	1. Identificar en la pantalla la información sobre el clima de los destinos.	Puede identificar rápidamente si un destino tiene predicción de lluvia o neblina (texto claro).	Si	

Facilidad de acceso	1. Al entrar a “Rutas recientes” puede ver todas sus rutas.	Los botones son fáciles de encontrar y presionar (no están escondidos ni son muy pequeños). La información de las rutas se muestra con claridad.	Si	
---------------------	---	--	----	--

Tabla 34: Pruebas de aceptación a un operador de tráiler

10. Balance de costos final

Posterior al despliegue de la aplicación LogistiClima se realizó balance final de costos en el que se integraron los gastos contemplados para el desarrollo del sistema. Este análisis se muestra a continuación de la Tabla 35 a la Tabla 37, donde se muestran los costos asociados a la infraestructura, los recursos humanos y los recursos de hardware y software requeridos durante el proceso de desarrollo.

Recursos Humanos				
Cantidad	Rol	Descripción	Salario mensual	Total (10 meses)
2	Desarrollador IA	Responsable de desarrollar e implementar los modelos de machine learning y algoritmos bioinspirados.	22,500	450,000
1	Desarrollador web	Encargado del desarrollo de la interfaz web para los usuarios.	14,000	140,000
Total				590,000

Tabla 35: Recursos humanos costo final

Recursos de Hardware y Software				
Cantidad	Nombre	Descripción	Costo	Subtotal
3	Computadora portátil con sistema operativo Windows 11	Equipos para el desarrollo y documentación del proyecto.	5,000	15,000
3	Visual Studio Professional	Entorno de desarrollo integrado.	912.92	27,387.60
3	Python	Lenguaje de programación.	0	0
1	MySQL	Sistema gestor de base de datos.	0	0
1	Microsoft 365 Familia	Librerías para la documentación.	2,299	2,299
1	WeatherAPI	API meteorológica para la obtención de datos para el modelo de Machine Learning.	81.16	811.60
1	Hosting de Google Cloud	Incluye los tres servicios necesarios para el despliegue y el SQL.	1,802	1,802
Total				47,299.60

Tabla 36: Recursos de Hardware y Software final

Infraestructura			
Nombre	Descripción	Costo bimestral	Subtotal (10 meses)
Servicio de luz	Costo bimestral estimado por el pago de servicios de electricidad.	180	900
Servicio de agua	Costo bimestral estimado por el pago del servicio de agua potable.	950	4,750
Servicio de internet	Servicio de internet de 100 Megas.	798	3,990
		Total	9,640

Tabla 37: Recursos de infraestructura final

Realizando una comparativa con el análisis de costos propuesto en capítulos anteriores, se puede observar que el servicio de Hosting elevó el precio ya que se tomó la decisión de alojar el sistema web utilizando los servicios de Cloud ofrecidos por Google, al tener la configuración elegida y descrita da un costo más elevado que el propuesto anteriormente, esto debido a que cada instancia que puede ser configurada tiene un costo de \$58 x 1 día; al notar esto se tomó la decisión de configurarla de manera que no tuviera instancias activas a menos que se hiciera la petición al servidor, para de esta manera tener un ahorro de costos. Con lo anterior tomado en cuenta, se obtuvo un costo total que se muestra en la Tabla 38.

Nombre	Costo
Costo recursos humanos	\$ 590,000 MXN
Costo recursos de hardware	\$ 47,299.60 MXN
Costo de infraestructura	\$ 9,640 MXN
Costo Total	\$ 646,939.60 MXN

Tabla 38: Costo total final del proyecto

11. Conclusiones

El presente proyecto abordó problemáticas generadas por las condiciones climatológicas pluviales en el ámbito logístico, identificando los principales factores que afectan la ejecución de rutas de transporte. En primera instancia, se procedió a analizar y delimitar los principales desafíos asociados a los fenómenos meteorológicos, en especial aquellos relacionados con las precipitaciones pluviales, que representan una amenaza significativa para la planificación y ejecución de rutas en empresas de logística. Esta delimitación permitió comprender las limitaciones operativas y los riesgos recurrentes que se presentan bajo escenarios meteorológicos variables, como son retrasos operativos y accidentes ocasionados por condiciones pluviales en el área metropolitana precisamente en el Estado de México, el cual es el estado de mayor industrialización del país, aportando el 16% del total al sector afectando las operaciones logísticas de todo el país al suceder retrasos en los traslados de mercancía.

Posteriormente, se realizó un análisis detallado del estado del arte enfocado en algoritmos bioinspirados y técnicas de machine learning, con el objetivo de identificar enfoques computacionales que puedan contribuir de manera efectiva a la resolución de problemas logísticos complejos, de los cuales se identificaron algoritmos genéticos, enjambre de partículas, recocido simulado y búsqueda tabú para la parte de algoritmos bioinspirados; y por otra parte para machine learning se estudiaron técnicas como redes neuronales recurrentes, máquinas de soporte vectorial, árboles de decisión y Random Forest. Este estudio bibliográfico permitió identificar las fortalezas y limitaciones de distintas metodologías, así como identificar tendencias actuales en la aplicación de estos algoritmos dentro del ámbito de la predicción y optimización.

Con base en este análisis, se realizaron pruebas con cuatro algoritmos bioinspirados (Búsqueda Tabú, Recocido Simulado, Algoritmo Genético y PSO), con el fin de validar su funcionamiento como referencia para la optimización de las rutas logísticas considerando como restricción las predicciones meteorológicas pluviales. Tras el análisis cuantitativo de 30 ejecuciones con 2 000 000 evaluaciones, el Recocido Simulado alcanzó una distancia media de 8,832.45 km (óptimo global), una desviación estándar de 15.47 km y un tiempo medio de ejecución de 0.344 s ($\sigma = 0.012$ s), con un coeficiente de variación de 0,18. Estos resultados, junto con su sencillez operativa y baja carga paramétrica, fundamentan la elección del Recocido Simulado como algoritmo para la optimización de rutas logísticas bajo condiciones meteorológicas variables.

De forma paralela, se evaluaron distintos modelos de machine learning orientados a la predicción de datos meteorológicos a partir de registros históricos. Cada propuesta fue sometida a pruebas de precisión y robustez, con el fin de anticipar eventos climáticos que pudieran afectar negativamente las operaciones logísticas, hasta elegir finalmente el modelo de Random Forest, el cual mostró un mayor valor de precisión (94%) al momento de predecir la condición meteorológica y se posicionó como el óptimo.

Para adaptar las penalizaciones del algoritmo bioinspirado a la percepción de riesgo en la conducción vial bajo distintas condiciones meteorológicas, se realizó una encuesta a 200 conductores (entre profesionales y particulares). El análisis de los datos recopilados permitió cuantificar, mediante una escala numérica discreta del 1 al 10, el nivel de peligrosidad asociado a cada fenómeno climático. Tormentas eléctricas y niebla se percibieron como los más peligrosos, mientras que las condiciones despejadas como las de menor riesgo.

En conjunto, los avances obtenidos en este proyecto permitieron sentar las bases para el desarrollo de un sistema que combine predicción climática y optimización de rutas, con el fin de minimizar tiempos de entrega transporte en condiciones meteorológicas adversas tomando en cuenta los objetivos ya establecidos. Este desarrollo permitirá evaluar el desempeño de los algoritmos seleccionados y validar la efectividad del modelo predictivo en condiciones reales, evaluando la aplicabilidad de la solución en entornos logísticos.

La siguiente etapa de desarrollo de este proyecto permitió consolidar la propuesta tecnológica de LogistiClima, avanzando desde el diseño conceptual hasta la implementación funcional de un prototipo que permite optimizar rutas logísticas terrestres considerando condiciones meteorológicas. En esta fase se abordó la construcción completa de los algoritmos que constituyen el núcleo del sistema, así como el desarrollo de la interfaz web que posibilita la interacción entre el usuario y los demás modelos. Todo ello implicó un proceso que incluyó diseño, programación, validación y ajuste, en el que se atendieron los retos técnicos que surgieron en el camino.

A partir de los objetivos planteados al inicio del proyecto, es posible afirmar que todos fueron alcanzados satisfactoriamente. Se completó la implementación de un algoritmo bioinspirado capaz de optimizar rutas terrestres con base en pronósticos meteorológicos, integrando parámetros que permiten adaptarse a escenarios reales del Estado de México. Asimismo, se desarrolló un modelo de Machine Learning que captura y representa de manera correcta las condiciones meteorológicas reales de las naves industriales. Ambos elementos se integraron en una interfaz web funcional que permite visualizar de manera gráfica las rutas generadas, buscando contribuir de esta manera a la optimización logística terrestre del Estado de México.

La culminación de esta fase no solo evidencia el dominio técnico del equipo en áreas como algoritmos bioinspirados, modelado predictivo y desarrollo web, sino también su capacidad para articular dichos conocimientos en una solución aplicable a una problemática real. Este proyecto representó un desafío significativo, tanto por la complejidad de los algoritmos implementados como por la necesidad de integrar diversas tecnologías en un solo sistema funcional; sin embargo, también constituyó una oportunidad para demostrar cómo los aprendizajes adquiridos a lo largo de la licenciatura pueden traducirse en herramientas útiles.

Finalmente, el trabajo también muestra la calidad del proceso colaborativo que sostuvo todo el trabajo. La comunicación constante, la coordinación y la capacidad para distribuir responsabilidades de forma estratégica

fueron factores esenciales para avanzar frente a los desafíos presentados. La colaboración permitió integrar distintas perspectivas y habilidades, dando como resultado un sistema coherente y alineado con los requerimientos reales del proyecto. Todo el trabajo realizado muestra la relevancia del proyecto, la solidez metodológica empleada y el compromiso del equipo por desarrollar soluciones innovadoras orientadas a las necesidades actuales del entorno.

Referencias

- [1] AKZENT STAFF, “Impacto de la logística en el desarrollo económico de México.” Accessed: Oct. 15, 2024. [Online]. Available: <https://blog.akzent.mx/impacto-de-la-logistica-en-el-desarrollo-economico-de-mexico>
- [2] A. 'Gómez, “Áreas clave para la logística en México, según Quincus.” Accessed: Oct. 15, 2024. [Online]. Available: <https://www.tyt.com.mx/nota/estas-son-las-areas-clave-para-la-logistica-en-mexico-segun-quincus>
- [3] INEGI, “Complejos industriales: Censos Económicos 2019,” México, 2019.
- [4] R. Morales, “Se adapta la distribución de productos ante fuertes lluvias en el EdoMéx.” Accessed: Mar. 10, 2025. [Online]. Available: <https://asisucede.com.mx/se-adapta-la-distribucion-de-productos-ante-fuertes-lluvias-en-el-edomex/>
- [5] F. Moreno-Ceja, M. del R. Zumaya-Leal, and A. Curiel-Ballesteros, “El transporte motorizado como presión al bienestar en ciudades en expansión,” *Revista de Salud Pública*, vol. 17, no. 2, pp. 242–253, 2015, Accessed: Mar. 10, 2025. [Online]. Available: <http://dx.doi.org/10.15446/rsap.v17n2.44511>
- [6] CCCB, “El papel de la IA en el clima, la meteorología y la calidad del aire.” Accessed: Oct. 16, 2024. [Online]. Available: <https://www.cccb.org/es/actividades/ficha/el-papel-de-la-ia-en-el-clima-la-meteorologia-y-la-calidad-del-aire/243318>
- [7] “¿Qué es la inteligencia artificial y cómo se usa?,” Temas - Parlamento Europeo. Accessed: Apr. 10, 2025. [Online]. Available: <https://www.europarl.europa.eu/topics/es/article/20200827STO85804/que-es-la-inteligencia-artificial-y-como-se-usa>
- [8] A. León-Javier, “Diseño e implementación en hardware de un algoritmo bioinspirado,” Instituto Politécnico Nacional, Ciudad de México, 2009. Accessed: Mar. 10, 2025. [Online]. Available: <https://ipn.mx/>
- [9] M. Cadena-Florero, L. Fajardo-Cely, and G. Peña-Contreras, “Algoritmos Genéticos y su aplicación para el análisis del problema del agente viajero,” Bogotá, 2019.
- [10] E. L. Lawler, J. K. Lenstra, A. R. Kan, and D. B. Shnomys, “The Traveling Salesman Problem: A Guided Tour of Combinatorial Optimization,” 1985, *New York*.
- [11] N. Christofides, “The vehicle routing problem,” *RAIRO Rech*, vol. 10, no. V1, pp. 55–70, 1976.
- [12] D. Goldberg, “Genetic Algorithms in Search, Optimization, and Machine Learning,” 1989, *Boston, USA*.
- [13] J. Kennedy and R. Eberhart, “Particle swarm optimization,” *Int. Conf. Neural Netw*, vol. 4, pp. 1942–1948, 1995.
- [14] X. S. Yang, “A new metaheuristic bat-inspired algorithm,” 2010.
- [15] X. S. Yang, “Firefly algorithms for multimodal optimization,” *Stochastic Algorithms: Foundations and Applications*, pp. 169–178, 2009.

- [16] A. E. S. Ezugwu, A. O. Adewumi, and M. E. Frîncu, "Simulated annealing based symbiotic organisms search optimization algorithm for traveling salesman problem," vol. 77, pp. 189–210, 2017.
- [17] D. Pérez, "Clase 17-20. Algoritmo genético híbrido," Ciudad de México, 2019.
- [18] D. Pérez, "Clase 13-15. Manejo de restricciones," Ciudad de México, 2019.
- [19] C. Coello, "Introducción a la Computación Evolutiva (Notas de Curso)." [Online]. Available: <https://delta.cs.cinvestav.mx/~ccoello/comepevol/apuntes.pdf>
- [20] "Machine Learning: definición, tipos y aplicaciones prácticas."
- [21] Ari Yair Barrera-Animas, Lukumon O. Oyedele, Muhammad Bilal, Taofeek Dolapo Akinosho, Juan Manuel Davila Delgado, and Lukman Adewale Akanbi, "Rainfall prediction: A comparative analysis of modern machine learning algorithms for time-series forecasting," *Machine Learning with Applications*, vol. 7, 2022.
- [22] Chrystal R. China, "Cinco tipos de machine learning que debe conocer," IBM Think. Accessed: May 10, 2025. [Online]. Available: <https://www.ibm.com/mx-es/think/topics/machine-learning-types>
- [23] C. Stryker, "¿Qué es una red neuronal recurrente (RNN)?," IBM. Accessed: Apr. 25, 2025. [Online]. Available: <https://www.ibm.com/mx-es/think/topics/recurrent-neural-networks>
- [24] C. Stryker, "¿Qué es una red neuronal recurrente (RNN)?"
- [25] C. Stryker, "¿Qué es una máquina de vectores de soporte (SVM)?," IBM. Accessed: Apr. 25, 2025. [Online]. Available: <https://www.ibm.com/mx-es/think/topics/support-vector-machine>
- [26] "¿Qué son los árboles de decisión?," IBM. Accessed: Apr. 25, 2025. [Online]. Available: <https://www.ibm.com/mx-es/think/topics/decision-trees>
- [27] R. Meenal, Prawin Angel Michael, D. Pamela, and E. Rajasekaran, "Random forest, la gran técnica de Machine Learning," Inesdi.
- [28] Nagesh Singh Chauhan, "Métricas De Evaluación De Modelos En El Aprendizaje Automático," *DataSource.ai*. Accessed: May 10, 2025. [Online]. Available: <https://www.datasource.ai/es/data-science-articles/metricas-de-evaluacion-de-modelos-en-el-aprendizaje-automatico>
- [29] R. Meenal, P. A. Michael, D. Pamela, and E. Rajasekaran, "Weather prediction using random forest machine learning model," *Indonesian Journal of Electrical Engineering and Computer Science*, vol. 22, no. 2, pp. 1208–1215, May 2021.
- [30] F. Fernández, "Meteorología y climatología. Aspectos generales," *Revista Indice*, pp. 6–9, Jan. 2012, Accessed: Mar. 30, 2025. [Online]. Available: <https://revistaindice.com/numero50/p6.pdf>
- [31] J. L. Fuentes, *Iniciación a la meteorología y climatología*. Madrid: Ediciones Mundi-Prensa, 2000.
- [32] J. L. Fuentes, *Iniciación a la meteorología y climatología*. Madrid: Ediciones Mundi-Prensa, 2000. Accessed: Mar. 30, 2025. [Online]. Available: https://books.google.es/books?hl=es&lr=lang_es&id=yHIqEQAAQBAJ&oi=fnd&pg=PA7&dq=que+es+la+meteorolog%C3%ADa&ots=9cPbbsdCbo&sig=KdshKoKAw-7XfQQva-Yhev-QbY#v=onepage&q&f=false

- [33] Secretaria de Comunicaciones y Transportes, “Conducir bajo la lluvia.” Accessed: Apr. 06, 2025. [Online]. Available: <https://www.gob.mx/sct/articulos/conducir-con-seguridad-bajo-la-lluvia?idiom=es>
- [34] Andres Sevilla, “Logística.” Accessed: Mar. 28, 2025. [Online]. Available: <https://economipedia.com/definiciones/logistica.html>
- [35] Anna Thompson, “¿Qué es la logística? Significado, procesos, funciones y ejemplos.” Accessed: Mar. 28, 2025. [Online]. Available: <https://www.dhl.com/discover/es-es/asesoramiento-logistico/asesoramiento-exportacion-importacion/que-es-logistica>
- [36] “Routal, the simplest and most efficient route optimizer.” Accessed: Oct. 15, 2024. [Online]. Available: <https://www.routal.com/en>
- [37] “Energy Webcast #2: Digitalization & Operations – Greenplan.” Accessed: Oct. 15, 2024. [Online]. Available: <https://greenplan.de/energy-webcast-2-digitalization-operations/>
- [38] Rout4Me, “Planificador de rutas de la última milla.” Accessed: Oct. 12, 2024. [Online]. Available: <https://www.route4me.com/es>
- [39] M. Holmstrom, D. Liu, and C. Vo, “Machine Learning Applied to Weather Forecasting,” Stanford, Dec. 2016.
- [40] J. Avila and J. Bailón, “Introducción. En Análisis y diseño en POO,” Portal Académico del CCH, UNAM. Accessed: Apr. 12, 2025. [Online]. Available: <https://portalacademico.cch.unam.mx/cibernetica1/analisis-y-diseno-en-poo/introduccion>
- [41] Matlab, “Herramientas de desarrollo de software,” Matlab. Accessed: May 14, 2025. [Online]. Available: https://la.mathworks.com/help/matlab/software-development.html?s_tid=CRUX_lftnav
- [42] B. Tuychiev, “Python vs Java: Diferencias y similitudes en 9 áreas clave,” Datacamp. Accessed: May 14, 2025. [Online]. Available: <https://www.datacamp.com/es/blog/python-vs-java>
- [43] R. Pereira *et al.*, “Energy efficiency across programming languages: how do energy, time, and memory relate?,” in *Proceedings of the 10th ACM SIGPLAN International Conference on Software Language Engineering*, New York, NY, USA: ACM, Oct. 2017, pp. 256–267. doi: 10.1145/3136014.3136031.
- [44] Himanshu Gupta, “Machine Learning Forecasting: How AI is Improving Weather Forecasting,” ClimateAi Blog. Accessed: May 12, 2025. [Online]. Available: <https://climate.ai/blog/machine-learning-forecasting-how-ai-is-improving-weather-forecasting/>
- [45] B. Toaza and D. Esztergár-Kiss, “A review of metaheuristic algorithms for solving TSP-based scheduling optimization problems,” *Appl Soft Comput*, vol. 148, p. 110908, Nov. 2023, doi: 10.1016/j.asoc.2023.110908.